LINEAR ALGEBRA

CONDENSED LECTURE NOTES

GRADO EN INGENIERÍA ELÉCTRICA

Gonzalo Contreras Aso[*]

*Based on the book by David C. Lay [**lay2007algebra**]. These lecture notes are unfinished: please report any issues/errata you may find.*

Universidad Carlos III de Madrid

1st September 2025 – 31st December 2025

"Mathematics is the art of reducing any problem to linear algebra." - William Stein, University of Washington.

CONTENTS

I Números complejos **6**

1 Introducción histórica 6

2 Definiciones básicas 6
- 2.1 Conjugación y división . . . 6
- 2.2 Plano complejo . . . 7

3 Formas trigonométrica y polar 7
- 3.1 Forma trigonométrica . . . 7
- 3.2 La forma polar . . . 8
- 3.3 Raíces . . . 10

4 Polinomios en $\mathbb{C}$ 11
- 4.1 Teorema Fundamental del Álgebra . . . 11
- 4.2 Teorema de los pares conjugados . . . 12

II Sistemas lineales **13**

5 Sistemas de ecuaciones lineales 13
- 5.1 Introducción . . . 13

[*] gcontrer (at) math (dot) uc3m (dot) es

5.2 Resolución de sistemas lineales . . . 14
5.3 Solución de sistemas lineales . . . 16
5.4 Ecuaciones vectoriales . . . 16
5.5 Combinaciones lineales y sistemas lineales . . . 18
5.6 Forma matricial . . . 19
5.7 Conjuntos solución . . . 20
5.8 Independencia lineal . . . 22
5.9 Teoremas importantes . . . 23

6 Transformaciones lineales 23
6.1 Introducción . . . 23
6.2 Transformaciones geométricas en $\mathbb{R}^2$ . . . 27
6.3 Teoremas sobre transformaciones lineales . . . 28

7 Extra 29
7.1 Polinomio interpolador . . . 29
7.2 Problemas de flujo en redes . . . 30

III Álgebra matricial y determinantes 33

8 Álgebra matricial 33
8.1 Operaciones básicas . . . 33
8.2 Multiplicación de matrices . . . 34
8.3 Transposición . . . 36

9 Inversa de una matriz 36
9.1 Cálculo de la inversa . . . 37
9.2 Teorema de la matriz inversa (I) . . . 37
9.3 Inversas de transformaciones lineales . . . 38

10 Matrices definidas por bloques 38

11 Determinantes 39
11.1 Definición y cálculo . . . 40
11.2 Comportamiento bajo operaciones fila . . . 41
11.3 Otras propiedades . . . 43

12 Extra 43
12.1 Relaciones de conmutación . . . 43
12.2 Algunos tipos de matrices importantes . . . 44
12.3 Pseudoinversas . . . 45

IV Espacios vectoriales 46

13 Espacios vectoriales 46
13.1 Axiomas aditivos . . . 46
13.2 Axiomas de multiplicación por escalar . . . 47
13.3 Ejemplos y contraejemplos de espacios vectoriales . . . 47
13.4 Subespacios vectoriales . . . 48

14 Espacios nulos, columna y transformaciones 50
14.1 El espacio columna . . . 50

14.2 Transformaciones lineales 51

15 Bases 51
15.1 Conjuntos linealmente independientes 51
15.2 Sistemas de coordenadas 53
15.3 Cambio de base 55

16 Dimensión de un espacio vectorial 56
16.1 Rango 58
16.2 Teorema de la matriz inversa (II) 58

V Valores y vectores propios 59

17 Introducción 59
17.1 Vectores y valores propios 59
17.2 Subespacios propios 60

18 Ecuación característica 61
18.1 Autovalores complejos 62
18.2 Multiplicidad de autovalores 62

19 Diagonalización 64
19.1 Matrices semejantes 64
19.2 Diagonalización de matrices 64
19.3 Ventajas operacionales de la diagonalización 66
19.4 Teorema de la matriz inversa (III) 66

20 Extra 67
20.1 Forma canónica de Jordan 67
20.2 Procesos de Markov 67

VI Producto escalar 69

21 Introducción 69
21.1 Producto interno 69
21.2 La matriz de Gram 70

22 Ortogonalidad 73
22.1 Complemento ortogonal 73
22.2 Conjuntos ortogonales 74
22.3 Proyecciones 76
22.4 Proceso de Gram–Schmidt 76

23 Optimización 78
23.1 Mínimos cuadrados 79

24 Extra 80
24.1 Descomposición QR 80

A Derivaciones de la fórmula de Euler 80
.1 A partir de la derivada del arcotangente 80

.2 A partir de la ecuación diferencial de la exponencial 81
.3 A partir de las correspondientes series de Taylor 81

B Matrices simétricas y matrices no negativas **83**

Notación y conceptos previos

Part I

Números complejos

1 INTRODUCCIÓN HISTÓRICA

La noción de "número" ha ido cambiando a lo largo de la historia. Ampliar su extensión introduce dificultades técnicas pero posibilita nuevas herramientas y conceptos.

- Originalmente: la gente usaba números solo para contar cosas $\Rightarrow$ números naturales. Solo se pueden restar si $x > y \Rightarrow x - y$.
- 976 d.C.: al-Khwarizmi introduce el 0 $\Rightarrow$ se pueden definir números negativos como el inverso del positivo, y la resta ya se extiende a cualquier número.
- Siglo XVIII: los complejos se formalizan por Euler para obtener soluciones de ecuaciones algebraicas y se empiezan a utilizar.

Fundamentales en trigonometría, ecuaciones diferenciales (vibraciones, cuántica, ...), circuitos, análisis de señales (Fourier, ...). Cualquier fenómeno periódico esconde por detrás números complejos.

2 DEFINICIONES BÁSICAS

Un **número complejo** $z \in \mathbb{C}$ es una dupla $z = (a, b)$ con $a, b \in \mathbb{R}$ con las propiedades:

- Suma: $(a_1, b_1) + (a_2, b_2) = (a_1 + a_2, b_1 + b_2)$
- Producto: $(a_1, b_1) \cdot (a_2, b_2) = (a_1 a_2 - b_1 b_2, a_1 b_2 + a_2 b_1)$

En general, se expresan de formas más cómodas: la **forma binómica**:

$$z = a + ib, \quad i^2 = -1.$$

donde i se conoce usualmente como la "unidad imaginaria"[1]

Ejemplo: $z_1 = 2 + i,\ z_2 = 3 + 4i$

- Suma: $z_1 + z_2 = 5 + 5i$
- Producto: $z_1 z_2 = 2 + 11i$
- Resta: $z_1 - z_2 = -1 - 3i$

Nótese que la resta no es una operación "nueva", sino que se deriva de la suma y el producto, como $z_1 - z_2 = z_1 + (-1) \cdot z_2$, ya que $-1 = -1 + 0i$ es un número complejo como cualquier otro.

2.1 *Conjugación y división*

Una operación esencial es la **conjugación**:

$$z = a + ib \quad \Rightarrow \quad \overline{z} = a - ib.$$

Propiedades:

$$\overline{\overline{z}} = z, \quad \overline{z_1 + z_2} = \overline{z_1} + \overline{z_2}, \quad \overline{z_1 z_2} = \overline{z_1} \cdot \overline{z_2}, \quad z\overline{z} = a^2 + b^2 \in \mathbb{R}.$$

[1] El sobrenombre "imaginario" para los complejos es bastante nefasto, con raíces históricas.

La conjugación permite calcular fácilmente la división de números complejos $z \neq 0$:

$$z^{-1} = \frac{1}{z} = \frac{\overline{z}}{z\overline{z}} = \frac{\overline{z}}{a^2 + b^2}.$$

Dado un número complejo $z = a + ib$, podemos definir su parte real y su parte imaginaria como $\mathrm{Re}(z) = a$, $\mathrm{Im}(z) = b$. Estas se pueden obtener, alternativamente, como

$$\mathrm{Re}(z) = \frac{z + \overline{z}}{2}, \qquad \mathrm{Im}(z) = \frac{z - \overline{z}}{2i}.$$

2.2 *Plano complejo*

Podemos representar cada número como un punto en un plano, donde el eje de abscisas representa $\mathrm{Re}(z)$ y el eje de ordenadas $\mathrm{Im}(z)$.

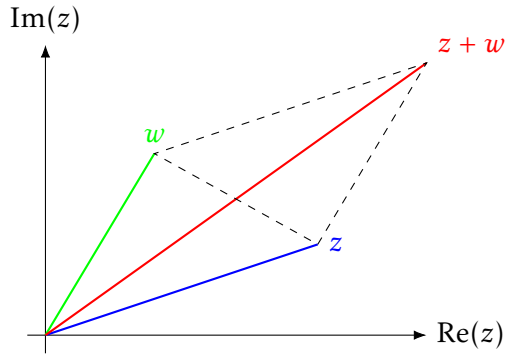

La suma de números se interpreta como la suma de los vectores asociados a cada punto. Para esta operación, la forma binómica es idónea. Pero como veremos, las siguientes formas de describir números complejos son mejores a la hora de interpretar el producto de estos.

3 FORMAS TRIGONOMÉTRICA Y POLAR

3.1 *Forma trigonométrica*

Sea $z = a + ib$. Existe $r \geq 0$, $\theta \in [0, 2\pi)$ tal que:

$$z = r(\cos\theta + i\sin\theta).$$

Desde el punto de vista del plano complejo, estaríamos describiendo los números en coordenadas polares (radio, ángulo) en lugar de en cartesianas (horizontal, vertical).

El cambio entre una descripción u otra nos la proporcionan nociones básicas de trigonometría:

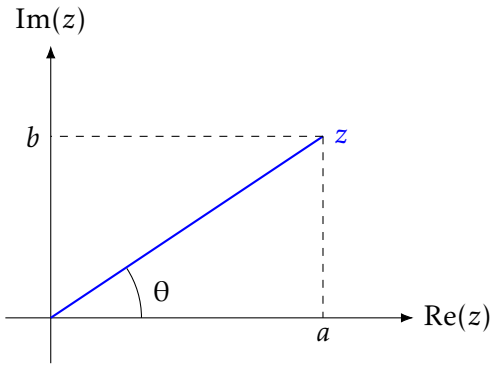

Se define el **módulo** de z como $r = |z| = \sqrt{a^2 + b^2}$ (el Teorema de Pitágoras) y el **argumento principal** de z como $\theta = \mathrm{Arg}(z) = \arctan(b/a) \in [0, 2\pi)$.

- Si calculamos el argumento de un número complejo y nos da un ángulo fuera del rango $[0, 2\pi)$, tendremos que convertirlo al equivalente en ese rango.
- El arco tangente toma los mismos valores para ángulos de cuadrantes opuestos: por tanto, una vez calculada esa función debemos asegurarnos de que el ángulo obtenido es el correcto, visualizando la posición del número complejo en el plano.

  Ejemplo. aunque $\tan(\pi/4) = \tan(5\pi/4)$, corresponden a números complejos distintos, algo que tenemos que tener en mente:

$$\mathrm{Arg}(1 + i) = \arctan(1) = \pi/4, \quad \text{sin embargo} \quad \mathrm{Arg}(-1 - i) = \arctan(1) = 5\pi/4$$

3.1.1 Operaciones en forma trigonométrica

La suma no es diferente de la de la forma binómica. Sin embargo, los productos, divisiones y potencias adquieren fórmulas nuevas, que permiten calcular estas operaciones de forma más rápida.

- Producto: $z_1 z_2 = r_1 r_2 \big(\cos(\theta_1 + \theta_2) + i \sin(\theta_1 + \theta_2) \big)$
- División: $\dfrac{z_1}{z_2} = \dfrac{r_1}{r_2} \big(\cos(\theta_1 - \theta_2) + i \sin(\theta_1 - \theta_2) \big)$
- Potencias (Teorema de De Moivre): $z^n = r^n \big(\cos(n\theta) + i \sin(n\theta) \big)$

No solo tenemos la ventaja computacional de estas operaciones, también nos proporcionan una forma de interpretar la multiplicación (similarmente, la división) de números complejos:

$$\begin{cases} r_1 r_2 & \text{escalado de uno con el módulo del otro} \\ \theta_1 + \theta_2 & \text{rotación de uno con el argumento del otro} \end{cases} \quad \Rightarrow \quad z_1 z_2 = \underbrace{r_1 r_2}_{\text{escalado}} \Big(\cos \underbrace{(\theta_1 + \theta_2)}_{\text{rotacion}} + i \sin \underbrace{(\theta_1 + \theta_2)}_{\text{rotacion}} \Big)$$

Por ejemplo, si multiplicamos un número por otro de módulo 1, lo que hacemos es rotar el primer número alrededor del origen de coordenadas, manteniendo el radio.

3.2 *La forma polar*

Existe una conexión muy profunda entre las funciones trigonométricas y las exponenciales, mediada por la famosa Fórmula de Euler (a veces conocida como "la ecuación más bonida de las Matemáticas"):

$$e^{i\theta} = \cos(\theta) + i \sin(\theta).$$

Está fuera del nivel de esta clase demostrar esta igualdad, hay cientos de recursos bibliográficos u online que lo muestran (por ej. [2]). Pero podemos motivarla: la multiplicación afecta al ángulo en una rotación, que en esencia es una suma. ¿Qué función cumple que transforma una multiplicación en una suma, es decir, $f(x)f(y) = f(x + y)$? La exponencial, $e^x e^y = e^{x+y}$.

3.2.1 Operaciones en forma polar

Por lo general es mucho más cómodo trabajar con exponenciales que con senos y cosenos, y las operaciones son análogas en esta forma:

- $z_1 z_2 = r_1 r_2 e^{i(\theta_1 + \theta_2)}$
- $\dfrac{z_1}{z_2} = \dfrac{r_1}{r_2} e^{i(\theta_1 - \theta_2)}$
- $z^n = r^n e^{in\theta}$

Ejemplo. Sea $z = 2 + 2i$, $w = -\sqrt{3} + i$

En forma trigonométrica/polar, tenemos

$$z = 2\sqrt{2}\left(\cos\frac{\pi}{4} + i\sin\frac{\pi}{4}\right) = \sqrt{2}e^{i\pi/4}$$

$$w = 2\left(\cos\frac{5\pi}{6} + i\sin\frac{5\pi}{6}\right) = 2e^{i5\pi/6}$$

Su multiplicación y división es

$$z \cdot w = 4\sqrt{2}\, e^{i\frac{13\pi}{12}},$$

$$\frac{z}{w} = \sqrt{2}\, e^{-i\frac{7\pi}{12}} = \sqrt{2}\, e^{i\frac{17\pi}{12}}$$

donde hemos pasado $-\frac{7\pi}{12}$ al ángulo en el rango correcto.

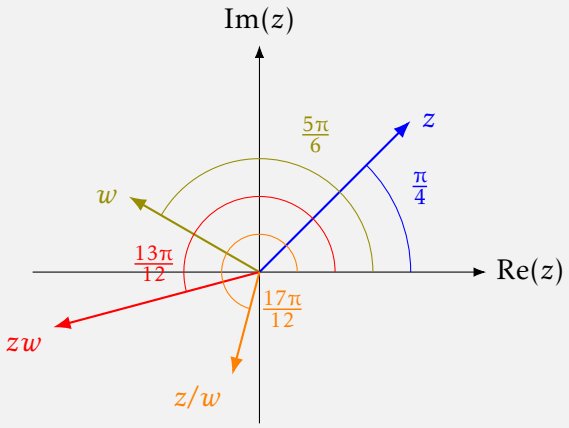

El siguiente ejemplo ilustra la conexión entre las rotaciones y la multiplicación de números complejos, a través del rol de la unidad imaginaria.

Ejemplo (multiplicación por i): en forma polar, la unidad imaginaria se escribe como

$$i = \cos\frac{\pi}{2} + i\sin\frac{\pi}{2} = e^{i\pi/2}.$$

Por lo tanto, multiplicar por i equivale a rotar 90° en sentido antihorario en el plano complejo, sin cambiar el radio (puesto que $|i| = 1$).

$i \cdot 1 \equiv$ 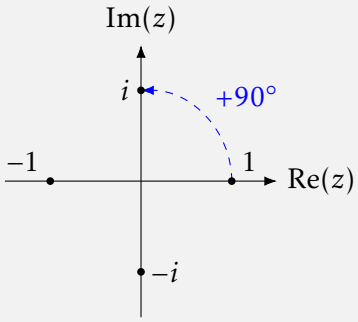

$\equiv i,$

$i \cdot i \equiv$ 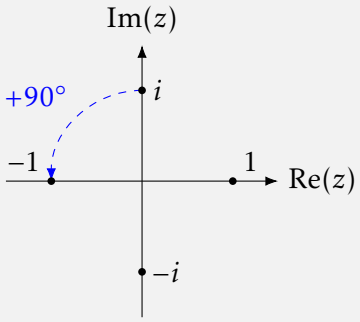

$\equiv -1,$

$i \cdot (-1) \equiv$ 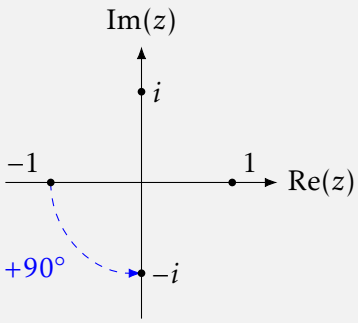

$\equiv -i,$

$i \cdot (-i) \equiv$ 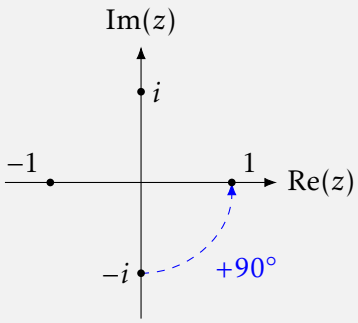

$\equiv 1.$

Ejercicio. Usando la fórmula de Euler, obtener las fórmulas de ángulo doble.

$$z = \cos(2\theta) + i\sin(2\theta) = e^{i2\theta} = (e^{i\theta})^2 = (\cos\theta + i\sin\theta)^2.$$

Expandiendo:

$$z = \cos^2\theta - \sin^2\theta + i(2\cos\theta\sin\theta).$$

Por lo tanto:

$$\mathrm{Re}(z) = \cos 2\theta = \cos^2\theta - \sin^2\theta, \qquad \mathrm{Im}(z) = \sin 2\theta = 2\sin\theta\cos\theta.$$

Análogamente se obtienen las fórmulas de suma de ángulos.

3.3 *Raíces*

De nuevo, acudimos a la forma polar:

$$\sqrt[n]{z} = z^{1/n}$$

Cuidado: aunque usamos el argumento principal $\theta \in [0, 2\pi)$ para describir únivocamente a un número complejo, realmente hay infinitos ángulos

$$\theta \sim \theta + 2\pi k, \quad k \in \mathbb{Z},$$

que representan el mismo z. Estos a la hora de representar o tratar con el número no son relevantes (son "giros de más" respecto al origen), pero a la hora de hacer las raíces se convierten en soluciones nuevas.

En general, para raíces debemos considerar

$$\frac{\theta}{n} + \frac{2\pi k}{n}, \quad k = 0, 1, \ldots, n-1,$$

que son n ángulos distintos, cada uno correspondiente a una raíz. El resto de los infinitos ángulos que surgen de otros valores de k están fuera del rango $[0, 2\pi)$, siendo equivalentes a alguno de los calculados.

Por tanto las n raíces de z son

$$\sqrt[n]{z} = \left\{\sqrt[n]{r}e^{i\frac{\theta}{n}}, \sqrt[n]{r}e^{i\frac{\theta+2\pi}{n}}, \sqrt[n]{r}e^{i\frac{\theta+4\pi}{n}}, \ldots\right\}$$

Ejemplos

- Desde la escuela sabemos que $(\pm 2)^2 = 4$. Vamos a comprobarlo:

$$z = 4 = 4e^{i0} \quad \Rightarrow \quad \sqrt{z} = \sqrt{4}\left\{e^{i0/2}, e^{i2\pi/2}, e^{i4\pi/2}, \ldots\right\} = \{2, -2\}.$$

- Si z es tal que $\mathrm{Arg}(z) = \pi$, entonces

$$\mathrm{Arg}(\sqrt{z}) \in \left\{\tfrac{\pi}{2}, \tfrac{3\pi}{2}\right\}.$$

- Calculamos y graficamos las raíces cúbicas de -27, una de las cuales, $(-3)^3 = -27$ la conocemos desde la escuela.

$$z = -27 = 27e^{i\pi}$$

$$\sqrt[3]{z} = \sqrt[3]{27}\left\{e^{i\pi/3}, e^{i(\pi/3+2\pi/3)}, e^{i(\pi/3+4\pi/3)}, \dots\right\}$$

$$= \{3e^{i\pi/3},\ 3e^{i\pi},\ 3e^{i5\pi/3}\}.$$

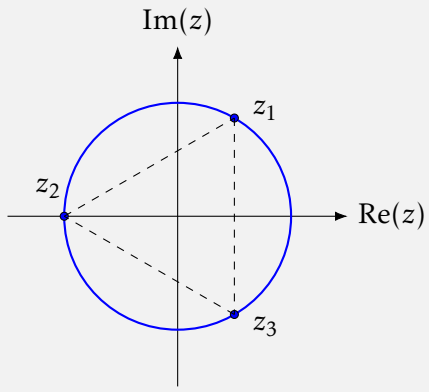

Hecho interesante (y útil): las raíces de cualquier número complejo se sitúan en un círculo de radio $\sqrt[n]{r}$, formando un polígono regular de n lados. Esto está íntimamente ligado al rol de la multiplicación de números complejos vista como rotaciones.

4 POLINOMIOS EN

4.1 *Teorema Fundamental del Álgebra*

Históricamente, el interés por los números complejos surgió de intentar obtener soluciones de ecuaciones polinómicas. Si bien con el tiempo se ha visto que los números complejos son fundamentales en cantidad de aplicaciones más allá de eso, sigue siendo un resultado de gran importancia la completitud de las ecuaciones algebraicas sobre el cuerpo de los números complejos.

4.1 THEOREM (Teorema fundamental del álgebra). *Sea un polinomio*

$$p(z) = a_0 + a_1 z + \cdots + a_n z^n, \quad a_i \in \mathbb{C}.$$

Este polinomio tiene exactamente n raíces (contando multiplicidades).

Este teorema está íntimamente ligado al siguiente, también importante.

4.2 THEOREM (Teorema de la factorización). *Sea un polinomio*

$$p(z) = a_0 + a_1 z + \cdots + a_n z^n, \quad a_i \in \mathbb{C}.$$

Este polinomio se puede factorizar como

$$p(z) = a_n(z - z_1)^{m_1}(z - z_2)^{m_2} \cdots (z - z_k)^{m_k},$$

donde m_i es la multiplicidad de la raíz z_i, y

$$n = \sum_{i=1}^{k} m_i = m_1 + m_2 + \cdots + m_k.$$

EJEMPLO: si $p(z) = z^3 - 2z^2 + z$, tenemos que este polinomio tiene tres raíces (contando multipliciades) en $\mathbb{C}$: $z = 0$ raíz simple (multiplicidad 1), y $z = 1$ doble. Se puede escribir como $p(z) = z(z-1)^2$.

Nota: la relevancia de este teorema en este contexto es que no es cierto si trabajamos en $\mathbb{R}$. En los reales hay polinomios que tienen menos raíces que su grado. Los complejos permiten resolver cualquier ecuación polinómica, obteniendo su máximo de soluciones.

4.2 *Teorema de los pares conjugados*

Part II

Sistemas lineales

5 SISTEMAS DE ECUACIONES LINEALES

5.1 *Introducción*

Una **ecuación lineal** en $\{x_1, \dots, x_n\}$ es

$$a_1x_1 + a_2x_2 + \cdots + a_nx_n = b,$$

donde $a_1, \dots, a_n, b \in \mathbb{R}$ son coeficientes.

Ejemplos:

$$3x_1 + 5x_2 = 3, \quad 5x - 8y + 4 = -10z + x.$$

Un **sistema de ecuaciones lineales** es una colección de estas. Una **solución** es una lista $s_1, \dots, s_n \in \mathbb{R}$ que satisface todas las ecuaciones. El conjunto de soluciones es el **conjunto solución**.

Dos sistemas son **equivalentes** si tienen el mismo conjunto solución.

Ejemplo. Interpretación geométrica (caso 2D)

$$\begin{cases} x_1 - 2x_2 = -1, \\ -x_1 + 3x_2 = 3 \end{cases}$$

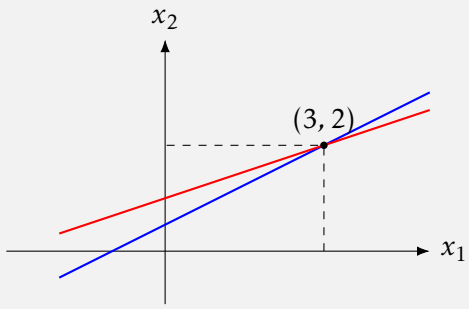

En 3D serían planos, en 4D hiperplanos.

Un sistema lineal puede tener:

- 0 soluciones (por ejemplo, rectas paralelas),
- 1 solución (por ejemplo, rectas que se cortan en un punto),
- Infinitas soluciones (por ejemplo, rectas idénticas).

Los sistemas lineales no pueden dar un número $1 < n < \infty$ de soluciones: por ejemplo, para dos soluciones al menos una de las dos ecuaciones habría de ser cuadrática, y por tanto no lineal.

5.1.1 Notación matricial

Podemos compactar información con matrices.

EJEMPLO.

$$e_1 : x_1 - 2x_2 + x_3 = 0,$$

$$e_2 : 2x_2 - 8x_3 = 8,$$

$$e_3 : -4x_1 + 5x_2 + 9x_3 = -9.$$

Matriz de coeficientes:

$$\begin{bmatrix} 1 & -2 & 1 \\ 0 & 2 & -8 \\ -4 & 5 & 9 \end{bmatrix}$$

Matriz aumentada:

$$\begin{bmatrix} 1 & -2 & 1 & 0 \\ 0 & 2 & -8 & 8 \\ -4 & 5 & 9 & -9 \end{bmatrix}$$

5.2 *Resolución de sistemas lineales*

Estrategia: llevar el sistema a uno equivalente más fácil de resolver.

Tres **operaciones elementales** *que no cambian la solución del sistema*:

1. Reemplazar una ecuación por una combinación lineal de ella misma y otra.
2. Intercambiar ecuaciones.
3. Multiplicar una ecuación por un número distinto de 0.

EJEMPLO ANTERIOR: Reemplazamos $e_3 \to e_3 + 4e_1$ para eliminar x_1 de la tercera ecuación:

$$\begin{bmatrix} 1 & -2 & 1 & 0 \\ 0 & 2 & -8 & 8 \\ 0 & -3 & 13 & -9 \end{bmatrix} \sim \begin{bmatrix} 1 & -2 & 1 & 0 \\ 0 & 1 & -4 & 4 \\ 0 & 0 & 1 & 3 \end{bmatrix} \sim \begin{bmatrix} 1 & 0 & 0 & 29 \\ 0 & 1 & 0 & 16 \\ 0 & 0 & 1 & 3 \end{bmatrix} \quad \Leftrightarrow \quad \begin{cases} x_1 = 29, \\ x_2 = 16, \\ x_3 = 3. \end{cases}$$

donde el símbolo $\sim$ denota "equivalente por filas" (es decir, que de una matriz a otra hemos llegado a través de operaciones elementales).

Por tanto, la solución es

$$(x_1, x_2, x_3) = (29, 16, 3).$$

En general, cuando discutimos la resolución de ecuaciones, nos preguntamos:

- **Existencia**: ¿existe al menos una solución?
- **Unicidad**: de existir, ¿es única?

5.2.1 Reducción por filas y formas escalonadas

La **entrada principal** de una fila no nula de una matriz es la entrada no nula más a la izquierda de esa fila.

Una matriz está en **forma escalonada** si:

- Las filas de ceros están al final.
- La entrada principal de cada fila no nula está a la derecha de la anterior.

- Todo lo que está debajo de una entrada principal son ceros.

Ejemplo.

$$\begin{bmatrix} 2 & -3 & 0 & 7 & 10 \\ 0 & 8 & 4 & 3 & 0 \\ 0 & 0 & 0 & 1 & -2 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$

Está en **forma escalonada reducida** si además:

- Todas las entradas principales son 1.
- Cada columna de un pivote tiene 0's en todas las demás filas.

Ejemplo.

$$\begin{bmatrix} 1 & 0 & 0 & 10 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & -2 \end{bmatrix}$$

El siguiente resultado es fundamental: nos dice que, tomemos el camino que tomemos, si usamos las operaciones elementales siempre vamos a llegar a la misma forma escalonada reducida.

5.1 THEOREM. *Cada matriz es equivalente (por filas) a una única matriz escalonada reducida.*

Las siguientes definiciones serán útiles más adelante:

- Una **posición pivote** es la posición de un 1 principal en la forma escalonada reducida.
- Una **columna pivote** es aquella que contiene una posición pivote (no todas lo son).

5.2.2 Algoritmo de reducción por filas (Gauss-Jordan)

El siguiente procedimiento lleva una matriz a su forma escalonada:

1. Seleccionar columna izquierda distinta de cero.
2. Seleccionar pivote no nulo (intercambiar filas si es necesario).
3. Reemplazar filas inferiores para crear ceros.
4. Repetir con la submatriz restante.

Para llegar a la forma escalonada reducida:

5. Con los pivotes de derecha a izquierda, crear ceros encima de las entradas principales.
6. Reescalar los pivotes a 1.

EJEMPLO. (con los pivotes indicados en rojo, las columnas pivote en naranja)

$$\begin{bmatrix} 0 & -3 & -6 & 4 & 9 \\ -1 & -2 & -1 & 3 & 1 \\ 2 & -3 & 0 & 3 & -1 \\ 1 & 4 & 5 & -9 & -7 \end{bmatrix} \underset{e_1 \leftrightarrow e_4}{\sim} \begin{bmatrix} 1 & 4 & 5 & -9 & -7 \\ -1 & -2 & -1 & 3 & 1 \\ 2 & -3 & 0 & 3 & -1 \\ 0 & -3 & -6 & 4 & 9 \end{bmatrix} \underset{\substack{e_2 \to e_1 + e_2 \\ e_3 \to e_3 + 2e_1}}{\sim} \begin{bmatrix} 1 & 4 & 5 & -9 & -7 \\ 0 & 2 & 4 & -6 & -6 \\ 0 & 5 & 10 & -15 & -15 \\ 0 & -3 & -6 & 4 & 9 \end{bmatrix}$$

$$\underset{\substack{e_3 \to e_3 - 5e_2/2 \\ e_4 \to e_4 + 3e_2/2}}{\sim} \begin{bmatrix} 1 & 4 & 5 & -9 & -7 \\ 0 & 2 & 4 & -6 & -6 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & -5 & 0 \end{bmatrix} \underset{e_3 \leftrightarrow e_4}{\sim} \begin{bmatrix} 1 & 4 & 5 & -9 & -7 \\ 0 & 2 & 4 & -6 & -6 \\ 0 & 0 & 0 & -5 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$

5.3 *Solución de sistemas lineales*

La reducción por filas conduce directamente a la descripción del conjunto solución.

5.2 THEOREM (Existencia y unicidad). *Un sistema tiene solución si y solo si la columna derecha de la matriz aumentada no es pivote. Es decir, no hay filas de la forma:*

$$[0\ 0\ \dots\ 0\ b], \quad b \neq 0$$

en la forma escalonada reducida. Si existe solución, esta es única si no hay variables libres.

EJEMPLO.

$$\begin{bmatrix} 1 & 0 & -5 & 1 \\ 0 & 1 & 1 & 4 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

Las variables x_1, x_2 aquí (pivotes) son variables "principales", mientras que x_3 es "libre". Las principales se puede despejar, en términos de las libres. La solución general es por tanto

$$\begin{cases} x_1 = 1 + 5x_3, \\ x_2 = 4 - x_3, \\ x_3 \ \text{ libre.} \end{cases}$$

En **forma paramétrica**, la solución se escribe

$$\vec{x} = \begin{bmatrix} 1 + 5t \\ 4 - t \\ t \end{bmatrix}, \quad t \in \mathbb{R}.$$

Un sistema con una o más soluciones se denomina **consistente**. De lo contrario, es **inconsistente**.

5.4 *Ecuaciones vectoriales*

Los sistemas lineales y sus propiedades tienen una clara interpretación en términos de vectores. Para simplicidad, lo discutimos en $\mathbb{R}^2$.

Un vector $\vec{v} = \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} \in \mathbb{R}^2$ es un elemento del plano, e identifica un punto con coordenadas cartesianas (v_1, v_2).

Nota importante: por convención siempre que hablemos de vector será vector *columna*.

Un repaso de conceptos básicos de vectores:

- Dos vectores son iguales si sus coordenadas son iguales.
- La suma de dos vectores $\vec{u}, \vec{v} \in \mathbb{R}^2$ es:

$$\vec{u} + \vec{v} = \begin{pmatrix} u_1 + v_1 \\ u_2 + v_2 \end{pmatrix} \in \mathbb{R}^2.$$

- El producto por un escalar $c \in \mathbb{R}$ es:

$$c\vec{v} = \begin{pmatrix} cv_1 \\ cv_2 \end{pmatrix} \in \mathbb{R}^2.$$

Ejemplo. La suma de vectores sigue la *regla del paralelogramo*

$$\vec{u} = \begin{pmatrix} 1 \\ 3 \end{pmatrix}, \quad \vec{v} = \begin{pmatrix} 2 \\ 1 \end{pmatrix},$$

$$\vec{u} + \vec{v} = \begin{pmatrix} 5 \\ 4 \end{pmatrix}, \quad 2\vec{v} = \begin{pmatrix} 4 \\ 2 \end{pmatrix}.$$

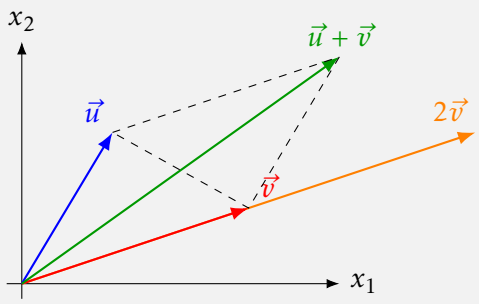

Todo lo discutido en $\mathbb{R}^2$ es análogo en $\mathbb{R}^n$.

5.4.1 Propiedades algebraicas de vectores en $\mathbb{R}^n$

Sean $\vec{u}, \vec{v}, \vec{w} \in \mathbb{R}^n$ y $c, d \in \mathbb{R}$:

(i) $\vec{u} + \vec{v} = \vec{v} + \vec{u}$ (conmutatividad)

(ii) $(\vec{u} + \vec{v}) + \vec{w} = \vec{u} + (\vec{v} + \vec{w})$ (asociatividad)

(iii) $\vec{u} + \vec{0} = \vec{0} + \vec{u} = \vec{u}$ (elemento neutro)

(iv) $\vec{u} + (-\vec{u}) = \vec{0}$ (inverso aditivo)

(v) $c(\vec{u} + \vec{v}) = c\vec{u} + c\vec{v}$ (distributividad)

(vi) $(c + d)\vec{u} = c\vec{u} + d\vec{u}$ (asociatividad respecto a escalares)

(vii) $c(d\vec{u}) = (cd)\vec{u}$ (compatibilidad escalar)

(viii) $1 \cdot \vec{u} = \vec{u}$ (elemento neutro multiplicativo)

donde $\vec{0}$ denota el vector de ceros, y $-\vec{v}$ denota $(-1)\vec{v}$.

Si bien todas estas propiedades son "evidentes" con vectores, es importante listarlas ya que hay muchos objetos matemáticos para los cuales no lo son tanto, o incluso desaparecen (por ejemplo, la conmutatividad en el producto de matrices no está garantizada). Por tanto hemos de dar las gracias a estas garantías siempre que estén.

5.5 *Combinaciones lineales y sistemas lineales*

Dados vectores $\vec{v}_1, \vec{v}_2, \ldots, \vec{v}_n \in \mathbb{R}^n$ y escalares $c_1, c_2, \ldots, c_n \in \mathbb{R}$, el vector:

$$\vec{y} = c_1\vec{v}_1 + c_2\vec{v}_2 + \cdots + c_n\vec{v}_n \equiv \sum_{i=1}^{n} c_i\vec{v}_i$$

se denomina **combinación lineal** de $\vec{v}_1, \ldots, \vec{v}_n$.

Esto no es más que la extensión a n dimensiones de algo que todo el mundo conoce: hacer medias con pesos. Por ejemplo, si un estudiante saca un 4 en un parcial que vale el 30% de la nota total, y un 8 en el otro parcial (que vale el 70% restante), tendrá como nota final la combinación lineal $0.3 \cdot 4 + 0.7 \cdot 8 = 6.8$, es decir, aprobado.

La existencia de combinaciones lineales está íntimamente relacionada con las soluciones de los sistemas lineales.

Ejemplo.

$$\vec{a}_1 = \begin{pmatrix} 1 \\ -2 \\ -5 \end{pmatrix}, \quad \vec{a}_2 = \begin{pmatrix} 2 \\ 5 \\ 6 \end{pmatrix}, \quad \vec{b} = \begin{pmatrix} 7 \\ 4 \\ -3 \end{pmatrix}.$$

Queremos escribir $\vec{b}$ como combinación lineal de $\vec{a}_1, \vec{a}_2$, es decir:

$$x_1\vec{a}_1 + x_2\vec{a}_2 = \vec{b}.$$

Sistema equivalente:

$$\begin{cases} x_1 + 2x_2 = 7 \\ -2x_1 + 5x_2 = 4 \\ -5x_1 + 6x_2 = -3 \end{cases}$$

En forma matricial:

$$[\vec{a}_1\ \vec{a}_2\ \vec{b}] = \begin{bmatrix} 1 & 2 & 7 \\ -2 & 5 & 4 \\ -5 & 6 & -3 \end{bmatrix} \sim \begin{bmatrix} 1 & 2 & 7 \\ 0 & 9 & 18 \\ 0 & 16 & 32 \end{bmatrix} \sim \begin{bmatrix} 1 & 2 & 7 \\ 0 & 1 & 2 \\ 0 & 0 & 0 \end{bmatrix} \sim \begin{bmatrix} 1 & 0 & 3 \\ 0 & 1 & 2 \\ 0 & 0 & 0 \end{bmatrix}.$$

No hay variables libres $\Rightarrow \vec{b}$ es combinación lineal con pesos $x_1 = 3,\ x_2 = 2$.

Por tanto, $x_1\vec{a}_1 + x_2\vec{a}_2 + \cdots + x_n\vec{a}_n = \vec{b}$ tiene el mismo conjunto solución que $[\vec{a}_1\ \vec{a}_2\ \ldots\ \vec{a}_n\ \vec{b}]$. Concluímos que un vector $\vec{b}$ es combinación lineal de $\vec{a}_1, \ldots, \vec{a}_n$ si y solo si existe solución al sistema lineal correspondiente.

5.5.1 Subespacios generados

El conjunto de todas las combinaciones lineales de $\vec{v}_1, \ldots, \vec{v}_n \in \mathbb{R}^n$ se llama:

$$\mathrm{Gen}\{\vec{v}_1, \ldots, \vec{v}_n\} \quad \text{o} \quad \mathrm{Span}\{\vec{v}_1, \ldots, \vec{v}_n\},$$

y recibe el nombre de **subespacio de $\mathbb{R}^n$ generado por los vectores**.

Ejemplos:

- $\text{Span}\{\vec{v}_1\} \sim \mathbb{R}$: una recta.

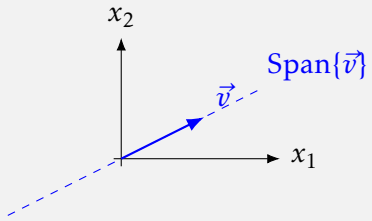

- $\text{Span}\{\vec{v}_1, \vec{v}_2\} \sim \mathbb{R}^2$: un plano en $\mathbb{R}^2$.

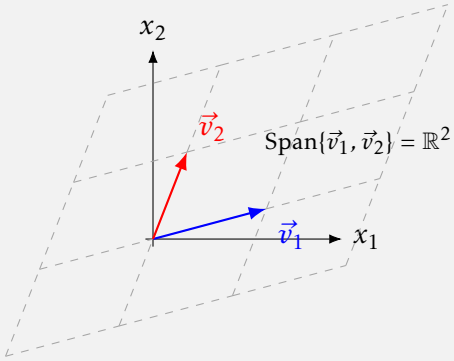

5.6 *Forma matricial*

Sea A una matriz de tamaño $m \times n$ con columnas $\vec{a}_1, \ldots, \vec{a}_n \in \mathbb{R}^m$. Entonces el producto de A y $\vec{x}$ es la combinación lineal de las columnas de A con pesos dados por $\vec{x}$:

$$A\vec{x} = [\vec{a}_1 \ \vec{a}_2 \ \cdots \ \vec{a}_n] \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = x_1\vec{a}_1 + x_2\vec{a}_2 + \cdots + x_n\vec{a}_n.$$

5.3 THEOREM. *Sea* A *una matriz de tamaño* $m \times n$ *con columnas* $\vec{a}_1, \ldots, \vec{a}_n \in \mathbb{R}^m$ *y* $\vec{b} \in \mathbb{R}^m$. *La ecuación matricial*

$$A\vec{x} = \vec{b}$$

tiene el mismo conjunto solución que la ecuación vectorial

$$x_1\vec{a}_1 + x_2\vec{a}_2 + \cdots + x_n\vec{a}_n = \vec{b},$$

que a su vez tiene el mismo conjunto solución que el sistema lineal

$$[\vec{a}_1 \ \vec{a}_2 \ \ldots \ \vec{a}_n \ \vec{b}].$$

Es decir, que la ecuación matricial $A\vec{x} = \vec{b}$ tiene solución si y solo si $\vec{b}$ es combinación lineal de las columnas de A. Si cualquier $\vec{b}$ es solución, las columnas generarán el subespacio entero.

5.4 THEOREM. *Sea* A *una matriz de tamaño* $m \times n$ *. Las siguientes afirmaciones son equivalentes:*

- *Para todo* $\vec{b} \in \mathbb{R}^m$*, la ecuación* $A\vec{x} = \vec{b}$ *tiene solución.*
- *Cualquier* $\vec{b} \in \mathbb{R}^m$ *es combinación lineal de las columnas de* A.
- *Las columnas de* A *generan* $\mathbb{R}^m$.
- A *tiene una posición pivote en cada fila.*

(cuidado, esto último habla de la matriz de coeficientes, no de la aumentada).

Notación: La matriz identidad $\mathbb{I}_n$ es la matriz de tamaño $n \times n$ con 1's en la diagonal y ceros en el resto de entradas.

Propiedades:

(i) $A(\vec{u} + \vec{v}) = A\vec{u} + A\vec{v}$ (distributiva)

(ii) $A(c\vec{u}) = c(A\vec{u})$ (compatibilidad escalar)

5.7 *Conjuntos solución*

Los **conjuntos solución** son objetos importantes en álgebra lineal, y aparecen en distintos contextos. Podemos caracterizar los conjuntos solución de los sistemas lineales, dividiéndolos en dos tipos.

5.7.1 Sistemas homogéneos

Un sistema de ecuaciones lineales es **homogéneo** si se puede escribir como

$$A\vec{x} = \vec{0}, \quad A \in \mathbb{R}^{m\times n},\ \vec{x} \in \mathbb{R}^n$$

El vector $\vec{x} = \vec{0}$ es siempre solución, y se denomina **solución trivial**. Lo interesante es ver qué otras soluciones existen.

El Teorema de existencia y unicidad visto anteriormente implica que $A\vec{x} = \vec{0}$ tiene solución no trivial sí y solo sí hay una variable libre[2]. Esto encaja con lo que ya sabíamos: un sistema lineal consistente puede tener o bien una única solución, o infinitas, así que si íbamos a tener alguna aparte de la trivial, necesariamente tendremos infinitas (parametrizadas con la variable libre).

EJEMPLO. Consideremos el siguiente sistema.

$$\begin{cases} 3x_1 + 5x_2 - 4x_3 = 0 \\ -3x_1 - 2x_2 + 4x_3 = 0 \\ 6x_1 + x_2 - 8x_3 = 0 \end{cases}$$

Aplicamos Gauss-Jordan:

$$\begin{bmatrix} 3 & 5 & -4 & 0 \\ -3 & -2 & 4 & 0 \\ 6 & 1 & -8 & 0 \end{bmatrix} \sim \begin{bmatrix} 3 & 5 & -4 & 0 \\ 0 & 3 & 0 & 0 \\ 0 & -9 & 0 & 0 \end{bmatrix} \sim \begin{bmatrix} 3 & 0 & -4 & 0 \\ 0 & 3 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

[2] Aunque todavía no hemos definido lo que es una dimensión (ya llegará), podemos hacer uso de la noción intuitiva de ese concepto. En esos términos lo que tenemos es

$$\dim(\text{conjunto solución}) = \dim(\text{espacio}) - \#\text{restricciones distintas}$$

Si no hay variables libres, entonces la resta da cero y el conjunto solución es de dimensión cero (un único punto: el trivial).

Entonces:

$$\begin{cases} 3x_1 - 4x_3 = 0 \\ x_2 = 0 \\ x_3 \text{ libre} \end{cases}$$

Geométricamente, el conjunto solución es una línea que pasa por $\vec{0}$ en el plano (x_1, x_3):

$$\text{Span}\left\{\begin{bmatrix} 4 \\ 0 \\ 3 \end{bmatrix}\right\}$$

(por conteo: 3 dimensiones − 2 restricciones = 1 dimensión)

El siguiente ejemplo es aun más trivial pero ilustra perfectamente la situación con dos variables libres.

Ejemplo. Consideremos la siguiente ecuación.

$$10x_1 - 3x_2 - 2x_3 = 0$$

$$\vec{x} = \begin{bmatrix} 0.3x_2 + 0.2x_3 \\ x_2 \\ x_3 \end{bmatrix} = x_2 \begin{bmatrix} 0.3 \\ 1 \\ 0 \end{bmatrix} + x_3 \begin{bmatrix} 0.2 \\ 0 \\ 1 \end{bmatrix}$$

Cualquier combinación lineal de $\vec{v}_1, \vec{v}_2$ es solución. Geométricamente: un plano en $\mathbb{R}^3$ que pasa por $\vec{0}$.

5.7.2 Sistemas inhomogéneos

Un sistema es inhomogéneos si no es homogéneo, es decir, si es $A\vec{x} = \vec{b}$ con $\vec{b} \neq 0$.

En sistemas lineales inhomogéneos, la solución la podemos caracterizar como un vector cualquiera que satisfaga la ecuación, más una combinación lineal arbitraria de vectores que satisfagan la ecuación homogénea.

Ejemplo. Consideramos la ecuación matricial con

$$A = \begin{bmatrix} 3 & 5 & -4 \\ -3 & -2 & 4 \\ 6 & 1 & 8 \end{bmatrix}, \quad \vec{b} = \begin{bmatrix} 7 \\ -1 \\ -4 \end{bmatrix}$$

$$\left[\begin{array}{ccc|c} 3 & 5 & -4 & 7 \\ -3 & -2 & 4 & -1 \\ 6 & 1 & 8 & -4 \end{array}\right] \sim \left[\begin{array}{ccc|c} 1 & 0 & -4/3 & 1 \\ 0 & 1 & 0 & 2 \\ 0 & 0 & 0 & 0 \end{array}\right]$$

Por tanto:

$$\vec{x} = \begin{bmatrix} -1 + \frac{4}{3}x_3 \\ 2 \\ x_3 \end{bmatrix} = \underbrace{\begin{bmatrix} -1 \\ 2 \\ 0 \end{bmatrix}}_{\vec{p}} + x_3 \underbrace{\begin{bmatrix} \frac{4}{3} \\ 0 \\ 1 \end{bmatrix}}_{\vec{v}}$$

Si la ecuación homogénea asociada solo tiene la solución trivial, entonces la inhomogénea tiene solución única. Si tiene

5.5 THEOREM. *El conjunto solución de* $A\vec{x} = \vec{b}$ *es el conjunto de todos los vectores* $\vec{w} = \vec{p} + \vec{v}_h$ *con* $\vec{p}$ *una solución particular de* $A\vec{x} = \vec{b}$ *y* $\vec{v}_h$ *cualquier vector de la ecuación homogénea.*

Podemos visualizarlo gráficamente con el siguiente ejemplo

EJEMPLO. Indepeniendemente de la elección de solución particular $\vec{p}_1$ o $\vec{p}_2$,

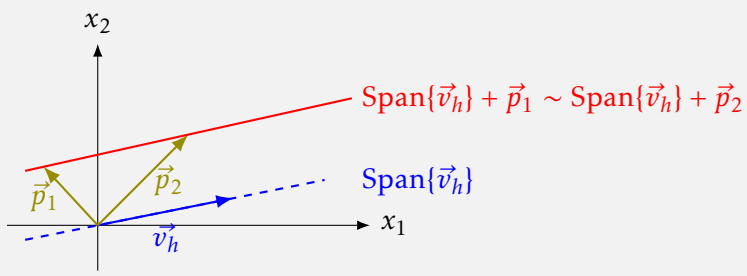

Por tanto, en el caso de los sistemas consistentes (en los que al menos hay una solución particular $\vec{p}$) tenemos que si el sistema homogéneo asociado tiene solo la solución trivial el inhomogéneo tendrá solución única ($\vec{p} + \vec{v}_h = \vec{p} + \vec{0} = \vec{p}$). Si por el contrario el homogéneo tiene alguna solución no trivial (en cuyo caso, son infinitas), eso da lugar a las infinitas soluciones del inhomogéneo.

5.8 *Independencia lineal*

Un conjunto de vectores $\{\vec{v}_1, \ldots, \vec{v}_m\}$ es **linealmente independiente** si:

$$x_1\vec{v}_1 + x_2\vec{v}_2 + \cdots + x_m\vec{v}_m = \vec{0}$$

únicamente tiene la solución trivial. De lo contrario, es **linealmente dependiente**.

EJEMPLO. Los vectores $\vec{e}_1$, $\vec{e}_2$, $\vec{e}_3$ dados por

$$\vec{e}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \vec{e}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \quad \vec{e}_3 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

son linealmente dependientes (porque podemos escribir $\vec{e}_3 = \vec{e}_1 + \vec{e}_2$, es decir, hay una relación de dependencia entre ellos).

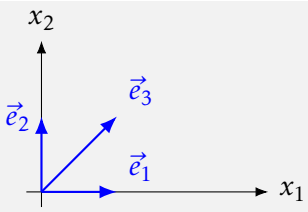

Sin embargo, el conjunto $\{\vec{e}_1, \vec{e}_2\}$ es en si mismo linealmente independiente (no hay ninguna forma de "anular uno con el otro", es decir, no hay una relación de dependencia lineal entre ellos).

Análogamente, las columnas de A son linealmente independientes sí y solo sí la ecuación $A\vec{x} = \vec{0}$ tiene únicamente la solución trivial.

5.9 *Teoremas importantes*

El primero es evidente dada la definición.

5.6 THEOREM. *Un conjunto* $S = \{\vec{v}_1, \ldots, \vec{v}_m\}$, $m \geq 2$, *es linealmente dependiente si y solo si al menos uno de los vectores en* S *es combinación lineal de los otros.*

El siguiente también es evidente desde un punto de vista geométrico: si tenemos más vectores que la dimensión de nuestro espacio, siempre podremos describir al menos uno de ellos como combinación lineal del resto.

5.7 THEOREM. *Cualquier conjunto de* $m > n$ *vectores en* $\mathbb{R}^n$ *es linealmente dependiente.*

Finalmente, el último teorema que presentamos también es evidente.

5.8 THEOREM. *Si un conjunto* $S = \{\vec{v}_1, \ldots, \vec{v}_m\}$ *contiene al vector* $\vec{0}$, *entonces es linealmente dependiente.*

6 TRANSFORMACIONES LINEALES

6.1 *Introducción*

Hasta el momento hemos discutido el producto de matriz por vector como eso, una operación más, sin otra interpretación. Sin embargo, esto va mucho más allá de una mera operación: podemos entender $A\vec{x}$ como un **operador** A que *actúa* sobre $\vec{x}$ el vector $\vec{x}$, y lo transforma en un nuevo vector $\vec{y} = A\vec{x}$.

EJEMPLO. En este caso la matriz A transforma vectores de $\mathbb{R}^4$ en vectores de $\mathbb{R}^2$.

$$A = \begin{bmatrix} 4 & -3 & 1 & 3 \\ 2 & 0 & 5 & 1 \end{bmatrix}, \quad \vec{u} = \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix}, \quad \vec{v} = \begin{bmatrix} 1 \\ 4 \\ -1 \\ 3 \end{bmatrix}$$

$$A\vec{u} = \begin{bmatrix} 5 \\ 8 \end{bmatrix}, \quad A\vec{v} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

Visualmente, una matriz $m \times n$ está realizando una operación así:

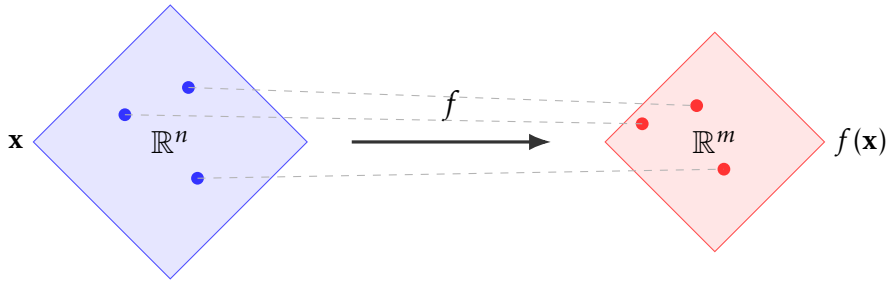

La correspondencia $\vec{x} \mapsto A\vec{x}$ se denomina **transformación** de un conjunto de vectores a otro.

6.1.1 Definiciones

Una **transformación/función/mapa** $T : \mathbb{R}^n \to \mathbb{R}^m$ asigna a cada $\vec{x} \in \mathbb{R}^n$ un vector $T(\vec{x}) \in \mathbb{R}^m$.

- El conjunto de partida: **dominio**, dom(T).
- El espacio de llegada: **codominio**, codom(T).
- La imagen: im(T).
- El rango: rang(T).

Ejemplo

$$A = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

Esto es una transformación $T : \mathbb{R}^3 \to \mathbb{R}^3$ cuyo rango es $\mathbb{R}^2$, ya que A es un proyector sobre el plano $x_1 x_2$:

$$T \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} x_1 \\ x_2 \\ 0 \end{bmatrix}$$

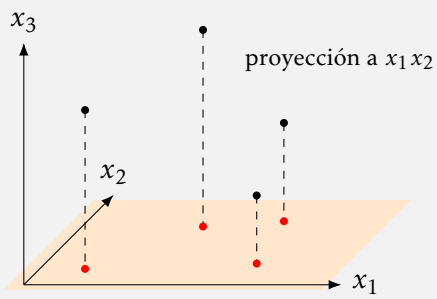

En general, para $A \in \mathbb{R}^{m \times n}$:

$$\text{Rango}(T) = \text{Span}\{\vec{a}_1, \ldots, \vec{a}_n\}, \quad A = [\vec{a}_1 \ \vec{a}_2 \ \ldots \ \vec{a}_n]$$

$$A\vec{x} = x_1\vec{a}_1 + x_2\vec{a}_2 + \cdots + x_n\vec{a}_n$$

Ejercicio Sea

$$A = \begin{bmatrix} 1 & -3 \\ 3 & 5 \\ -1 & 7 \end{bmatrix}, \quad \vec{u} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}, \quad \vec{b} = \begin{bmatrix} 3 \\ 2 \\ -5 \end{bmatrix}, \quad \vec{c} = \begin{bmatrix} 3 \\ 2 \\ 5 \end{bmatrix}.$$

Definimos

$$T : \mathbb{R}^2 \to \mathbb{R}^3, \quad \text{dado por} \quad \vec{x} \mapsto A\vec{x}.$$

—

a) Imagen de $\vec{u}$ bajo T:

$$T(\vec{u}) = A\vec{u} = \begin{bmatrix} 5 \\ 1 \\ -9 \end{bmatrix}.$$

b) Preimagen de $\vec{b}$ bajo T:

$$A\vec{x} = \vec{b}.$$

$$\begin{bmatrix} 1 & -3 & 3 \\ 3 & 5 & 2 \\ -1 & 7 & -5 \end{bmatrix} \sim \begin{bmatrix} 1 & -3 & 3 \\ 0 & 14 & -7 \\ 0 & 4 & -2 \end{bmatrix} \sim \begin{bmatrix} 1 & -3 & 3 \\ 0 & 1 & -1/2 \\ 0 & 0 & 0 \end{bmatrix}.$$

Por tanto,

$$\vec{x} = \frac{1}{2}\begin{bmatrix} 3 \\ -1 \end{bmatrix}.$$

c) ¿Existe más de una preimagen? No.

d) ¿Está $\vec{c}$ en el rango de T?

Necesitamos comprobar si

$$A\vec{x} = \vec{c}.$$

$$\begin{bmatrix} 1 & -3 & 3 \\ 3 & 5 & 2 \\ -1 & 7 & -5 \end{bmatrix} \sim \begin{bmatrix} 1 & -3 & 3 \\ 0 & 14 & -7 \\ 0 & 4 & 8 \end{bmatrix} \sim \begin{bmatrix} 1 & -3 & 3 \\ 0 & 2 & -1 \\ 0 & 0 & 5 \end{bmatrix}.$$

El sistema es inconsistente, por lo tanto **no hay solución**.

6.1.2 Propiedades de las transformaciones lineales

Una transformación es **lineal** si:

1. $T(\vec{u} + \vec{v}) = T(\vec{u}) + T(\vec{v}), \quad \forall \vec{u}, \vec{v} \in \mathrm{dom}(T)$.
2. $T(c\vec{u}) = cT(\vec{u}), \quad \forall c \in \mathbb{R}, \vec{u} \in \mathrm{dom}(T)$.

De esas propiedades se deduce:

1. $T(\vec{0}) = \vec{0}$.
2. $T(c_1\vec{v}_1 + \cdots + c_m\vec{v}_m) = c_1T(\vec{v}_1) + \cdots + c_mT(\vec{v}_m), \quad \forall c_i \in \mathbb{R}$.

Esto se conoce como el **principio de superposición**: el resultado de aplicar una transformación a una combinación lineal es la combinación lineal de las transformaciones.

EJERCICIOS

1. Dado un escalar r, definimos $\mathrm{T} : \mathbb{R}^2 \to \mathbb{R}^2$,
$$\mathrm{T}(\vec{x}) = r\vec{x}.$$
Para $r > 1$ es una dilatación, para $0 < r < 1$ es una contracción. Se prueba que es lineal verificando las propiedades (i) y (ii).

2. Sea $p(x) = a_0 + a_1 x + a_2 x^2$. Mostrar que la derivada es un operador lineal:
$$\frac{d}{dx}(cp(x) + dq(x)) = cp'(x) + dq'(x).$$

6.1.3 Transformaciones afines y matrices

Una transformación afín se define como:

$$\mathrm{T} : \mathbb{R}^n \to \mathbb{R}^m, \quad \mathrm{T}(\vec{x}) = \mathrm{A}\vec{x} + \vec{b}.$$

No es lineal si $\vec{b} \neq 0$.

6.1 THEOREM. *Sea $\mathrm{T} : \mathbb{R}^n \to \mathbb{R}^m$ lineal. Entonces existe una matriz única A tal que*
$$\mathrm{T}(\vec{x}) = \mathrm{A}\vec{x}.$$
La matriz de T es de $m \times n$ y sus columnas son $\mathrm{T}(\vec{e}_j)$, donde $\vec{e}_j$ es la base canónica.

EJEMPLO. Supongamos $\mathrm{T} : \mathbb{R}^2 \to \mathbb{R}^3$ con:
$$\mathrm{T}\left(\begin{bmatrix}1\\0\end{bmatrix}\right) = \begin{bmatrix}5\\-7\\2\end{bmatrix}, \quad \mathrm{T}\left(\begin{bmatrix}0\\1\end{bmatrix}\right) = \begin{bmatrix}-3\\8\\0\end{bmatrix}.$$

Entonces, para $\vec{x} = \begin{bmatrix}x_1\\x_2\end{bmatrix}$:
$$\mathrm{T}(\vec{x}) = x_1\mathrm{T}(\vec{e}_1) + x_2\mathrm{T}(\vec{e}_2) = \begin{bmatrix}5x_1 - 3x_2\\-7x_1 + 8x_2\\2x_1\end{bmatrix}.$$

La matriz canónica de T es:
$$\mathrm{A} = \begin{bmatrix}5 & -3\\-7 & 8\\2 & 0\end{bmatrix}.$$

EJEMPLO (ROTACIONES). claramente si rotamos dos veces un vector es lo mismo que rotarlo una vez pero ambos ángulos, y rotar $x \in \mathbb{R}$ veces un ángulo es equivalente a rotar una única vez el

ángulo multiplicado por x. En definitiva, las rotaciones son transformaciones lineales.

Sea $T_\varphi : \mathbb{R}^2 \to \mathbb{R}^2$ la rotación de un ángulo φ respecto al origen:

$$A_\varphi = \begin{bmatrix} \cos\varphi & -\sin\varphi \\ \sin\varphi & \cos\varphi \end{bmatrix}.$$

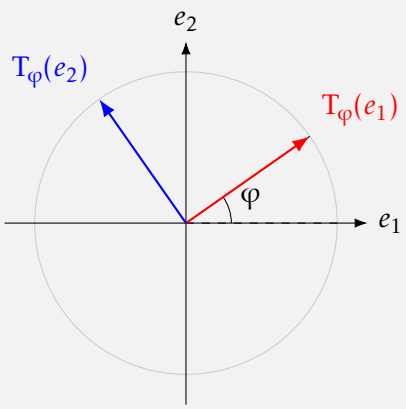

6.2 *Transformaciones geométricas en* $\mathbb{R}^2$

Además de las rotaciones que acabamos de ver, tenemos:

- Reflexiones

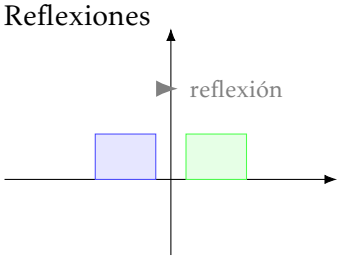

- Trasquilados

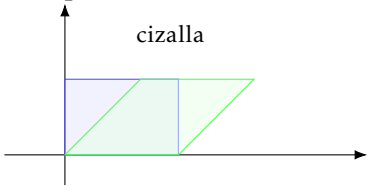

- Contracciones y dilataciones

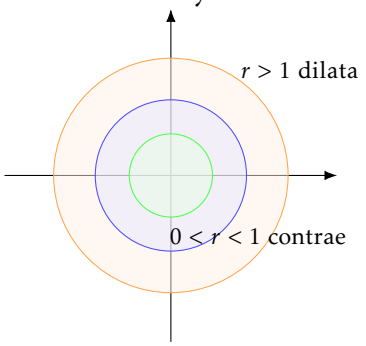

- Proyecciones

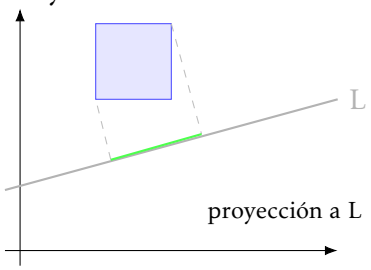

6.2.1 Existencia y unicidad

- T es **sobreyectiva** si $\forall \vec{b} \in \mathbb{R}^m$ existe $\vec{x} \in \mathbb{R}^n$ tal que $T(\vec{x}) = \vec{b}$.
- T es **inyectiva** si $\forall \vec{b} \in \mathbb{R}^m$ hay a lo sumo un $\vec{x} \in \mathbb{R}^n$ tal que $T(\vec{x}) = \vec{b}$.
- T es **biyectiva** si es inyectiva y sobreyectiva.

Visualmente:

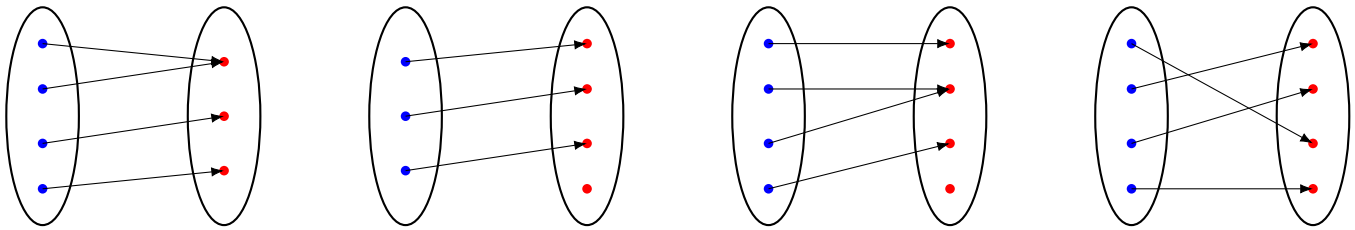

No inyectiva, sí sobreyectiva. | Sí inyectiva, no sobreyectiva. | Ni inyectiva ni sobreyectiva. | Inyectiva y sobreyectiva.

NOTA SOBRE TERMINOLOGÍA. En muchos contextos se habla de las transformaciones (no solo lineales y no solo entre espacios de vectores reales) como "morfismos". Hay distintos nombres más específicos que conviene saber, dependiendo de qué propiedades cumplen:

- Si la transformación es biyectiva, se dice que es un isomorfismo entre espacios (y los espacios que están relacionados entre sí por dicha transformación se dice que son isomorfos).
- Si la transformación es de un espacio sobre sí mismo, se dice que es un endomorfismo.
- Si es a la vez un isomorfismo y un endomorfismo, se dice que es un automorfismo.

6.3 *Teoremas sobre transformaciones lineales*

6.2 THEOREM. *Sea* $T : \mathbb{R}^n \to \mathbb{R}^m$ *una transformación lineal. Entonces* T *es inyectiva si y sólo si* $T(\vec{x}) = \vec{0}$ *tiene únicamente la solución trivial.*

Esto es intuitivo: si dos vectores distintos se transforman en el mismo, su resta es una solución no trivial de $T(\vec{x}) = \vec{0}$.

6.3 THEOREM. *Sean* $T : \mathbb{R}^n \to \mathbb{R}^m$ *una transformación lineal y* A *su matriz canónica. Entonces:*

1. T *es sobreyectiva si las columnas de* A *generan* $\mathbb{R}^m$.
2. T *es inyectiva si y sólo si las columnas de* A *son linealmente independientes.*

EJEMPLO. Sea

$$T(x_1, x_2) = (3x_1 + x_2,\ 5x_1 + 7x_2,\ x_1 + 3x_2).$$

Queremos demostrar que T es lineal e inyectiva. ¿Es sobreyectiva?

$$T(\vec{x}) = \begin{bmatrix} 3 & 1 \\ 5 & 7 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = A\vec{x}.$$

Es lineal por construcción. Las columnas de A no son múltiplos, luego son linealmente independientes $\Rightarrow$ T es inyectiva.

Pero esas columnas no generan todo $\mathbb{R}^3$, su subespacio es menor, por lo que T no es sobreyectiva.

7 EXTRA

7.1 *Polinomio interpolador*

Una situación práctica donde aparecen los sistemas lineales es en la **interpolación**.

Por ejemplo, si medimos el campo eléctrico $|\mathrm{E}|$ a distintas distancias x_i de la carga, obtenemos un conjunto de puntos.

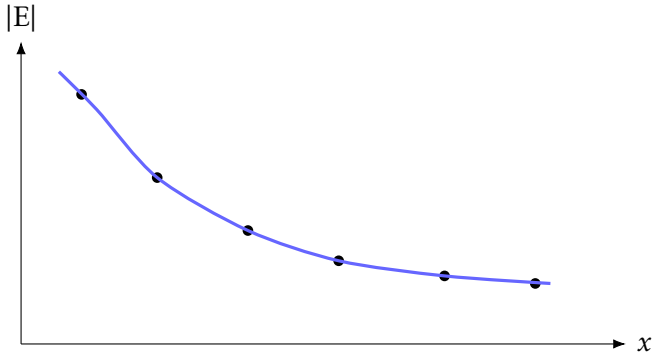

Para predecir valores intermedios, necesitamos un "modelo" que ajuste los datos. Por lo general es común utilizar polinomios para ello, ya que es fácil de operar con ellos, y es fácil construir una base (en futuros temas veremos qué significa esto) dada una dimensión fija. Dados n datos $\{(\mathrm{E}_i, x_i)\}_{i=1}^n$, existe un único polinomio de orden $n-1$ que pasa por ellos.

En un problema de interpolación polinómica queremos ajustar, por tanto,

$$p(x) = a_0 + a_1 x + a_2 x^2 + \cdots + a_{n-1} x^{n-1}.$$

Imponemos que el polinomio ha de pasar por cada uno de los datos:

$$\begin{cases} \mathrm{E}_1 = a_0 + a_1 x_1 + a_2 x_1^2 + \cdots + a_{n-1} x_1^{n-1}, \\ \mathrm{E}_2 = a_0 + a_1 x_2 + a_2 x_2^2 + \cdots + a_{n-1} x_2^{n-1}, \\ \quad \vdots \\ \mathrm{E}_n = a_0 + a_1 x_n + a_2 x_n^2 + \cdots + a_{n-1} x_n^{n-1}. \end{cases}$$

Esto nos da un sistema lineal:

$$\underbrace{\begin{bmatrix} 1 & x_1 & x_1^2 & \cdots & x_1^{n-1} \\ 1 & x_2 & x_2^2 & \cdots & x_2^{n-1} \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & x_n & x_n^2 & \cdots & x_n^{n-1} \end{bmatrix}}_{\mathrm{M}} \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_{n-1} \end{bmatrix} = \begin{bmatrix} \mathrm{E}_1 \\ \mathrm{E}_2 \\ \vdots \\ \mathrm{E}_n \end{bmatrix}.$$

La matriz M se denomina "matriz de Vandermonde", y la solución de este sistema proporciona los coeficientes $a_0, a_1, \ldots a_n$ del **polinomio interpolador**.

Ejemplo. Suponemos los datos $\{(1,6),(2,6),(3,7)\}$. Podemos usar una parábola (es decir, un polinomio de orden 2) para ajustarlos.

Planteamos el siguiente sistema lineal para sus coeficientes a_0, a_1, a_2.

$$\begin{pmatrix} 1 & 1 & 1^2 \\ 1 & 2 & 2^2 \\ 1 & 3 & 3^2 \end{pmatrix} \cdot \begin{pmatrix} a_0 \\ a_1 \\ a_2 \end{pmatrix} = \begin{pmatrix} 6 \\ 6 \\ 7 \end{pmatrix}$$

Resolvemos este sistema de ecuaciones para hallar el polinomio interpolador:

$$y = a_2x^2 + a_1x + a_0 = \frac{x^2}{2} - \frac{3x}{2} + 7$$

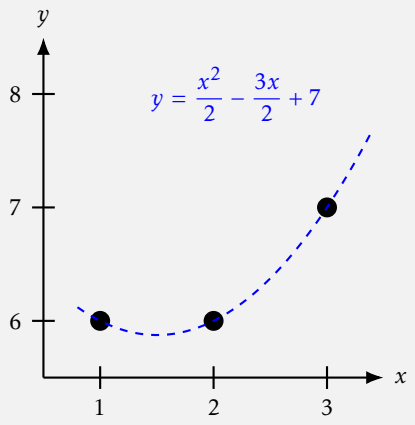

Nota

- Si usamos un polinomio de orden $m < n - 1$, probablemente no haya solución (por ejemplo, no podemos ajustar tres puntos con una recta salvo que estén en línea).
- Si $m > n - 1$, probablemente haya infinitas soluciones (por ejemplo, hay infinitas parábolas que ajustan dos puntos).

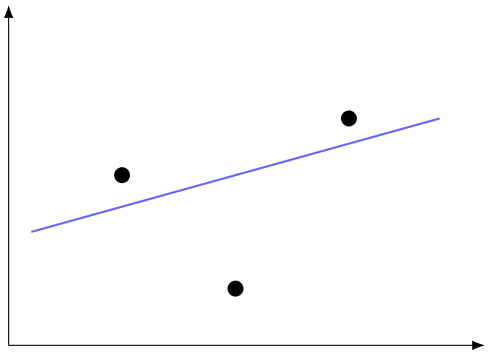

$m = 1 < 2 = n - 1$ (sin solución)

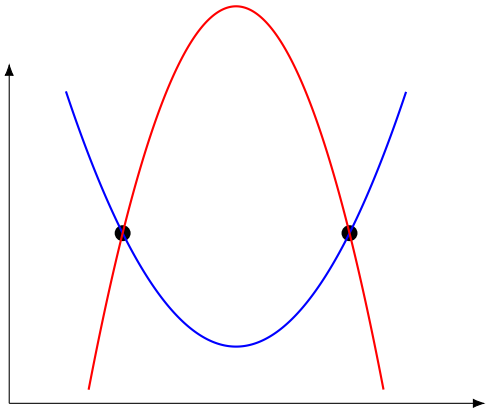

$m = 2 > 1 = n - 1$ (infinitas soluciones)

7.2 *Problemas de flujo en redes*

Un contexto muy común donde aparecen los sistemas lineales son los **problemas de flujo en redes**.

La idea general es sencilla: tenemos una red de nodos y conexiones (carreteras, tuberías, cables eléctricos, etc.), y queremos conocer cuánto fluye por cada ramal. En estos problemas siempre aparece una regla de *conservación*:

- **Conservación en los nodos:** lo que entra a un nodo debe ser igual a lo que sale.

Esto se traduce en un conjunto de **ecuaciones lineales** en las incógnitas que representan los flujos. Resolver el sistema con eliminación de Gauss–Jordan nos permite determinar los valores de todas las corrientes, caudales o flujos de manera cuantitativa.

Por ejemplo, si en el nodo A entran 100 unidades de flujo, la condición de conservación nos da

$$x_1 + x_2 = 100.$$

En el nodo B, todo lo que llega (x_1) debe salir por x_3, de modo que

$$x_1 = x_3.$$

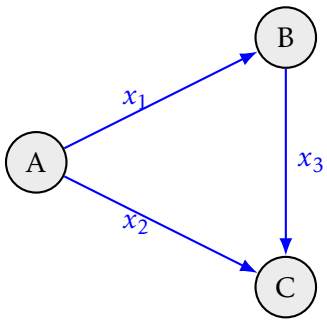

Figure 1: Ejemplo de red genérica de flujo.

En el nodo C entra $x_2 + x_3$ y debe salir lo mismo. Estas ecuaciones conforman un sistema lineal que podemos resolver por el método de Gauss–Jordan.

7.2.1 Sistemas lineales en circuitos eléctricos

Vamos a mostrar como ejemplo de los problemas de flujo el caso de la corriente a través de un circuito. Cuando queremos calcular las *corrientes* en un circuito, aplicamos dos reglas fundamentales:

- **Ley de Ohm:** $V = IR$, que relaciona voltaje, corriente y resistencia.
- **Leyes de Kirchhoff:**
  - **KCL (ley de corrientes):** la suma de corrientes que entran a un nodo es igual a la suma de las que salen.
  - **KVL (ley de voltajes):** en una malla cerrada, la suma de caídas de voltaje es igual a la suma de las fuentes.

Cada una de estas reglas nos da una **ecuación lineal** en las incógnitas del problema. De este modo, un circuito eléctrico no es más que una fuente de sistemas de ecuaciones que podemos resolver tal y como hemos visto en este tema.

Consideramos el caso particular de la Figura 2, un circuito con una batería y dos resistencias en paralelo. En este caso, queremos determinar las corrientes I_1 e I_2 en cada rama. De acuerdo con la ley de Ohm y la ley de voltajes:

$$R_1 I_1 = V, \qquad R_2 I_2 = V.$$

Además, la corriente total suministrada por la batería es

$$I_{\text{total}} = I_1 + I_2.$$

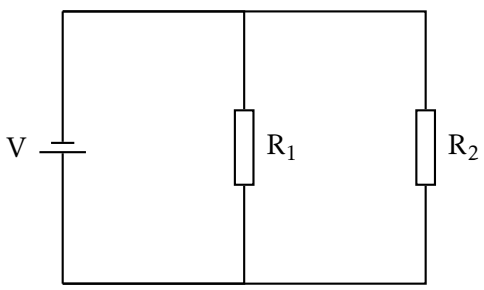

Figure 2: Batería con dos resistencias en paralelo.

Podemos escribir este problema como un sistema lineal en las incógnitas I_1, I_2, I_{total}:

$$\begin{bmatrix} R_1 & 0 & 0 \\ 0 & R_2 & 0 \\ -1 & -1 & 1 \end{bmatrix} \begin{bmatrix} I_1 \\ I_2 \\ I_{total} \end{bmatrix} = \begin{bmatrix} V \\ V \\ 0 \end{bmatrix}.$$

Resolviendo este sistema por eliminación de Gauss–Jordan, obtenemos directamente las corrientes en cada rama y la corriente total.

Ejemplo. Sea $V = 12\,\mathrm{V}$, $R_1 = 6\,\Omega$, $R_2 = 12\,\Omega$. Planteamos:

$$\begin{cases} 6I_1 = 12, \\ 12I_2 = 12, \\ I_{total} = I_1 + I_2. \end{cases}$$

De aquí se obtiene:

$$I_1 = 2\,\mathrm{A}, \quad I_2 = 1\,\mathrm{A}, \quad I_{total} = 3\,\mathrm{A}.$$

Este mismo método es aplicable no sólo a circuitos eléctricos, sino también a redes de tráfico (autos entrando y saliendo de intersecciones), redes de tuberías (flujos de agua), o cadenas de suministro.

Part III

Álgebra matricial y determinantes

8 ÁLGEBRA MATRICIAL

Una matriz de tamaño $m \times n$ es un elemento del espacio $\mathcal{M}_{m\times n}$ (el conjunto de matrices de tamaño $m \times n$), y se denota

$$\mathrm{A} = (a_{ij}) = \begin{pmatrix} a_{11} & \cdots & a_{1j} & \cdots & a_{1n} \\ \vdots & & \vdots & & \vdots \\ a_{i1} & \cdots & a_{ij} & \cdots & a_{in} \\ \vdots & & \vdots & & \vdots \\ a_{m1} & \cdots & a_{mj} & \cdots & a_{mn} \end{pmatrix} \in \mathcal{M}_{m\times n}.$$

Las **entradas diagonales** son $a_{11}, a_{22}, a_{33}, \ldots$ y forman la **diagonal principal** (en adelante nos referiremos a esta como la "diagonal").

- Una **matriz diagonal** es una matriz cuadrada $n \times n$ cuyos elementos fuera de la diagonal principal son cero.
- La **matriz identidad** de tamaño n, $\mathbb{I}_n$, es diagonal y todas las entradas de la diagonal son 1.
- La **matriz cero** 0 tiene todas sus entradas nulas.
- Una **matriz simétrica** cumple $a_{ij} = a_{ji}$, mientras que es **antisimétrica** si $a_{ij} = -a_{ji}$ para todo i, j.

8.1 *Operaciones básicas*

La suma de matrices del mismo tamaño se define como la suma componente a componente. La multiplicación por un escalar también se define componente a componente.

Ejemplo. Consideramos las matrices y el escalar

$$\mathrm{A} = \begin{bmatrix} 4 & 0 & 5 \\ -1 & 3 & 2 \end{bmatrix}, \quad \mathrm{B} = \begin{bmatrix} 1 & 1 & 1 \\ 3 & 5 & 7 \end{bmatrix}, \quad r = 2.$$

Entonces

$$\mathrm{A} + \mathrm{B} = \begin{bmatrix} 5 & 1 & 6 \\ 2 & 8 & 9 \end{bmatrix}, \quad r\mathrm{A} = \begin{bmatrix} 8 & 0 & 10 \\ -2 & 6 & 4 \end{bmatrix}.$$

Propiedades. Sean $\mathrm{A}, \mathrm{B} \in \mathcal{M}_{m\times n}$, $r, s \in \mathbb{R}$:

(i) $\mathrm{A} + \mathrm{B} = \mathrm{B} + \mathrm{A}$ (conmutatividad)

(ii) $(\mathrm{A} + \mathrm{B}) + \mathrm{C} = \mathrm{A} + (\mathrm{B} + \mathrm{C})$ (asociatividad)

(iii) $\mathrm{A} + 0 = 0 + \mathrm{A} = \mathrm{A}$ (elemento neutro)

(iv) $r(\mathrm{A} + \mathrm{B}) = r\mathrm{A} + r\mathrm{B}$

(v) $(r + s)\mathrm{A} = r\mathrm{A} + s\mathrm{A}$

(vi) $r(s\mathrm{A}) = (rs)\mathrm{A}$

8.2 *Multiplicación de matrices*

Ya sabemos multiplicar una matriz por un vector:

$$A\vec{x} = x_1\vec{a}_1 + \cdots + x_n\vec{a}_n.$$

Se podría definir la multiplicación de matrices de distintas formas, pero, vistas como transformaciones lineales, es conveniente usar la siguiente propiedad:

$$A(B\vec{x}) = (AB)\vec{x}, \quad \vec{x} \in \mathbb{R}^n,\ B \in \mathcal{M}_{p\times n},\ A \in \mathcal{M}_{m\times p}.$$

Visualmente:

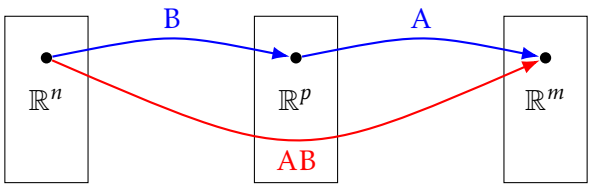

La única multiplicación posible que satisface esa propiedad es

$$A(B\vec{x}) = [A\vec{b}_1\ A\vec{b}_2\ \ldots\ A\vec{b}_n]\vec{x}, \quad \text{si } B = [\vec{b}_1\ \vec{b}_2\ \ldots\ \vec{b}_n].$$

Por tanto, se define el **producto de matrices** como

$$AB = [A\vec{b}_1\ A\vec{b}_2\ \ldots\ A\vec{b}_n].$$

Interpretación: cada columna de AB es la combinación lineal de las columnas de A, con pesos dados por la respectiva columna de B.

Ejemplo. Consideramos las matrices y el vector

$$A = \begin{bmatrix} 2 & 3 \\ 1 & -5 \end{bmatrix}, \quad B = \begin{bmatrix} 4 & 3 & 6 \\ 1 & -2 & 3 \end{bmatrix}, \quad \vec{x} = \begin{bmatrix} 2 \\ 0 \end{bmatrix}.$$

Se obtiene

$$AB = \begin{bmatrix} 11 & 0 & 21 \\ -1 & 13 & -9 \end{bmatrix}.$$

Comprobación:

$$(AB)\vec{x} = \begin{bmatrix} 11 \\ 25 \end{bmatrix}, \quad B\vec{x} = \begin{bmatrix} 10 \\ -3 \end{bmatrix}, \quad A(B\vec{x}) = \begin{bmatrix} 11 \\ 25 \end{bmatrix}.$$

8.2.1 Propiedades de la multiplicación de matrices

Sean $A \in \mathcal{M}_{m\times n}$, B, C matrices con tamaños compatibles, y $r \in \mathbb{R}$:

(i) $A(BC) = (AB)C$ (asociatividad)

(ii) $A(B + C) = AB + AC$ (distributividad izquierda)

(iii) $(B + C)A = BA + CA$ (distributividad derecha)

(iv) $r(AB) = (rA)B = A(rB)$

(v) $I_m A = A = A\mathbb{I}_n$ (elemento neutro)

Mucho cuidado:

- El orden importa: en general $AB \neq BA$ (si acaso está definido).
- Si $AB = BA$, se dice que A y B conmutan.
- En general, $AB = AC$ no implica $B = C$.
- En general, $AB = 0$ no implica $A = 0$ o $B = 0$.

Ejemplo. Consideramos las matrices

$$A = \begin{bmatrix} 2 & -3 \\ -4 & 6 \end{bmatrix}, \quad B = \begin{bmatrix} 8 & 4 \\ 5 & 5 \end{bmatrix}, \quad C = \begin{bmatrix} 5 & -2 \\ 3 & 1 \end{bmatrix}.$$

Entonces

$$AB = \begin{bmatrix} 1 & -7 \\ -2 & 14 \end{bmatrix}, \quad AC = \begin{bmatrix} 1 & -7 \\ -2 & 14 \end{bmatrix}.$$

Aunque ambas son iguales, provienen de matrices $B \neq C$.

Nota: Esta multiplicación es la única que cumple la propiedad $A(B\vec{x}) = (AB)\vec{x}$. Existen otras multiplicaciones de interés, como la **multiplicación de Hadamard** $A \circ B$, que es componente a componente, pero no satisface dicha propiedad.

Ejemplo (producto de Hadamard). Vamos a comprobar que, usando otro producto (que de primeras podría parecer natural), perdemos la propiedad que deseamos del producto. Consideramos las matrices y el vector

$$A = \begin{bmatrix} 1 & 0 \\ 2 & 0 \end{bmatrix}, \quad B = \begin{bmatrix} 1 & 0 \\ 2 & 0 \end{bmatrix}, \quad \vec{x} = \begin{bmatrix} 3 \\ 5 \end{bmatrix}.$$

Usamos el producto de Hadamard (multiplicando componente a componente)

$$A(B\vec{x}) = \begin{bmatrix} 6 \\ 5 \end{bmatrix}, \quad (A \circ B)\vec{x} = \begin{bmatrix} 0 \\ 12 \end{bmatrix}.$$

Claramente ambos vectores son distintos, y por tanto $(A \circ B)\vec{x} \neq A(B\vec{x})$.

Potencias de matrices. Podemos definir potencias de una matriz $A \in \mathcal{M}_{n\times n}$ a partir del producto de forma similar a como se hace con números,

$$A^k = \underbrace{A \cdot A \cdot \ldots \cdot A}_{k \text{ veces}} \in \mathcal{M}_{n\times n}.$$

Notas:

- Una matriz siempre conmuta consigo misma (por eso, como es evidente, el orden de las multiplicaciones en la potencia es irrelevante).
- La potencia cero es la identidad: $A^0 = \mathbb{I}_n$, ya que $A^0\vec{x} = \vec{x} = \mathbb{I}_n\vec{x}$.

8.3 *Transposición*

Dada $A \in \mathcal{M}_{m\times n}$, la **transpuesta** de A es la matriz $A^T \in \mathcal{M}_{n\times m}$, cuyas columnas son las filas de A.

Ejemplo. Consideramos las matriz A siguiente, y calculamos su traspuesta.

$$A = \begin{bmatrix} -5 & 2 \\ 1 & -3 \\ 0 & 4 \end{bmatrix} \quad \Rightarrow \quad A^T = \begin{bmatrix} -5 & 1 & 0 \\ 2 & -3 & 4 \end{bmatrix}.$$

Propiedades:

(i) $(A^T)^T = A$

(ii) $(A + B)^T = A^T + B^T$

(iii) $(rA)^T = rA^T \quad \forall r \in \mathbb{R}$

(iv) $(AB)^T = B^T A^T$

Problema sugerido: Para la rotación $T_\varphi : \mathbb{R}^2 \to \mathbb{R}^2$ definida en el capítulo anterior, ¿qué interpretación tiene la transposición de A_φ?

9 INVERSA DE UNA MATRIZ

Habiendo definido la multiplicación, cabe preguntarse cómo se definiría, si existe, el inverso multiplicativo. Recordemos que, con números, esto se define como el número que cumple, por ejemplo:

$$5 \cdot 5^{-1} = 1, \quad 5^{-1} \cdot 5 = 1$$

La generalización a matrices requiere ambas condiciones (dada la no conmutatividad). Se dice que una matriz $A \in \mathcal{M}_{n\times n}$ es **invertible** si existe $C \in \mathcal{M}_{n\times n}$ (la inversa de A) tal que:

$$AC = \mathbb{I}_n \quad \text{y} \quad CA = \mathbb{I}_n$$

Usualmente se denota el inverso como A^{-1}, y de existir este es único. Una matriz que no es invertible se denomina **matriz singular**.

9.1 THEOREM. *Si $A \in \mathcal{M}_{n\times n}$ es invertible, entonces $\forall b \in \mathbb{R}^n$ la ecuación $A\vec{x} = \vec{b}$ tiene solución única:*

$$\vec{x} = A^{-1}\vec{b}.$$

Propiedades. Sean $A, B \in \mathcal{M}_{n\times n}$ matrices invertibles:

(i) A^{-1} es invertible, y $(A^{-1})^{-1} = A$.

(ii) AB es invertible, y $(AB)^{-1} = B^{-1}A^{-1}$.

(iii) A^T es invertible, y $(A^T)^{-1} = (A^{-1})^T$.

9.1 *Cálculo de la inversa*

Si una matriz es invertible, lo que seguramente nos interesará es calcular dicha inversa. En el caso de matrices 2×2 existe una fórmula explícita sencilla de recordar:

$$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix} \quad \Rightarrow \quad A^{-1} = \frac{1}{ad - bc} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix}$$

donde, si $ad - bc = 0$, la matriz no es invertible.

Ejemplo. Sea

$$A = \begin{bmatrix} 3 & 4 \\ 5 & 6 \end{bmatrix} \quad \Rightarrow \quad A^{-1} = \frac{1}{-2} \begin{bmatrix} 6 & -4 \\ -5 & 3 \end{bmatrix}$$

Comprobación:

$$AA^{-1} = \frac{1}{-2} \begin{bmatrix} -2 & 0 \\ 0 & -2 \end{bmatrix} = \mathbb{I}_2, \quad A^{-1}A = \frac{1}{-2} \begin{bmatrix} -2 & 0 \\ 0 & -2 \end{bmatrix} = \mathbb{I}_2.$$

Para una matriz general, ¿cuál sería el procedimiento para obtener su inversa? Acudimos al algoritmo de Gauss-Jordan de nuevo, a través del siguiente resultado.

9.2 THEOREM. *Si* $A \in \mathcal{M}_{n\times n}$ *es invertible, entonces*

$$[A \mid \mathbb{I}_n] \sim [\mathbb{I}_n \mid A^{-1}],$$

es decir, A *es invertible si es equivalente por filas a* $\mathbb{I}_n$*, y esas mismas operaciones elementales transforman* $\mathbb{I}_n$ *en* A^{-1}.

Ejemplo.

$$A = \begin{bmatrix} 0 & 1 & 2 \\ 1 & 0 & 3 \\ 4 & -3 & 8 \end{bmatrix}$$

$$[A \mid I_3] \sim \cdots \sim [I_3 \mid A^{-1}] = \begin{bmatrix} -9/2 & 7 & -3/2 \\ -2 & 4 & -1 \\ 3/2 & -2 & 1/2 \end{bmatrix}$$

Nota importante: en examen, verificar siempre que $AA^{-1} = A^{-1}A = \mathbb{I}_n$ para comprobar que no nos hemos equivocado en algún paso intermedio.

9.2 *Teorema de la matriz inversa (I)*

Para muchas aplicaciones es importante tener matrices invertibles. Por tanto, caracterizar cuándo una matriz lo es, es de gran importancia. A lo largo de los temas veremos distintas condiciones, por el momento enunciamos 12.

9.3 THEOREM. *de la matriz inversa Sea* $A \in \mathcal{M}_{n\times n}$*. Los siguientes enunciados son equivalentes:*

(a) A *es invertible.*

(b) A *es equivalente por filas a* $\mathbb{I}_n$.

(c) A *tiene n posiciones pivote.*

(d) $A\vec{x} = \vec{0}$ *tiene solo la solución trivial.*

(e) *Las columnas de* A *son linealmente independientes.*

(f) *La transformación* $\vec{x} \mapsto A\vec{x}$ *es inyectiva.*

(g) *La ecuación* $A\vec{x} = \vec{b}$ *tiene al menos una solución* $\forall \vec{b} \in \mathbb{R}^n$.

(h) *Las columnas de* A *generan* $\mathbb{R}^n$.

(i) *La transformación* $\vec{x} \mapsto A\vec{x}$ *mapea* $\mathbb{R}^n$ *sobre* $\mathbb{R}^n$.

(j) $\exists C \in \mathcal{M}_{n\times n}$ *tal que* $CA = \mathbb{I}_n$.

(k) $\exists D \in \mathcal{M}_{n\times n}$ *tal que* $AD = \mathbb{I}_n$.

(l) A^T *es una matriz invertible.*

9.3 *Inversas de transformaciones lineales*

Hasta ahora hemos discutido las inversas desde el punto de vista matricial. Como discutimos en el tema anterior, las transformaciones lineales entre espacios finitos están descritas por matrices, por tanto cabe preguntarse si están relacionados las inversas en ambos casos.

9.4 THEOREM. *Sea* $T : \mathbb{R}^n \to \mathbb{R}^n$ *una transformación lineal, y sea* A *la matriz canónica de* T. *Entonces* T *es invertible si y solo si* A *es invertible. En tal caso, existe* $S : \mathbb{R}^n \to \mathbb{R}^n$ *dado por*

$$S(\vec{x}) = A^{-1}\vec{x}$$

tal que

$$S(T(\vec{x})) = \vec{x}, \quad T(S(\vec{x})) = \vec{x}.$$

Visualmente,

$$\begin{tikzcd} \vec{x} \arrow[r, bend left, "A"] & A\vec{x} \arrow[l, bend left, "A^{-1}"] \end{tikzcd}$$

10 MATRICES DEFINIDAS POR BLOQUES

En muchos casos de interés aparecen matrices definidas por bloques, por ejemplo:

$$M = \begin{bmatrix} A & B \\ C & D \end{bmatrix} \in \mathcal{M}_{m\times n}$$

donde

$$A \in \mathcal{M}_{m_1\times n_1}, \quad B \in \mathcal{M}_{m_1\times n_2}, \quad C \in \mathcal{M}_{m_2\times n_1}, \quad D \in \mathcal{M}_{m_2\times n_2}$$

con $m = m_1 + m_2$, $n = n_1 + n_2$.

De especial interés es el caso cuadrado, con $m = n$, $m_1 = n_1$, $m_2 = n_2$. Para estas matrices, tenemos propiedades análogas de suma y multiplicación.

Ejemplo.

$$M_1 = \begin{bmatrix} A_1 & B_1 \\ 0 & C_1 \end{bmatrix}, \quad M_2 = \begin{bmatrix} A_2 & 0 \\ 0 & C_2 \end{bmatrix}$$

con

$$A_1 = \begin{bmatrix} 2 & 1 \\ 3 & 0 \end{bmatrix}, \quad A_2 = \begin{bmatrix} 0 & 2 \\ 1 & 1 \end{bmatrix}, \quad B_1 = \begin{bmatrix} 3 \\ 2 \end{bmatrix}, \quad C_1 = 2, \quad C_2 = -1$$

Entonces:

$$M_1 + M_2 = \begin{bmatrix} A_1 + A_2 & B_1 \\ 0 & C_1 + C_2 \end{bmatrix} = \begin{bmatrix} 2 & 3 & 3 \\ 4 & 1 & 2 \\ 0 & 0 & 1 \end{bmatrix}$$

$$M_1 M_2 = \begin{bmatrix} A_1 A_2 & B_1 C_2 \\ 0 & C_1 C_2 \end{bmatrix} = \begin{bmatrix} 1 & 5 & -3 \\ 0 & 0 & -2 \\ 0 & 0 & -2 \end{bmatrix}$$

Las matrices definidas por bloques son especialmente interesantes cuando hay bloques nulos. Muchas propiedades se simplifican en estos casos.

11 DETERMINANTES

Los determinantes son objetos bastante particulares, y su inclusión en el álgebra lineal, aunque es bastante útil (especialmente cuando veamos autovalores) e informativa, es generalmente poco intuitiva. Además, su cálculo es operacionalmente más complicado de lo que suele requerir el álgebra lineal[3]. Es por esto que algunos libros de texto famosos (por ejemplo, el de *Linear Algebra Done Right* de Sheldon Axler) omite su discusión hasta mucho más adelante, aunque eso acaba complicando algunos cálculos (por ejemplo, el de los autovalores) más de lo necesario. Aquí los introducimos ya, motivándolos con el siguiente ejemplo.

Consideremos los tres sistemas lineales siguientes:

$$\text{(I)} \quad \begin{cases} 2x + 3y &= 7 \\ 4x + 6y &= 14 \end{cases} \qquad \text{(II)} \quad \begin{cases} 3x + 2y &= 7 \\ 6x + 4y &= 14 \end{cases} \qquad \text{(III)} \quad \begin{cases} 2x + 3y &= 7 \\ 4x + 2y &= 14 \end{cases}$$

Los (I) y (II) son sistemas dependientes (las ecuaciones son múltiplos), mientras que (III) es independiente. En forma vectorial:

$$\text{(I)} \quad x\begin{pmatrix} 2 \\ 4 \end{pmatrix} + y\begin{pmatrix} 3 \\ 6 \end{pmatrix} = \begin{pmatrix} 7 \\ 14 \end{pmatrix}, \qquad \text{(II)} \quad x\begin{pmatrix} 3 \\ 6 \end{pmatrix} + y\begin{pmatrix} 2 \\ 4 \end{pmatrix} = \begin{pmatrix} 7 \\ 14 \end{pmatrix}, \qquad \text{(III)} \quad x\begin{pmatrix} 2 \\ 4 \end{pmatrix} + y\begin{pmatrix} 3 \\ 2 \end{pmatrix} = \begin{pmatrix} 7 \\ 14 \end{pmatrix}.$$

En (I)–(II), los vectores columna son linealmente dependientes: hay infinitas soluciones si el vector de la derecha pertenece a esa recta, y ninguna en caso contrario. En (III), los vectores no son linealmente independientes: generan un paralelogramo y hay una única solución.

[3] De hecho, los determinantes son objetos *multilineales*, aunque eso es un detalle que pasaremos por alto aquí ya que no nos es tan relevante para nuestro contexto.

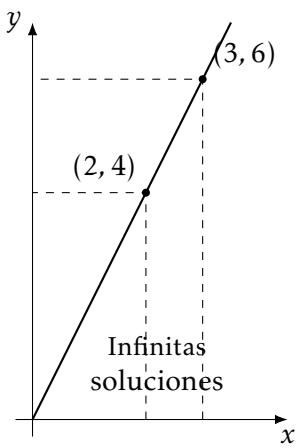

Sistemas (I)–(II): linealmente dependientes.

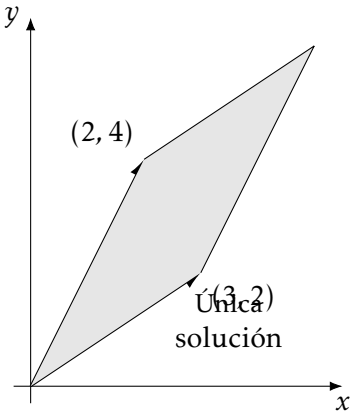

Sistema (III): linealmente independientes (paralelogramo).

El área del paralelogramo con lados $\vec{v}_1, \vec{v}_2 \in \mathbb{R}^2$ nos indica si son dependientes o no: el área es cero $\Leftrightarrow$ los vectores son linealmente dependientes. Además, cuando $\vec{v}_1, \vec{v}_2$ son l.i., el *orden* de los vectores importa: hablar de *área con signo* (orientada) distingue $\{\vec{v}_1, \vec{v}_2\}$ de $\{\vec{v}_2, \vec{v}_1\}$ mediante un cambio de signo.

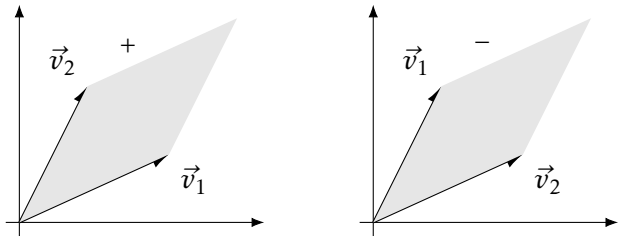

En general, para $\vec{v}_1, \ldots, \vec{v}_n \in \mathbb{R}^n$:

$$\det\Big([\vec{v}_1\ \vec{v}_2\ \cdots\ \vec{v}_n]\Big) \quad \text{es el } \textbf{hipervolumen signado} \text{ del paralelepípedo de lados } \vec{v}_1, \ldots, \vec{v}_n.$$

Nota: si alguna "cara" tiene volumen cero (dos vectores dependientes), el hipervolumen total se anula. En la práctica, calcular geométricamente este valor no es operativo; recurrimos a *técnicas algebraicas*.

11.1 *Definición y cálculo*

A cada matriz cuadrada A se le puede asociar un número especial llamado el **determinante** de la matriz, denotado por $\det(\mathrm{A})$ o $|\mathrm{A}|$.

Se puede definir recursivamente:

1) El determinante de $\mathrm{A} = [a] \in \mathcal{M}_{1\times 1}$ es $\det(\mathrm{A}) = a$.

2) Para $\mathrm{A} \in \mathcal{M}_{n\times n}$ con $n \geq 2$, definimos

$$\det(\mathrm{A}) = \sum_{j=1}^{n} (-1)^{1+j} a_{1j} \det\Big(\mathrm{A}_{1j}\Big)$$

donde $\mathrm{A}_{ij} \in \mathcal{M}_{(n-1)\times(n-1)}$ es la matriz resultante de eliminar la fila i y la columna j de A.

Ejemplo. Para el caso 2×2, tenemos

$$\mathrm{A} = \begin{bmatrix} a & b \\ c & d \end{bmatrix} \quad \Rightarrow \quad \det(\mathrm{A}) = (-1)^2 a_{11} \det(\mathrm{A}_{11}) + (-1)^3 a_{12} \det(\mathrm{A}_{12}) = ad - bc.$$

Se denomina el **cofactor** (i, j) de una matriz A a

$$C_{ij} = (-1)^{i+j} \det\big(A_{ij}\big).$$

Regla mnemotécnica: los signos de $(-1)^{i+j}$ siguen el patrón

$$\begin{bmatrix} + & - & + & - & \cdots \\ - & + & - & + & \cdots \\ + & - & + & - & \cdots \\ \vdots & \vdots & \vdots & \vdots & \ddots \end{bmatrix}$$

Aunque la definición de determinante haga referencia a la primera fila, podemos calcularlo mediante cualquier otra fila o columna:

$$\det(A) = a_{i1}C_{i1} + a_{i2}C_{i2} + \cdots + a_{in}C_{in}, \quad \forall i,$$

$$\det(A) = a_{1j}C_{1j} + a_{2j}C_{2j} + \cdots + a_{nj}C_{nj}, \quad \forall j.$$

Estas fórmulas se denominan **expansión por cofactores**.

Ejemplo (Regla de Sarrus). En el caso de matrices 3×3, tenemos la siguiente fórmula a nuestra disposición

$$\det\begin{bmatrix} a & b & c \\ d & e & f \\ g & h & i \end{bmatrix} = a\det\begin{bmatrix} e & f \\ h & i \end{bmatrix} - b\det\begin{bmatrix} d & f \\ g & i \end{bmatrix} + c\det\begin{bmatrix} d & e \\ g & h \end{bmatrix}$$

$$= aei - afh + bdi - bfg + cdh - ceg.$$

Notamos que, aunque en este ejemplo hemos usado la expansión de cofactores de la fila 1, podríamos haber usado cualquier otra fila o columna.

11.1 theorem. *Sea* $A \in \mathcal{M}_{n\times n}$ *una matriz triangular. Entonces,* $\det(A)$ *es el producto de las entradas diagonales principales.*

Esto hace conveniente el cálculo de determinantes si conseguimos antes reducir la matriz a esta forma mediante operaciones fila. Sin embargo, estas operaciones modifican el determinante y hay que tenerlo en cuenta.

11.2 *Comportamiento bajo operaciones fila*

Sea $A \in \mathcal{M}_{n\times n}$ invertible.

- Si B se obtiene de intercambiar dos filas, $\det(A) = -\det(B)$.

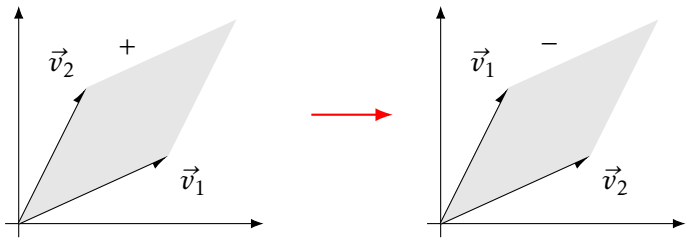

- Si B se obtiene de multiplicar una fila por k, $\det(A) = \frac{1}{k}\det(B)$.

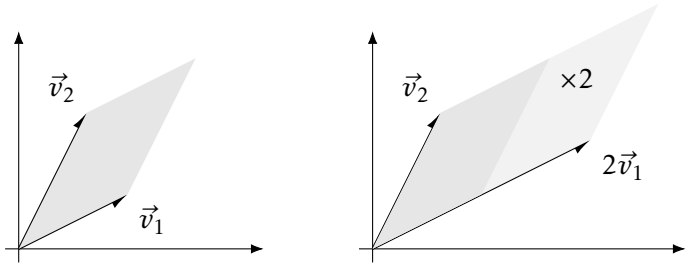

- Si B se obtiene de añadir un múltiplo de una fila a otra, $\det(A) = \det(B)$.

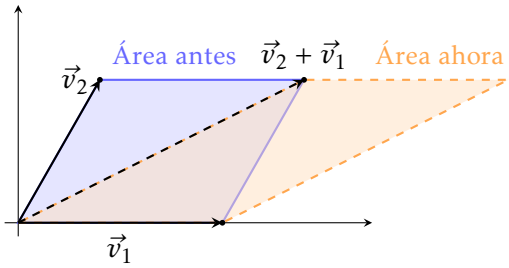

Podemos comprobar visualmente que la operación de trasquilado/cizalla sobre el área la preserva: el triángulo solo azul es idéntico al solo naranja.

En general, para calcular determinantes de matrices de dimensión 4 o mayor, lo más conveniente es aplicar estas operaciones, reduciendo el determinante al de una matriz triangular sobre la que aplicar el anterior Teorema.

Ejemplo.

$$A = \begin{bmatrix} 2 & -8 & 6 & 8 \\ 3 & -9 & 5 & 10 \\ -3 & 0 & 1 & -2 \\ 1 & -4 & 0 & 6 \end{bmatrix}$$

Mediante operaciones fila:

$$\det A = -\det\begin{bmatrix} 1 & -4 & 0 & 6 \\ 3 & -9 & 5 & 10 \\ -3 & 0 & 1 & -2 \\ 2 & -8 & 6 & 8 \end{bmatrix} = -2\det\begin{bmatrix} 1 & -4 & 0 & 6 \\ 0 & 3 & 5 & -8 \\ 0 & -12 & 1 & 16 \\ 0 & 0 & 6 & -4 \end{bmatrix}$$

$$= -2\det\begin{bmatrix} 1 & -4 & 0 & 6 \\ 0 & 3 & 5 & -8 \\ 0 & 0 & 21 & -16 \\ 0 & 0 & 3 & -2 \end{bmatrix} = 2\det\begin{bmatrix} 1 & -4 & 0 & 6 \\ 0 & 3 & 5 & -8 \\ 0 & 0 & 3 & -2 \\ 0 & 0 & 0 & -2 \end{bmatrix}$$

$$= 2 \cdot 1 \cdot 3 \cdot 3 \cdot (-2) = -36.$$

El siguiente teorema nos establece la conexión entre la independencia lineal y los determinantes, tal y como comentamos al inicio de la sección.

11.2 THEOREM. *Una matriz* $A \in \mathcal{M}_{n\times n}$ *es invertible si y sólo si* $\det(A) \neq 0$.

Como vimos, que una matriz cuadrada es invertible si sus columnas (o filas) son linealmente independientes, así que los determinantes caracterizan esto.

11.3 *Otras propiedades*

Sean $A, B \in \mathcal{M}_{n\times n}$. Entonces:

(i) $\det\left(A^T\right) = \det(A)$.

(ii) $\det(AB) = \det(A)\det(B)$.

(iii) Si A es invertible, $\det\left(A^{-1}\right) = \det(A)^{-1}$.

Regla de Cramer A la hora de calcular soluciones a sistemas de ecuaciones, es ineficiente (especialmente para dimensiones altas) pero posible usar la llamada *regla de Cramer*.

Sea $A \in \mathcal{M}_{n\times n}$ invertible. Para cualquier $b \in \mathbb{R}^n$, la solución de $A\vec{x} = b$ tiene entradas dadas por

$$x_i = \frac{\det(A_i(b))}{\det(A)},$$

donde $\det(A_i(b))$ es el determinante de la matriz A cuya columna i-ésima ha sido sustituida por b.

En general, la obtención de una solución por este método involucra calcular muchos determinantes, aumentando la cantidad de pasos intermedios y con ello las probabilidades de cometer un error por el camino, por lo que siempre se recomienda usar Gauss-Jordan.

12 EXTRA

12.1 *Relaciones de conmutación*

Dadas dos matrices cuadradas $A, B \in \mathbb{R}^{n\times n}$, se define el "conmutador" como

$$[A, B] = AB - BA.$$

El conmutador mide la falta de conmutatividad entre A y B: si $[A, B] = 0$, entonces A y B conmutan.

Ejemplo. Sea

$$A = \begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix}, \quad B = \begin{pmatrix} 5 & 0 \\ 0 & -1 \end{pmatrix}.$$

Como ambas son matrices diagonales, se cumple

$$AB = BA = \begin{pmatrix} 10 & 0 \\ 0 & -3 \end{pmatrix}.$$

Por tanto,

$$[A, B] = AB - BA = 0.$$

El conmutador es útil porque captura de manera algebraica el hecho de que, en general, aplicar dos transformaciones lineales en distinto orden produce resultados diferentes. Esta operación aparece en muchos contextos, tanto teóricos como aplicados. Por ejemplo, las rotaciones en $\mathbb{R}^3$ no conmutan, es decir, rotar un objeto primero alrededor de un eje y luego alrededor de otro no produce el mismo resultado que hacerlo en el orden inverso; este hecho se refleja algebraicamente en que el conmutador entre las matrices de rotación no es nulo.

Ejemplo 2 (rotaciones). Consideramos en $\mathbb{R}^3$ las matrices de rotación $R_x(\theta)$ (un ángulo θ entorno al eje x) y $R_y(\varphi)$ (un ángulo φ entorno al eje y).

$$R_x(\theta) = \begin{pmatrix} 1 & 0 & 0 \\ 0 & \cos\theta & -\sin\theta \\ 0 & \sin\theta & \cos\theta \end{pmatrix}, \qquad R_y(\varphi) = \begin{pmatrix} \cos\varphi & 0 & \sin\varphi \\ 0 & 1 & 0 \\ -\sin\varphi & 0 & \cos\varphi \end{pmatrix}.$$

Tomemos, por ejemplo, $\theta = \varphi = \pi/2$. Entonces

$$R_x(\pi/2) = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & -1 \\ 0 & 1 & 0 \end{pmatrix}, \quad R_y(\pi/2) = \begin{pmatrix} 0 & 0 & 1 \\ 0 & 1 & 0 \\ -1 & 0 & 0 \end{pmatrix}.$$

Calculamos:

$$R_x(\pi/2)\, R_y(\pi/2) = \begin{pmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix}, \quad R_y(\pi/2)\, R_x(\pi/2) = \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & -1 \\ -1 & 0 & 0 \end{pmatrix}.$$

Como se observa,

$$R_x(\pi/2)\, R_y(\pi/2) \neq R_y(\pi/2)\, R_x(\pi/2)\,,$$

y en consecuencia no conmutan

$$[R_x(\pi/2), R_y(\pi/2)] \neq 0.$$

Esto refleja geométricamente que el orden en el que se realizan las rotaciones importa: rotar primero alrededor del eje x y luego alrededor del eje y no produce el mismo resultado que hacerlo en el orden inverso.

12.2 *Algunos tipos de matrices importantes*

12.2.1 Por sus propiedades algebraicas

Ortogonales

Unitarias

Hermíticas

Nilpotentes

Idempotentes

Estocásticas

Diagonalmente dominantes

Normales

12.2.2 Por su estructura

Toeplitz y Hankel

Circulantes

12.3 *Pseudoinversas*

Part IV

Espacios vectoriales

13 ESPACIOS VECTORIALES

Todo lo discutido en los capítulos anteriores se puede reinterpretar dentro de un marco más general: el de los espacios vectoriales.

Un **espacio vectorial** no es más que un conjunto no vacío V cuyos elementos llamaremos *vectores*. En él están definidas dos operaciones: la suma de vectores y la multiplicación de un vector por un escalar, siendo los escalares elementos de un cuerpo $\mathbb{K}$.

Decimos que V es un espacio vectorial sobre $\mathbb{K}$ si, para todo $\vec{u}, \vec{v}, \vec{w} \in \mathrm{V}$ y $c, d \in \mathbb{K}$, se cumplen los siguientes axiomas:

(A1) $\vec{u} + \vec{v} \in \mathrm{V}$,

(A2) $\vec{u} + \vec{v} = \vec{v} + \vec{u}$,

(A3) $(\vec{u} + \vec{v}) + \vec{w} = \vec{u} + (\vec{v} + \vec{w})$,

(A4) $\exists \vec{0} \in \mathrm{V}$ tal que $\vec{u} + \vec{0} = \vec{u}$,

(A5) $\forall \vec{u} \in \mathrm{V}$, $\exists -\vec{u} \in \mathrm{V}$ tal que $\vec{u} + (-\vec{u}) = \vec{0}$.

y respecto a la multiplicación por escalares:

(M1) $c\vec{u} \in \mathrm{V}$,

(M2) $c(\vec{u} + \vec{v}) = c\vec{u} + c\vec{v}$,

(M3) $(c + d)\vec{u} = c\vec{u} + d\vec{u}$,

(M4) $c(d\vec{u}) = (cd)\vec{u}$,

(M5) $1\vec{u} = \vec{u}$.

En otras palabras: en un espacio vectorial podemos sumar sus elementos, multiplicarlos por escalares y estas operaciones se comportan de manera "adecuada". Todo esto es de sobra conocido para, por ejemplo, vectores del plano $\mathbb{R}^2$ (listas de dos componentes que podemos combinar linealmente como queramos y seguimos obteniendo vectores de $\mathbb{R}^2$ de vuelta).

La potencia de los espacios vectoriales es que estos axiomas no restringen los vectores a lo que estamos habituados: cualquier conjunto de objetos (ya sean listas de componentes, funciones definidas en un intervalo, polinomios, etc) puede formar un espacio vectorial si satisface estas propiedades.

Vamos a detallar estos axiomas un poco más, y derivar varias consecuencias de ellos.

13.1 *Axiomas aditivos*

Gracias a los axiomas aditivos podemos escribir expresiones como

$$\vec{v}_1 + \vec{v}_2 + \cdots + \vec{v}_m$$

sin preocuparnos por el orden de los sumandos ni por la colocación de paréntesis.

De hecho, de ellos se deducen propiedades importantes:

- El vector nulo $\vec{0}$ es único.
- La inversa aditiva $-\vec{u}$ de cada vector $\vec{u}$ también es única.
- Si $\vec{u} + \vec{w} = \vec{v} + \vec{w}$, entonces $\vec{u} = \vec{v}$.

Además, la **resta** de vectores se define como

$$\vec{u} - \vec{v} = \vec{u} + (-\vec{v}).$$

13.2 *Axiomas de multiplicación por escalar*

Los axiomas de multiplicación nos aseguran que la acción de los escalares sobre los vectores está bien definida. Por ejemplo:

- Para todo $k \in \mathbb{K}$ y $\vec{0} \in \mathrm{V}$, se cumple $k\vec{0} = \vec{0}$.
- Para todo $\vec{u} \in \mathrm{V}$, se cumple $0 \cdot \vec{u} = \vec{0}$.
- Para todo $k \in \mathbb{K}$ y $\vec{u} \in \mathrm{V}$, $(-k)\vec{u} = -(k\vec{u}) = k(-\vec{u})$.

13.3 *Ejemplos y contraejemplos de espacios vectoriales*

Es natural preguntarse: además del archiconocido $\mathbb{R}^n$ con la suma y producto por escalar usuales, ¿qué otros conjuntos cumplen todas estas propiedades? A lo largo de este y los próximos temas veremos varios, pero por mostrar algunose ejemplos ahora

- El espacio $\mathbb{K}^n$ con la suma usual de vectores y la multiplicación por escalares.
- El espacio de matrices $\mathcal{M}_{m\times n}(\mathbb{K})$, con la suma de matrices y la multiplicación escalar habituales.
- El espacio de polinomios de grado menor o igual que n, denotado P_n, cuyos elementos son de la forma
$$p(t) = p_0 + p_1 t + p_2 t^2 + \cdots + p_n t^n,$$
con $p_i \in \mathbb{K}$. Este conjunto también constituye un espacio vectorial sobre $\mathbb{K}$.

Ejercicio Comprobar que $\mathbb{P}_n$ sobre $\mathbb{R}$ cumple los axiomas de un espacio vectorial.

—

(A1) $p(t) + q(t) = (p_0 + q_0) + (p_1 + q_1)t + \cdots + (p_n + q_n)t^n$.

(A2) – (A3) Axiomas de $\mathbb{R}$.

(A4) El elemento neutro es $p(t) = 0 + 0t + \cdots + 0t^n$.

(A5) El inverso aditivo es $p(t) = -p_0 - p_1 t - \cdots - p_n t^n$.

(M1) $cp(t) = (cp_0) + (cp_1)t + \cdots + (cp_n)t^n$.

(M2) – (M5) Axiomas de $\mathbb{R}$.

Los axiomas (A1) y (M1) muestran que no aumentamos el grado del polinomio (no salimos del espacio vectorial).

Vistos los anteriores ejemplos, cabe preguntarse qué no es un espacio vectorial. Claramente, $\mathbb{R}^2$ sobre $\mathbb{R}$ (vectores reales con la multiplicación por escalares reales) es un espacio vectorial. Pero:

- El semiplano superior de $\mathbb{R}^2$ sobre $\mathbb{R}$ (vectores reales con la segunda componente mayor o igual a cero) no lo es, porque no existen en ese espacio las inversas aditivas de cada vector fuera del eje X.
- $\mathbb{R}^2$ sobre $\mathbb{C}$ (vectores reales con la multiplicación por escalares complejos) no lo es, ya que, por ejemplo, $i \cdot \begin{bmatrix} 1 \\ 0 \end{bmatrix} \notin \mathbb{R}^2$.
- $\mathbb{Q}^2$ sobre $\mathbb{R}$ (vectores racionales con la multiplicación por escalares reales) tampoco lo es, pues por ejemplo $\pi \cdot \begin{bmatrix} \frac{3}{2} \\ 1 \end{bmatrix} \notin \mathbb{Q}^2$.

13.4 *Subespacios vectoriales*

Un **subespacio vectoriales** de un espacio vectorial V es un subconjunto $W \subseteq V$ con tres propiedades:

(i) $\vec{0} \in W$.

(ii) W es cerrado bajo la suma: $\forall \vec{u}, \vec{v} \in W \implies \vec{u} + \vec{v} \in W$.

(iii) W es cerrado bajo la multiplicación escalar: $\forall \vec{u} \in W, c \in \mathbb{K} \implies c\vec{u} \in W$.

Podemos combinar (ii) y (iii) en una sola condición: W ha de ser cerrado bajo combinaciones lineales:

$$\forall \vec{u}, \vec{v} \in W, \quad \forall c, d \in \mathbb{K}, \quad c\vec{u} + d\vec{v} \in W.$$

Ejemplo El conjunto $\{\vec{0}\}$ es subespacio de cualquier espacio vectorial. El espacio vectorial entero también es subespacio de sí mismo. Notación: $W \leq V$.

El siguiente ejemplo muestra un punto bastante sutil acerca de los subespacios vectoriales.

Ejemplo Cuidado: $\mathbb{R}^2$ no es subespacio de $\mathbb{R}^3$, ya que $\mathbb{R}^2$ son vectores de dos componentes, mientras que los elementos de $\mathbb{R}^3$ tienen tres. Sin embargo, el conjunto

$$W = \left\{ \begin{bmatrix} t \\ s \\ 0 \end{bmatrix} : t, s \in \mathbb{R} \right\}$$

sí es un subespacio de $\mathbb{R}^3$, ya que representa al plano $z = 0$ dentro del espacio tridimensional.

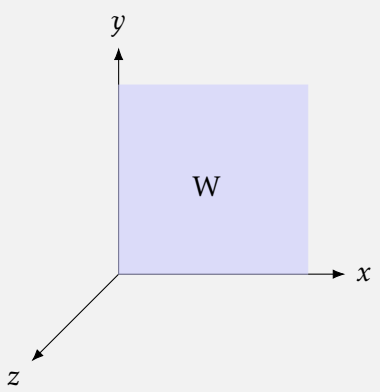

Veamos varios ejemplos menos intuitivos (ya que son espacios vectoriales cuyos elementos no son "vectores" en el sentido usual)

Ejemplo Sea $V = M_{n\times n}$.

- El subconjunto de matrices triangulares superiores es un subespacio.
- El subconjunto de matrices $A \in M_{n\times n}$ tales que $A = A^T$ es también un subespacio.

En ambos casos el elemento neutro respecto a la adición (la matriz nula $0 \in M_{n\times n}$) pertenece al subconjunto, y las combinaciones lineales permanecen en el subconjunto.

Ejemplo Sea $\mathbb{P}$ el espacio vectorial de todos los polinomios. Entonces $\mathbb{P}_n$ (el espacio vectorial de todos los polinomios de orden n) es un subespacio de $\mathbb{P}$.

Hay un ejemplo subespacio que ya hemos visto anteriormente.

13.1 THEOREM. *Sean $\vec{v}_1, \vec{v}_2, \ldots, \vec{v}_m \in V$. Entonces*

$$Span\{\vec{v}_1, \vec{v}_2, \ldots, \vec{v}_m\}$$

es un subespacio de V. A este conjunto se le llama ***subespacio generado*** *por $\vec{v}_1, \ldots, \vec{v}_m$.*

Ejercicio Definimos

$$W = \left\{ \begin{bmatrix} a-3b \\ b-a \\ a \\ b \end{bmatrix} \middle| \; a, b \in \mathbb{R} \right\}.$$

Demostrar que es subespacio de $\mathbb{R}^4$.

—

Claramente, si $a = b = 0$ entonces $\vec{0} \in W$.

Ahora, comprobamos la combinación lineal:

$$c\begin{bmatrix} a-3b \\ b-a \\ a \\ b \end{bmatrix} + d\begin{bmatrix} a'-3b' \\ b'-a' \\ a' \\ b' \end{bmatrix} = \begin{bmatrix} (ca-3cb)+(da'-3db') \\ (cb-ca)+(db'-da') \\ ca+da' \\ cb+db' \end{bmatrix}.$$

Definiendo $s = ac + da'$ y $t = bc + db'$, se tiene

$$\begin{bmatrix} s-3t \\ t-s \\ s \\ t \end{bmatrix} \in W.$$

Por tanto, W es un subespacio.

EJERCICIO. Supongamos

$$\vec{v}_1 = \begin{bmatrix} 1 \\ -1 \\ -2 \end{bmatrix}, \quad \vec{v}_2 = \begin{bmatrix} 5 \\ -4 \\ -7 \end{bmatrix}, \quad \vec{v}_3 = \begin{bmatrix} -3 \\ 1 \\ 0 \end{bmatrix}, \quad \vec{y} = \begin{bmatrix} -4 \\ 3 \\ h \end{bmatrix}.$$

¿Para qué valores de h pertenece $\vec{y}$ al subespacio generado por $\vec{v}_1, \vec{v}_2, \vec{v}_3$?

—

En otras palabras, buscamos si existe una combinación lineal de los tres primeros vectores que sea igual a $\vec{y}$. Esto se traduce en un sistema lineal, cuya resolución nos indica que el sistema es consistente únicamente cuando $h = 5$.

De aquí concluimos dos cosas:

1. Los vectores $\vec{v}_1, \vec{v}_2, \vec{v}_3$ son linealmente dependientes,
2. $\vec{y}$ pertenece al subespacio generado por ellos si y solo si $h = 5$.

14 ESPACIOS NULOS, COLUMNA Y TRANSFORMACIONES

El **espacio nulo** de una matriz $A \in \mathcal{M}_{m\times n}$ se define como el conjunto de todas las soluciones de la ecuación homogénea $A\vec{x} = \vec{0}$:

$$\mathrm{Nul}(A) = \{\vec{x} \in \mathbb{R}^n : A\vec{x} = \vec{0}\}.$$

Es evidente que el vector nulo $\vec{0}$ pertenece a Nul(A), y además este conjunto cumple las propiedades de un subespacio vectorial.

14.1 THEOREM. *Sea $A \in \mathcal{M}_{m\times n}$. Entonces, Nul(A) es un subespacio de $\mathbb{R}^n$.*

Para calcular los vectores que forman el espacio nulo, basta con resolver $A\vec{x} = \vec{0}$. Dichos vectores son, por definición, linealmente independientes y su número coincide con la cantidad de variables libres del sistema.

Geométricamente, el espacio nulo se entiende como el conjunto de vectores que son llevados al origen bajo la transformación definida por A.

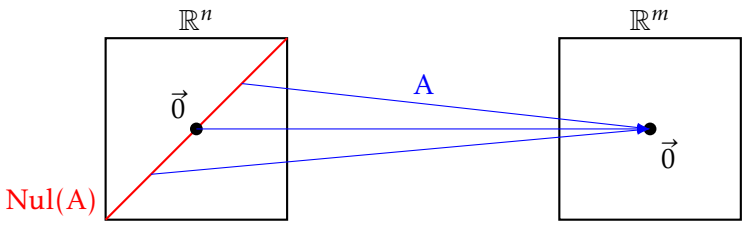

14.1 *El espacio columna*

Por otro lado, el **espacio columna** de una matriz $A \in \mathcal{M}_{m\times n}$ es el conjunto de todas las combinaciones lineales de las columnas de A. Si denotamos $A = [\vec{a}_1, \vec{a}_2, \ldots, \vec{a}_n]$, entonces:

$$\mathrm{Col}(A) = \mathrm{Span}\{\vec{a}_1, \vec{a}_2, \ldots, \vec{a}_n\}.$$

14.2 THEOREM. *Sea* $A \in \mathcal{M}_{m\times n}$. *Entonces, Col*(A) *es un subespacio de* $\mathbb{R}^m$.

El espacio columna representa la imagen de la transformación definida por A, mientras que el espacio nulo representa los vectores que se anulan bajo dicha transformación.

En base a los resultados de temas anteriores, sabemos que $\mathrm{Col}(A) = \mathbb{R}^m$ si y solo si la ecuación $A\vec{x} = \vec{b}$ tiene solución para todo $\vec{b} \in \mathbb{R}^m$.

A priori no tienen nada que ver, pero realmente Nul(A) y Col(A) están relacionados, como veremos pronto.

14.2 *Transformaciones lineales*

Todos los conceptos que hemos discutido se generalizan al caso de **transformaciones lineales**. Sea $T : V \to W$ una transformación lineal entre espacios vectoriales. Decimos que T es lineal si cumple:

(i) $T(\vec{u} + \vec{v}) = T(\vec{u}) + T(\vec{v})$, para todo $\vec{u}, \vec{v} \in V$.

(ii) $T(c\vec{u}) = cT(\vec{u})$, para todo escalar $c \in \mathbb{K}$ y $\vec{u} \in V$.

De este modo, una transformación lineal "preserva" las combinaciones lineales.

Se define el **núcleo** de T como:

$$\ker(T) = \{\vec{u} \in V : T(\vec{u}) = \vec{0}\},$$

y el **rango** de T como:

$$\mathrm{rang}(T) = \{T(\vec{x}) \in W : \vec{x} \in V\}.$$

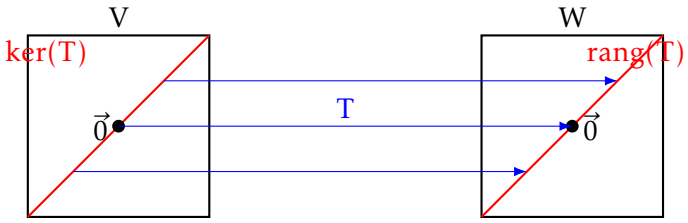

En el caso de que T provenga de una matriz A, se cumple que $\ker(T) = \mathrm{Nul}(A)$ y $\mathrm{rang}(T) = \mathrm{Col}(A)$.

15 BASES

Uno de los conceptos centrales en álgebra lineal es el de **base**. Intuitivamente, una base es un conjunto "mínimo suficiente" de vectores con el que podemos reconstruir todo el espacio, sin vectores redundantes. Esto está íntimamente relacionado con la idea de los sistemas de coordenadas´.

15.1 *Conjuntos linealmente independientes*

El concepto de conjuntos linealmente independientes ya lo vimos en temas anteriores, pero aquí lo repasamos ya que es fundamental para discutir las "bases" de espacios vectoriales.

Sea $S = \{\vec{v}_1, \vec{v}_2, \ldots, \vec{v}_m\}$ con $m \geq 2$ y $\vec{v}_1 \neq \vec{0}$. Entonces S es linealmente dependiente si y sólo si existe algún $j > 1$ tal que

$$\vec{v}_j \in \mathrm{Span}\{\vec{v}_1, \ldots, \vec{v}_{j-1}\}.$$

Dicho de otra manera: un conjunto de vectores es linealmente dependiente si alguno de los vectores es combinación lineal de los anteriores.

EJEMPLOS.

- En $\mathbb{R}^2$, el conjunto
$$\{\vec{v}_1, \vec{v}_2, \vec{v}_3\} = \left\{ \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \begin{bmatrix} -1 \\ 2 \end{bmatrix} \right\}$$
es dependiente porque $\vec{v}_3 = -\vec{v}_1 + 2\vec{v}_2$.
- En el espacio de polinomios, si $p_1(t) = 1$, $p_2(t) = t$ y $p_3(t) = 4 - t$, entonces
$$p_3 = 4\,p_1 - p_2,$$
de modo que $\{p_1, p_2, p_3\}$ es un conjunto dependiente en $\mathcal{P}$.

EJEMPLO. Denotemos por $C[0,1]$ el espacio de funciones $f(t)$ continuas en el intervalo $[0,1]$. Es un espacio vectorial legítimo (podemos sumar funciones y seguirán siendo continuas en el intervalo, lo mismo con la multiplicación por escalares reales). En él,

- $\{\sin t, \cos t\}$ es un conjunto linealmente independiente, ya que no existe ningún $k \in \mathbb{R}$ tal que $\sin t = k \cos t, \forall t \in [0,1]$.
- $\{\sin t \cos t,\ \sin 2t\}$ es un conjunto linealmente dependiente, ya que $\sin 2t = 2 \sin t \cos t$.

Sea W un subespacio de V. Un conjunto $B = \{\vec{b}_1, \ldots, \vec{b}_m\} \subset W$ es una **base de** W si se verifican:

1. B es linealmente independiente;
2. $W = \mathrm{Span}(B)$.

En particular, si $A \in \mathcal{M}_{n\times n}$ es invertible, entonces sus columnas forman una base de $\mathbb{R}^n$ (son independientes y generan todo $\mathbb{R}^n$).

15.1.1 Bases "estándar"

Las columnas $\vec{e}_1, \ldots, \vec{e}_n$ de la identidad $\mathbb{I}_n$ constituyen la **base estándar** de $\mathbb{R}^n$. Visualmente:

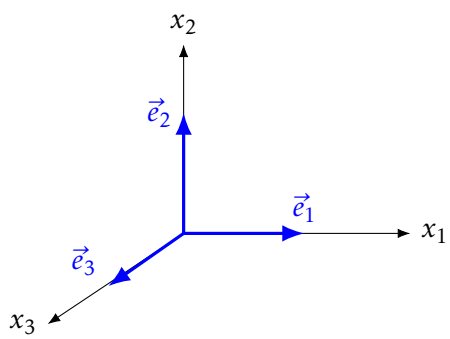

Para polinomios, el conjunto
$$S = \{1,\ t,\ t^2,\ \ldots,\ t^n\}$$
es la **base estándar** de $\mathbb{P}_n$ (es independiente y genera todos los polinomios de grado $\leq n$).

EJERCICIO. Sean

$$\vec{v}_1 = \begin{bmatrix} 3 \\ 0 \\ -6 \end{bmatrix}, \quad \vec{v}_2 = \begin{bmatrix} -4 \\ 1 \\ 7 \end{bmatrix}, \quad \vec{v}_3 = \begin{bmatrix} -2 \\ 1 \\ 5 \end{bmatrix}.$$

¿Es $B = \{\vec{v}_1, \vec{v}_2, \vec{v}_3\}$ una base de $\mathbb{R}^3$?

—

Formamos la matriz con estas columnas y reducimos por filas:

$$\begin{bmatrix} 3 & -4 & -2 \\ 0 & 1 & 1 \\ -6 & 7 & 5 \end{bmatrix} \sim \begin{bmatrix} 3 & -4 & -2 \\ 0 & 1 & 1 \\ 0 & -1 & 1 \end{bmatrix} \sim \begin{bmatrix} 3 & -4 & -2 \\ 0 & 1 & 1 \\ 0 & 0 & 2 \end{bmatrix}.$$

Hay tres pivotes $\Rightarrow$ las columnas son independientes y generan $\mathbb{R}^3$. Por tanto B es una base de $\mathbb{R}^3$.

NOTA: para ser una base, sus vectores no necesariamente tienen que ser ortogonales (aunque todavía no hemos definido qué significa que dos vectores sean ortognoales, hacemos uso de la noción intuitiva por ahora).

15.1.2 Una base como conjunto generador "eficiente"

Una base es un conjunto generador "eficiente", sin vectores innecesarios.

15.1 THEOREM. *Sea* $S = \{\vec{v}_1, \ldots, \vec{v}_m\}$ *y* $W = Span(S)$.

1. *Si algún* $\vec{v}_k$ *es combinación lineal de los demás, entonces podemos quitarlo sin perder el espacio generado.*
2. *Si* $W \neq \{\vec{0}\}$, *entonces algún subconjunto de* S *es base de* W.

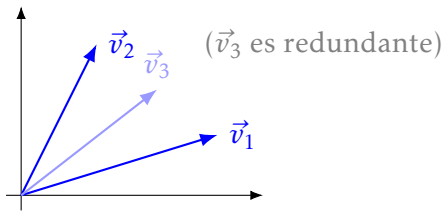

15.1.3 Bases de Nul(A) y Col(A)

Para Nul(A), una base se obtiene *por construcción* resolviendo $A\vec{x} = \vec{0}$ y expresando las soluciones paramétricas como combinación de vectores libres.

Para Col(A), tenemos un criterio especialmente práctico.

15.2 THEOREM. *Las columnas pivote de* A *forman una base de Col*(A).

15.2 *Sistemas de coordenadas*

Una de las aplicaciones más importantes del concepto de **base** es que nos permite definir un *sistema de coordenadas* en el espacio vectorial.

15.3 THEOREM. *Sea* $\mathrm{B} = \{\vec{b}_1, \dots, \vec{b}_n\}$ *una base de un espacio vectorial* V. *Entonces, para cada* $\vec{x} \in \mathrm{V}$ *existe un único conjunto de escalares* $\{c_1, \dots, c_n\}$ *tal que*

$$\vec{x} = c_1\vec{b}_1 + c_2\vec{b}_2 + \cdots + c_n\vec{b}_n.$$

Al conjunto $\{c_1, \dots, c_n\}$ se le llama **coordenadas de** $\vec{x}$ **relativas a la base** B. El vector de coordenadas se denota como

$$[\vec{x}]_{\mathrm{B}} = \begin{bmatrix} c_1 \\ \vdots \\ c_n \end{bmatrix} \in \mathbb{R}^n.$$

Visualmente, tenemos que un mismo punto tiene distintas coordenadas respecto a la base elegida

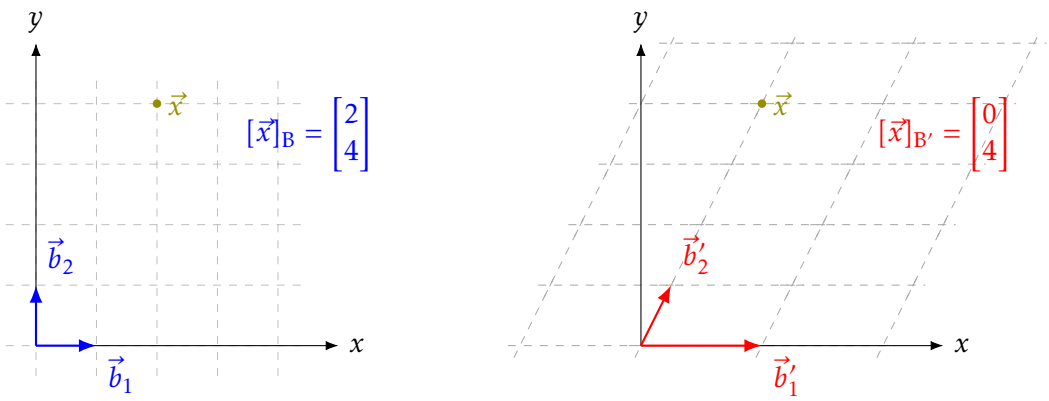

El siguiente ejemplo es ilustrativo en cuanto al cálculo de coordenadas respecto a una base

EJEMPLO. Supongamos que $\vec{b}_1 = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$, $\vec{b}_2 = \begin{bmatrix} -1 \\ 1 \end{bmatrix}$ y $\vec{x} = \begin{bmatrix} 4 \\ 5 \end{bmatrix}$. Queremos hallar $[\vec{x}]_{\mathrm{B}}$.

Resolvemos

$$c_1\vec{b}_1 + c_2\vec{b}_2 = \vec{x}, \quad \Rightarrow \quad \begin{bmatrix} 2 & -1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} c_1 \\ c_2 \end{bmatrix} = \begin{bmatrix} 4 \\ 5 \end{bmatrix}.$$

La solución nos da

$$[\vec{x}]_{\mathrm{B}} = \begin{bmatrix} 3 \\ 2 \end{bmatrix}.$$

El anterior motiva la noción de **matriz de cambio de coordenadas** de B a la base estándar $\mathcal{E}$, denotada como P_{B}:

$$\vec{x} = \mathrm{P}_{\mathrm{B}}[\vec{x}]_{\mathrm{B}}, \quad \mathrm{P}_{\mathrm{B}} = [\vec{b}_1\ \vec{b}_2\ \cdots\ \vec{b}_n].$$

Dado que las columnas de P_{B} son linealmente independientes, P_{B} es invertible. Por lo tanto,

$$[\vec{x}]_{\mathrm{B}} = \mathrm{P}_{\mathrm{B}}^{-1}\vec{x}.$$

Este proceso implementa la llamada **función de coordenadas**:

$$\vec{x} \mapsto [\vec{x}]_{\mathrm{B}}.$$

La función de coordenadas sirve de conexión entre el posiblemente desconocido espacio vectorial V y

el conocido y familiar $\mathbb{R}^n$. Visualmente,

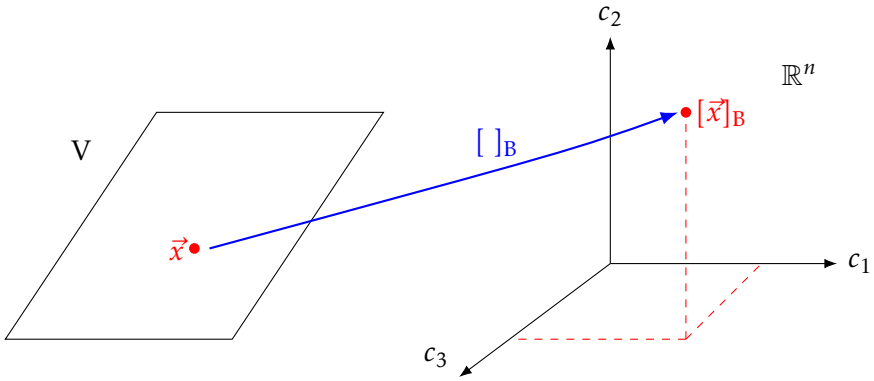

15.4 THEOREM. *Sea* $B = \{\vec{b}_1, \ldots, \vec{b}_n\}$ *una base para un espacio vectorial* V. *Entonces la función de coordenadas*

$$[\ ]_B : V \to \mathbb{R}^n$$

es una transformación lineal biyectiva.

Esto no es sorprendente a estas alturas. Que podamos escribir esta función con una matriz P_B la hace lineal, y que tenga inversa la hace biyectiva (eso no lo hemos mostrado pero es razonable).

PROPIEDADES

(i) $[\vec{v} + \vec{w}]_B = [\vec{v}]_B + [\vec{w}]_B$.

(ii) $[r\vec{v}]_B = r\,[\vec{v}]_B$.

De nuevo, esto es evidente por la linealidad de la función de coordenadas.

15.3 *Cambio de base*

En muchos casos, trabajar con una base distinta de la original facilita los cálculos. Por tanto, necesitamos saber cómo pasar de la descripción de un vector en una base (sus coordenadas) a la descripción en la nueva base. Esto ya lo hemos visto con un caso sencillo, el de pasar de vectores de la base estándar $\mathcal{E}$ a una base dada B. Ahora buscamos el caso general.

Partimos de un vector $\vec{x}$ descrito en las coordenadas $[\vec{x}]_B$ de la base B, y queremos trasladarlo a las coordenadas $[\vec{x}]_C$ de otra base C.

Dado que tanto B como C son bases, podemos escribir las coordenadas de cada vector $\vec{b}_i \in B$ en la base C. Así obtenemos:

$$[\vec{b}_1]_C, [\vec{b}_2]_C, \ldots, [\vec{b}_n]_C.$$

Si $\vec{v} \in V$, tenemos

$$\vec{v} = v_1^B \vec{b}_1 + v_2^B \vec{b}_2 + \cdots + v_n^B \vec{b}_n,$$

y en la nueva base:

$$[\vec{v}]_C = v_1^B [\vec{b}_1]_C + \cdots + v_n^B [\vec{b}_n]_C.$$

Definiendo la matriz de cambio de base

$$P_{C \leftarrow B} = \Big[\, [\vec{b}_1]_C \; [\vec{b}_2]_C \; \ldots \; [\vec{b}_n]_C \,\Big],$$

tenemos la relación:

$$[\vec{v}]_C = P_{C\leftarrow B}[\vec{v}]_B.$$

Análogamente,

$$[\vec{v}]_B = P_{B\leftarrow C}[\vec{v}]_C, \quad \text{con} \quad P_{B\leftarrow C} = \Big[\, [\vec{c}_1]_B \; [\vec{c}_2]_B \; \dots \; [\vec{c}_n]_B \,\Big].$$

Además, $P_{C\leftarrow B}$ y $P_{B\leftarrow C}$ son matrices inversas entre sí:

$$(P_{C\leftarrow B})^{-1} = P_{B\leftarrow C}.$$

Ejemplo. Sean

$$\vec{b}_1 = \begin{bmatrix} -9 \\ 1 \end{bmatrix}, \quad \vec{b}_2 = \begin{bmatrix} -5 \\ -1 \end{bmatrix}, \quad \vec{c}_1 = \begin{bmatrix} 1 \\ -4 \end{bmatrix}, \quad \vec{c}_2 = \begin{bmatrix} 3 \\ -5 \end{bmatrix}.$$

Definimos $B = \{\vec{b}_1, \vec{b}_2\}$ y $C = \{\vec{c}_1, \vec{c}_2\}$. Queremos calcular la matriz $P_{C\leftarrow B}$.

Para ello, buscamos las coordenadas de $\vec{b}_1$ y $\vec{b}_2$ en la base C:

$$[\vec{b}_1]_C = \begin{bmatrix} 6 \\ -5 \end{bmatrix}, \qquad [\vec{b}_2]_C = \begin{bmatrix} 4 \\ -3 \end{bmatrix}.$$

Por lo tanto,

$$P_{C\leftarrow B} = \begin{bmatrix} 6 & 4 \\ -5 & -3 \end{bmatrix}.$$

En general, para calcular $P_{C\leftarrow B}$, resolvemos

$$[\vec{c}_1 \; \vec{c}_2 \; \dots \; \vec{c}_n \; : \; \vec{b}_1 \; \vec{b}_2 \; \dots \; \vec{b}_n] \;\sim\; [\mathbb{I}_n \; : \; P_{C\leftarrow B}].$$

De forma análoga,

$$[\vec{c}_1 \; \vec{c}_2 \; \dots \; \vec{c}_n \; : \; \vec{b}_1 \; \vec{b}_2 \; \dots \; \vec{b}_n] \;\sim\; [P_{B\leftarrow C} \; : \; \mathbb{I}_n].$$

15.3.1 Aplicaciones de los cambios de base

Los cambios de base son fundamentales en muchos contextos:

- Traducir información obtenida en un sistema (por ejemplo, objetivos vistos con una cámara apuntando en una dirección) a otro (apuntando ahora en otra).
- Algunas operaciones son mucho más sencillas en una base que en otra. Esto lo veremos en detalle con la diagonalización.
- En ocasiones queremos comprimir información, sobre todo cuando tenemos una base de datos grande que sospechamos que tiene bastante información redundante. Una forma eficiente de hacerlo es encontrar una base en la cual algunos vectores no sean tan relevantes, y eliminarlos (la técnica más conocida para llevarlo a cabo se denomina *Principal Component Analysis*, PCA).

16 DIMENSIÓN DE UN ESPACIO VECTORIAL

A lo largo de anteriores temas ha habido una noción muy intuitiva, que formalizamos aquí: la *dimensión*. El hecho de que cualquier espacio vectorial con una base sea isomorfo a $\mathbb{R}^n$ (es decir, que

existe una biyección entre sus elementos), nos dice que hay un número intrínseco, n, al espacio, que no depende de la base escogida.

16.1 THEOREM. *Todas las bases de un espacio vectorial* V *tienen el mismo número de elementos.*

La dimensión de un espacio vectorial V finito se define como el número de vectores en cualquier base de V. Si $\mathrm{B} = \{\vec{b}_1, \ldots, \vec{b}_n\}$ es una base de V, entonces

$$\dim(\mathrm{V}) = n.$$

EJEMPLOS. Los espacios $\mathbb{R}^n$ y $\mathbb{P}_n$, que hemos visto una y otra vez, tienen las siguientes dimensiones,

$$\dim(\mathbb{R}^n) = n, \quad \dim(\mathbb{P}_n) = n + 1,$$

acordes a la intuición.

EJERCICIO. Obtener la dimensión del subespacio definido por

$$\mathrm{W} = \left\{ \begin{bmatrix} a - 3b + 6c \\ 5a + 4d \\ b - 2c - d \\ 5d \end{bmatrix} \middle| \; a, b, c, d \in \mathbb{R} \right\}.$$

—

Para comenzar, expresamos este conjunto en términos de un sistema de generadores. Observamos que cualquier elemento de W puede escribirse como una combinación lineal de los vectores

$$v_1 = \begin{bmatrix} 1 \\ 5 \\ 0 \\ 0 \end{bmatrix}, \quad v_2 = \begin{bmatrix} -3 \\ 0 \\ 1 \\ 0 \end{bmatrix}, \quad v_3 = \begin{bmatrix} 6 \\ 0 \\ -2 \\ 0 \end{bmatrix}, \quad v_4 = \begin{bmatrix} 0 \\ 4 \\ -1 \\ 5 \end{bmatrix}.$$

Por tanto,

$$\mathrm{W} = \mathrm{Span}\{v_1, v_2, v_3, v_4\}.$$

La pregunta clave es: ¿cuántos de estos vectores son linealmente independientes? Para comprobarlo, colocamos los vectores como columnas de una matriz y realizamos reducción por filas:

$$\begin{bmatrix} 1 & -3 & 6 & 0 \\ 5 & 0 & 0 & 4 \\ 0 & 1 & -2 & -1 \\ 0 & 0 & 0 & 5 \end{bmatrix} \sim \begin{bmatrix} 1 & -3 & 6 & 0 \\ 0 & 0 & 0 & 4 \\ 0 & 1 & -2 & -1 \\ 0 & 0 & 0 & 5 \end{bmatrix} \sim \begin{bmatrix} 1 & -3 & 6 & 0 \\ 0 & 1 & -2 & -1 \\ 0 & 0 & 0 & 4 \\ 0 & 0 & 0 & 5 \end{bmatrix}.$$

De aquí se concluye que los vectores v_1, v_2 y v_4 son linealmente independientes, mientras que v_3 es dependiente, pues en realidad se cumple que

$$v_3 = -2v_2.$$

Así, una base de W es

$$B = \{v_1, v_2, v_4\},$$

y por tanto

$$\dim(W) = 3.$$

16.2 THEOREM (de la base). *Sea* V *un espacio vectorial de dimensión* $n \geq 1$. *Entonces:*

- *Cualquier conjunto linealmente independiente con exactamente* n *elementos es, automáticamente, una base de* V.
- *Equivalentemente, cualquier conjunto de* n *vectores que genere* V *es una base de* V.

16.0.1 Subespacios de espacios de dimensión finita

Si W es un subespacio de un espacio vectorial V de dimensión finita, entonces W también tiene dimensión finita y se cumple

$$\dim(W) \leq \dim(V).$$

Además, si $A \in \mathcal{M}_{m\times n}$, entonces $\dim(\mathrm{Nul}(A))$ es el número de variables libres de $A\vec{x} = \vec{0}$ y $\dim(\mathrm{Col}(A))$ es el número de columnas pivote de A.

16.1 *Rango*

El rango de una matriz $A \in \mathcal{M}_{m\times n}$ se define como la dimensión de su espacio columna.

Cuidado: desfortunadamente, la palabra "rango" se usa indistintamente para el espacio de "llegada" de un operador T, y para la dimensión del espacio columna de una matriz A.

16.3 THEOREM (del rango). *Para toda matriz* $A \in \mathcal{M}_{m\times n}$ *se cumple*

$$rang(A) + \dim(Nul(A)) = n.$$

Este resultado nos dice que el número de columnas pivote más el número de columnas libres equivale al número total de columnas.

16.2 *Teorema de la matriz inversa (II)*

En el tema anterior discutimos la invertibilidad de matrices. Ahora tenemos más herramientas para caracterizarlas.

16.4 THEOREM (de la matriz inversa, continuación). *Sea* $A \in \mathcal{M}_{n\times n}$. *Los siguientes enunciados son equivalentes a que* A *sea una matriz invertible:*

(m) *Las columnas de* A *forman una base de* $\mathbb{R}^n$.
(n) $Col(A) = \mathbb{R}^n$.
(o) $\dim(Col(A)) = n$.
(p) $rango(A) = n$.
(q) $Nul(A) = \{\vec{0}\}$.
(r) $\dim(Nul(A)) = 0$.

Part V

Valores y vectores propios

17 INTRODUCCIÓN

La transformación lineal $\vec{x} \mapsto A\vec{x}$ "mueve" vectores en distintas direcciones. Sin embargo, hay ciertos vectores *especiales* para los cuales la acción de A es más simple: únicamente los escala. Estos vectores se denominan **vectores propios**, y los escalares correspondientes, **valores propios**.

Ejemplo. Sea

$$A = \begin{bmatrix} 3 & -2 \\ 1 & 0 \end{bmatrix}, \quad \vec{u} = \begin{bmatrix} -1 \\ 1 \end{bmatrix}, \quad \vec{v} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}.$$

Entonces

$$A\vec{u} = \begin{bmatrix} -5 \\ -1 \end{bmatrix}, \quad A\vec{v} = \begin{bmatrix} 4 \\ 2 \end{bmatrix} = 2\vec{v}.$$

Notamos que $\vec{v}$ es un vector propio asociado al autovalor $\lambda = 2$.

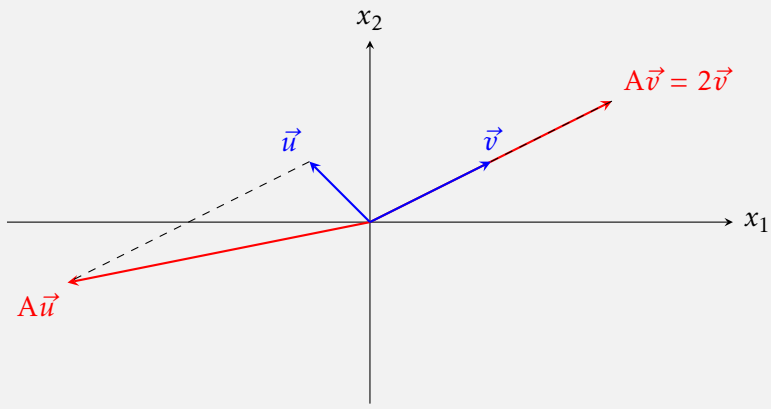

La acción de A sobre $\vec{u}$ es más compleja que sobre $\vec{v}$, el cual simplemente escala por 2.

17.1 *Vectores y valores propios*

Un **vector propio** o *autovector* de $A \in \mathcal{M}_{n\times n}$ es un vector no nulo $\vec{x} \neq \vec{0}$ tal que

$$A\vec{x} = \lambda\vec{x},$$

para algún $\lambda \in \mathbb{R}$. Este λ se denomina **valor propio** o *autovalor* de A.

El conjunto de todos los valores propios de una matriz A se llama el **espectro** de A:

$$\sigma(A) = \{\lambda_1, \ldots, \lambda_p\}.$$

Además, mayor autovalor (en módulo),

$$\rho(A) = \max\{|\lambda_1|, \ldots, |\lambda_p|\}$$

se denomina **radio espectral**, y es muy importante para diversas aplicaciones.

Los siguientes teoremas son importantes. El primero concierne a autovectores asociados a autovalores

distintos, el segundo a autovectores asociados a un mismo autovalor.

17.1 THEOREM. *Si $\vec{v}_1, \ldots, \vec{v}_p$ son vectores propios asociados a valores propios distintos $\lambda_1, \ldots, \lambda_p$, entonces $\{\vec{v}_1, \ldots, \vec{v}_p\}$ es un conjunto linealmente independiente.*

17.2 THEOREM. *Sea $A \in \mathcal{M}_{n\times n}$. Si $\vec{v}_1, \ldots, \vec{v}_p$ son vectores propios asociados al mismo λ, entonces cualquier combinación lineal no nula*

$$\vec{x} \in Span\{\vec{v}_1, \ldots, \vec{v}_p\}$$

es también vector propio de A.

Como vemos, lo que tenemos es una colección, no ya de vectores, sino de direcciones o incluso subespacios "privilegiados", en los que la acción de la matriz correspondiente se simplifica.

17.2 *Subespacios propios*

Esto último motiva la introducción del concepto de **subespacio propio** asociado a un autovalor λ. Este se define como

$$E_\lambda = \{\vec{x} \in \mathbb{R}^n : A\vec{x} = \lambda\vec{x}\}.$$

Notemos que la condición que satisface se puede escribir de dos maneras distintas

$$A\vec{x} = \lambda\vec{x} \Longleftrightarrow (A - \lambda\mathbb{I}_n)\vec{x} = \vec{0}.$$

EJERCICIO. Encontrar una base para E_2, siendo $\lambda = 2$ autovalor de

$$A = \begin{bmatrix} 4 & -1 & 6 \\ 2 & -1 & 6 \\ 2 & -1 & 8 \end{bmatrix}.$$

—

Resolver $(A - 2I)\vec{x} = 0$ lleva a un sistema con una variable pivote y dos libres.

$$\begin{cases} x_1 = 1/2x_2 - 3x_3 \\ x_2,\ x_3 \text{ libres.} \end{cases} \Rightarrow \vec{x} = x_2 \begin{bmatrix} 1/2 \\ 1 \\ 0 \end{bmatrix} + x_3 \begin{bmatrix} -3 \\ 0 \\ 1 \end{bmatrix}$$

La base resultante es

$$B = \left\{ \begin{bmatrix} 1/2 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} -3 \\ 0 \\ 1 \end{bmatrix} \right\}.$$

Vemos claramente la relación entre subespacios nulos y subespacios asociados a autovalores.

17.3 THEOREM. *Sea $A \in \mathcal{M}_{n\times n}$. Para cada autovalor λ de* A, *se cumple que $E_\lambda = Nul(A - \lambda\mathbb{I}_n)$.*

Hasta ahora hemos asumido conocidos los autovalores, pero no hemos visto todavía cómo se obtienen. Existen algunos casos en los que el cálculo de autovalores es inmediato, por ejemplo el expuesto a

continuación.

17.4 THEOREM. *Los valores propios de una matriz triangular son las entradas de la diagonal principal.*

En general, sin embargo, será necesario recurrir a otra técnica para el cálculo de autovalores.

18 ECUACIÓN CARACTERÍSTICA

La información de los autovalores de una matriz $A \in \mathcal{M}_{n\times n}$ está codificada en una ecuación denominada **ecuación característica** de A.

Recordemos que, para que la ecuación $(A - \lambda\mathbb{I}_n)\vec{x} = \vec{0}$ tenga solución no trivial, es necesario que $(A - \lambda\mathbb{I}_n)$ no sea invertible. Esta condición se traduce en:

$$\det(A - \lambda\mathbb{I}_n) = 0.$$

Esta es la llamada **ecuación característica** de A, que da lugar a un polinomio de grado como mucho n. Por tanto, una matriz de orden n puede tener como máximo n autovalores distintos.

El polinomio

$$p(\lambda) = \det(A - \lambda\mathbb{I}_n)$$

se denomina **polinomio característico** de A.

Una vez calculados los autovalores, podemos determinar los autovectores asociados siguiendo el procedimiento indicado anteriormente (el cálculo de la base del espacio nulo de $A - \lambda\mathbb{I}_n$).

EJEMPLO. Sea

$$A = \begin{bmatrix} 2 & 3 \\ 3 & -6 \end{bmatrix}.$$

Calculamos el polinomio característico y sus raíces:

$$p(\lambda) = \det(A - \lambda\mathbb{I}_n) = \det\begin{bmatrix} 2-\lambda & 3 \\ 3 & -6-\lambda \end{bmatrix} = (2-\lambda)(-6-\lambda) - 9.$$

$$p(\lambda) = \lambda^2 + 4\lambda - 21 = 0 \quad \Rightarrow \quad \lambda_1 = 3,\ \lambda_2 = -7.$$

- Para $\lambda_1 = 3$, resolvemos $(A - 3\mathbb{I}_n)\vec{v}_1 = 0$ y obtenemos

$$\vec{v}_1 = \begin{bmatrix} 3 \\ 1 \end{bmatrix}.$$

- Para $\lambda_2 = -7$, resolvemos $(A + 7\mathbb{I}_n)\vec{v}_2 = 0$ y obtenemos

$$\vec{v}_2 = \begin{bmatrix} 1 \\ -3 \end{bmatrix}.$$

Nota: al intentar encontrar el/los autovector/autovectores asociados a un autovalor, el sistema de ecuaciones a resolver $(A - \lambda_i\mathbb{I}_n)\vec{v}_i = 0$ es necesariamente compatible indeterminado. De hecho, al menos una ecuación será redundante precisamente por esto. Esto encaja con lo que hemos discutido

antes acerca de los subespacios propios: si fuera compatible determinado la solución sería un único vector que no se podría reescalar.

18.1 *Autovalores complejos*

Hasta este momento hemos trabajado con espacios vectoriales reales $\mathbb{R}^n$, ya que ofrecen mayor simplicidad y una intuición visual más clara. Sin embargo, en muchos casos, aun cuando las matrices tengan entradas reales, sus autovalores y/o autovectores pueden ser complejos.

Ejemplo. Sea $T : \mathbb{C}^n \to \mathbb{C}^n$ la transformación lineal definida por

$$T(\vec{x}) = A\vec{x}, \quad A = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}.$$

1. El polinomio característico es

$$p(\lambda) = \det \begin{bmatrix} -\lambda & 1 \\ -1 & -\lambda \end{bmatrix} = \lambda^2 + 1,$$

cuyas raíces son $\lambda = \pm i$.

2. Para $\lambda = i$, resolvemos

$$\begin{bmatrix} -i & 1 \\ -1 & -i \end{bmatrix} \vec{v} = \vec{0}, \quad \Rightarrow \quad E_i = \operatorname{Span}\left\{ \begin{bmatrix} i \\ 1 \end{bmatrix} \right\}.$$

Para $\lambda = -i$, de forma análoga se obtiene

$$E_{-i} = \operatorname{Span}\left\{ \begin{bmatrix} i \\ -1 \end{bmatrix} \right\}.$$

18.2 *Multiplicidad de autovalores*

En los ejemplos anteriores todos los autovalores eran distintos, lo que garantizaba que los autovectores asociados formaran una base (gracias al primer teorema de este tema). Sin embargo, esto no siempre ocurre.

Ejemplos.

- Sea

$$A = \begin{bmatrix} 4 & -1 & 6 \\ 2 & 1 & 6 \\ 2 & -1 & 8 \end{bmatrix}.$$

Su polinomio característico es

$$p(\lambda) = -(\lambda - 2)^2(\lambda - 9).$$

Aquí $\lambda = 2$ es una raíz doble (multiplicidad 2) y $\lambda = 9$ es una raíz simple.

En este ejemplo, encontramos que

$$E_2 = \text{Span}\left\{\begin{bmatrix}\frac{1}{2}\\1\\0\end{bmatrix}, \begin{bmatrix}-3\\0\\1\end{bmatrix}\right\}, \quad E_9 = \text{Span}\left\{\begin{bmatrix}1\\1\\1\end{bmatrix}\right\}.$$

Por lo tanto, existe una base de autovectores y la matriz es diagonalizable.

- Pero no siempre tenemos tanta suerte: consideremos la matriz

$$A = \begin{bmatrix}2 & 2 & 3\\0 & 2 & 2\\0 & 0 & 2\end{bmatrix}.$$

Su polinomio característico es $(\lambda - 2)^3$, y el único autovalor es $\lambda = 2$, con multiplicidad algebraica 3. Sin embargo, el subespacio propio asociado es

$$E_2 = \text{Span}\left\{\begin{bmatrix}1\\0\\0\end{bmatrix}\right\},$$

que tiene dimensión 1, insuficiente para formar una base de $\mathbb{R}^3$.

La posibilidad de formar una base con los autovectores asociados a autovalores de una matriz dependerá de las multiplicidades algebraica y geométrica de cada autovalor.

18.2.1 Multiplicidad algebraica y geométrica

Sea $A \in \mathcal{M}_{n\times n}$ y λ un autovalor.

- La **multiplicidad algebraica** de λ, denotada m_λ, es el exponente con el que λ aparece como raíz del polinomio característico.
- La **multiplicidad geométrica** de λ es $\dim(E_\lambda)$.

El siguiente teorema establece una relación entre ellos.

18.1 THEOREM. *Para todo autovalor λ de A, se cumple que* $\dim(E_\lambda) \leq m_\lambda$.

EJEMPLOS ANTERIORES.

- En el primer caso, teníamos $m_2 = 2 = \dim(E_2)$ y $m_9 = 1 = \dim(E_9)$.
- En el segundo caso, teníamos $m_2 = 3$ pero $\dim(E_2) = 1$.

Estos ejemplos nos guían en la dirección correcta: los autovectores de una matriz forman una base del espacio si y solo si $m_\lambda = \dim(E_\lambda)$, $\forall \lambda$.

falta teorema aquí

Esto es muy relevante para la próxima sección.

19 DIAGONALIZACIÓN

Una de las motivaciones que mencionamos al comienzo del tema era la posibilidad de, dada una matriz A, encontrar una base del espacio en la que la matriz sea diagonal, puesto que eso simplifica *mucho* algunos cálculos. Antes de eso conviene discutir la semejanza entre matrices.

19.1 *Matrices semejantes*

Dos matrices $A, B \in \mathcal{M}_{n\times n}$ son **semejantes** si existe una matriz invertible P tal que

$$A = PBP^{-1}.$$

19.1 THEOREM. *Si* A *y* B *son semejantes, entonces comparten el polinomio característico y, en consecuencia, también el espectro.*

Esto es evidente si recordamos las propiedades del determinante

$$\det(A - \lambda\mathbb{I}_n) = \det\left(PBP^{-1} - \lambda PP^{-1}\right) = \det(P)\det(B - \lambda\mathbb{I}_n)\det\left(P^{-1}\right) = \det(B - \lambda\mathbb{I}_n).$$

Un caso particular de semejanza aparece al hacer un cambio de base. Si A_B es el operador en la base original B, y A_C es su forma en otra base C, se cumple que ambas son semejantes, relacionadas por

$$A_B = P_{B\leftarrow C} A_C (P_{C\leftarrow B})^{-1} \tag{1}$$

Podemos visualizar la relación mediante el siguiente diagrama conmutativo:

$$\begin{tikzcd}
\vec{x} \arrow[r, "A"] \arrow[d, "P^{-1}"'] & A\vec{x} \arrow[d, "P"] \\
{[\vec{x}]_{B'}} \arrow[r, "A_{B'}"'] & {[A\vec{x}]_{B'}}
\end{tikzcd}$$

19.2 *Diagonalización de matrices*

Hay un tipo de semejanza entre matrices que es especialmente útil, que se da cuando una matriz cualquiera es semejante a una matriz diagonal. Entonces se dice que la matriz original es *diagonalizable*. En base a lo que hemos visto en secciones anteriores, tenemos la siguiente caracterización.

19.2 THEOREM. *Una matriz* $A \in M_{n\times n}$ *es diagonalizable si y solo si sus autovectores forman una base del espacio. Equivalentemente:* A *posee n autovectores linealmente independientes.*

En ese caso, existen una matriz invertible $P = [\vec{v}_1 \vec{v}_2, \ldots, \vec{v}_n]$ (siendo las columnas $\vec{v}_i$ los autovectores de A) y una diagonal $D = \operatorname{diag}(\lambda_1, \ldots, \lambda_n)$ tales que

$$A = PDP^{-1}.$$

Claramente, A y D son matrices semejantes (y por tanto tiene sentido que compartan el mismo espectro).

Ejercicio. Diagonalizar, si es posible, las siguientes matrices.

1.
$$A = \begin{bmatrix} 2 & 4 & 3 \\ -4 & -6 & -3 \\ 3 & 3 & 1 \end{bmatrix}.$$

—

Su polinomio característico es

$$p(\lambda) = \det(A - \lambda I) = -(\lambda - 1)(\lambda + 2)^2.$$

Luego los autovalores son $\lambda_1 = 1$ y $\lambda_2 = -2$ (doble). Para que A sea diagonalizable necesitamos $\dim E_{-2} = 2$. Calculando,

$$E_{-2} = \ker(A + 2I) = \operatorname{Span}\left\{\begin{bmatrix} -1 \\ 1 \\ 0 \end{bmatrix}\right\}, \qquad \dim E_{-2} = 1 < 2.$$

Por tanto, A **no es diagonalizable**.

2.
$$A = \begin{bmatrix} 1 & 3 & 3 \\ -3 & -5 & -3 \\ 3 & 3 & 1 \end{bmatrix}.$$

—

De nuevo $p(\lambda) = -(\lambda - 1)(\lambda + 2)^2$, pero esta vez obtenemos

$$E_1 = \operatorname{Span}\left\{\begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix}\right\}, \qquad E_{-2} = \operatorname{Span}\left\{\begin{bmatrix} -1 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix}\right\}.$$

Así, $\dim E_1 = 1$ y $\dim E_{-2} = 2$, con lo que $\dim E_1 + \dim E_{-2} = 3 = n$. Por consiguiente, A **es diagonalizable**. Tomando como columnas los autovectores

$$P = [\vec{v}_1\ \vec{v}_2\ \vec{v}_3] = \begin{bmatrix} 1 & -1 & -1 \\ -1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}, \qquad D = \operatorname{diag}(1, -2, -2),$$

se verifica $A = PDP^{-1}$ (en este caso, es más práctico comprobar $AP = PD$, así evitamos calcular P^{-1} explícitamente).

Formalizando las ideas de ejercicios anteriores, presentamos el siguiente resultado.

19.3 THEOREM. *Sea* $A \in \mathcal{M}_{n\times n}$ *con autovalores (distintos)* $\lambda_1, \dots, \lambda_p$.

1. A *es diagonalizable si y solo si*
$$\sum_{i=1}^{p} \dim(E_{\lambda_i}) = n,$$
equivalente a que para todo i, *la multiplicidad geométrica de* λ_i *coincida con la algebráica.*
2. *Si* A *es diagonalizable y* B_i *es una base de* E_{λ_i}, *entonces la unión* $B_1 \cup \dots \cup B_p$ *es una base del espacio vectorial.*

19.3 *Ventajas operacionales de la diagonalización*

Diagonalizar una matriz conlleva unas serie de ventajas. Por un lado, desde el punto de vista de la interpretación se entiende qué subespacios son característicos a la matriz (si esta representa algún tipo de sistema, estos subespacios van a tener significados particulares). Esto es fundamental en muchos contextos: por ejemplo, la mecánica cuántica está basada casi en su totalidad en ideas de linealidad de operadores (transformaciones), cuyos autovalores representan observables físicos y sus autovectores estados particulares del sistema asociados a esos observables.

Además de esto, también hay ventajas a la hora de realizar ciertos cálculos. Concretamente, si $A = PDP^{-1}$, entonces:

- El determinante de la matriz es el producto de sus autovalores,
$$\det(A) = \det\left(PDP^{-1}\right) = \det(P)\det(D)\det\left(P^{-1}\right) = \det(D) = \prod_{i=1}^{n} \lambda_i.$$

- Las potencias de matrices se reducen a calcular las potencias de la matriz diagonal (algo trivial), seguido de dos productos de matrices.
$$A^k = \underbrace{(PDP^{-1})(PDP^{-1})\dots(PDP^{-1})}_{k \text{ veces}} = PD^kP^{-1} \quad (k \in \mathbb{N}).$$

- De forma similar, si una matriz no posee el cero en su espectro (si $\lambda_i \neq 0$, $\forall i$) entonces
$$A^{-1} = (PDP^{-1})^{-1} = P^{-1}D^{-1}P.$$

- Una propiedad muy importante de las matrices es su traza: la suma de las entradas de la diagonal principal. Esta se puede escribir también en términos de los autovalores, gracias a la diagonalización
$$\operatorname{tr}(A) = \sum_{i=1}^{n} a_{ii} = \sum_{i=1}^{n} \lambda_i.$$

19.4 *Teorema de la matriz inversa (III)*

Con los conceptos adquiridos en este tema disponemos de nuevas formas de caracterizar una matriz invertible, que añadimos a los ya conocidos.

19.4 THEOREM (de la matriz inversa, continuación). *Sea* $A \in \mathcal{M}_{n\times n}$. *Los siguientes enunciados son equivalentes a que* A *sea una matriz invertible:*

(s) 0 no *es autovalor de* A.

(t) $\det(A) \neq 0$.

20 EXTRA

20.1 *Forma canónica de Jordan*

20.2 *Procesos de Markov*

Una aplicación donde los autovalores y autovectores son fundamentales, es en los **procesos de Markov**.

Un proceso de Markov describe un sistema que evoluciona de manera probabilística entre distintos estados, con la propiedad de que el futuro solo depende del estado actual (y no de la historia anterior). Un ejemplo sencillo es un *caminante aleatorio* que se mueve sobre una red: en cada paso, salta de un nodo a otro con cierta probabilidad.

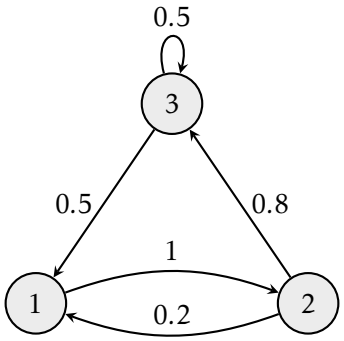

Figure 3: Un caminante aleatorio en una red de 3 nodos.

Si denotamos por $\pi(t)$ al vector de probabilidades en el instante t, y por P a la matriz de transición (cuyas entradas son las probabilidades de salto), entonces la dinámica está dada por

$$\pi(t+1) = P^T \pi(t).$$

Con el tiempo, muchos procesos de Markov tienden a un **estado estacionario** π^* que satisface

$$\pi^* = \lim_{t\to\infty} \pi(t) \quad \Longrightarrow \quad \pi^* = P^T \pi^*.$$

Esto es exactamente la ecuación de un autovector: π^* es un vector propio de P con autovalor $\lambda = 1$. Además, como representa una distribución de probabilidades, sus componentes deben ser no negativas y sumar 1. Este autovector tiene una interpretación objetiva: la componente π^*_i representa la proporción del veces que pasa el caminante aleatorio en el nodo i respecto al total de los nodos.

EJEMPLO. Para la red de 3 nodos anterior, la matriz de transición es

$$P = \begin{bmatrix} 0 & 0.4 & 0 \\ 0.6 & 0 & 0.5 \\ 0.4 & 0.6 & 0.5 \end{bmatrix}.$$

El estado estacionario satisface

$$\pi^* = P^T \pi^*, \qquad \pi_1^* + \pi_2^* + \pi_3^* = 1, \qquad \pi_i > 0, \forall i.$$

La solución es el autovector

$$\pi^* = \begin{bmatrix} 5/18 \\ 5/18 \\ 4/9 \end{bmatrix} \approx \begin{bmatrix} 0.278 \\ 0.278 \\ 0.444 \end{bmatrix}.$$

Es decir, el nodo más visitado por un paseante aleatorio sería el tercero, casi el doble que los otros.

El algoritmo *PageRank* de Google para ordenar páginas web según su importancia (de forma que los primeros resultados en cada búsqueda son los más relevantes), se basa en exactamente la misma idea[4]: un caminante aleatorio en la red de páginas web, que sigue enlaces con cierta probabilidad y de vez en cuando salta a una página aleatoria. El *ranking* de cada página se obtiene del vector estacionario de esta cadena de Markov: es decir, del autovector asociado al autovalor 1 de la matriz de transición (normalizada). Esto tiene sentido con respecto a la interpretación del vector como representando la cantidad de veces que el paseante pasa por cada página, de forma que aquellas páginas más visitadas por el paseante serán las mejor conectadas y por tanto las que estén posicionadas más arriba en el ranking.

[4]Aunque algo modificada, dándole más reglas al paseante aleatorio, pero las matemáticas son las mismas.

Part VI

Producto escalar

21 INTRODUCCIÓN

Hasta el momento hemos generalizado la estructura lineal (adición y multiplicación por escalar) de $\mathbb{R}^n$ a espacios vectoriales genéricos V. Sin embargo, hay nociones que todavía no tenemos disponibles con la maquinaria introducida y que son esenciales en aplicaciones, como el cálculo de longitudes y ángulos.

Todo esto requiere de la introducción de estructuras adicionales con las que *equipar* el espacio vectorial original.

21.1 *Producto interno*

Sea V un espacio vectorial. Podemos asociar a cada par de vectores $\vec{u}, \vec{v} \in \mathrm{V}$ un número real, denotado por $\langle \vec{u}, \vec{v} \rangle \in \mathbb{R}$, que se denomina **producto interno** de V, si se cumplen las siguientes propiedades para todo $\vec{u}, \vec{v}, \vec{w} \in \mathrm{V}$ y $a, b \in \mathbb{K}$:

(i) Linealidad en la primera entrada:

$$\langle a\vec{u} + b\vec{v}, \vec{w} \rangle = a\langle \vec{u}, \vec{w} \rangle + b\langle \vec{v}, \vec{w} \rangle.$$

(ii) Simetría conjugada:

$$\langle \vec{u}, \vec{v} \rangle = \langle \vec{v}, \vec{u} \rangle.$$

(iii) Semidefinido positivo:

$$\langle \vec{u}, \vec{u} \rangle \geq 0, \quad \text{y} \quad \langle \vec{u}, \vec{u} \rangle = 0 \iff \vec{u} = 0.$$

Este último punto nos permite asignar a cada vector un número propio, llamado la **norma**, definida por:

$$\|\vec{u}\| = \sqrt{\langle \vec{u}, \vec{u} \rangle}.$$

Ejemplos.

- El espacio euclídeo usual $\mathbb{R}^n$ tiene un producto interno *natural* o *usual*:

$$\langle \vec{u}, \vec{v} \rangle = \vec{u}^{\mathrm{T}} \vec{v} = \sum_{i=1}^{n} u_i v_i.$$

  En este caso, la norma nos indica la longitud del vector, en virtud del teorema de Pitágoras:

$$\|\vec{u}\| = \sqrt{\vec{u}^{\mathrm{T}} \vec{u}} = \sqrt{u_1^2 + u_2^2 + \cdots + u_n^2}.$$

- Consideremos el espacio vectorial de funciones continuas en el intervalo $[a, b]$. El siguiente producto interno es válido y muy útil en la práctica (ejemplo: mecánica cuántica, ondas,

etc.):

$$\langle f, g\rangle = \int_a^b f(t)g(t)\,dt.$$

- Sea V el espacio de matrices reales $\mathcal{M}_{m\times n}(\mathbb{R})$. Un producto interno válido es:

$$\langle \mathrm{A}, \mathrm{B}\rangle = \mathrm{Tr}(\mathrm{B}^{\mathrm{T}}\mathrm{A}) = \sum_{i=1}^{m}\sum_{j=1}^{n} a_{ij}b_{ij}.$$

Ejercicio sugerido: demostrar que los tres productos internos satisfacen las propiedades de linealidad, simetría y de ser semidefinidos positivos.

21.2 *La matriz de Gram*

Sea $\mathrm{B} = \{\vec{b}_1, \vec{b}_2, \ldots, \vec{b}_n\}$ una base de V. Podemos escribir los vectores $\vec{u}, \vec{v}$ como combinaciones lineales de los vectores de B, y respecto a esa base el producto interno se expresa como:

$$\langle \vec{u}, \vec{v}\rangle = \langle u_1\vec{b}_1 + u_2\vec{b}_2 + \ldots u_n\vec{b}_n, v_1\vec{b}_1 + v_2\vec{b}_2 + \ldots v_n\vec{b}_n\rangle = [\vec{u}]_{\mathrm{B}}^{\mathrm{T}}\,\mathrm{G}^{\mathrm{B}}\,[\vec{v}]_{\mathrm{B}},$$

donde G^{B} es la **matriz de Gram** asociada a la base B, definida como:

$$\mathrm{G}^{\mathrm{B}} = \begin{bmatrix} \langle \vec{b}_1, \vec{b}_1\rangle & \langle \vec{b}_1, \vec{b}_2\rangle & \cdots & \langle \vec{b}_1, \vec{b}_n\rangle \\ \langle \vec{b}_2, \vec{b}_1\rangle & \langle \vec{b}_2, \vec{b}_2\rangle & \cdots & \langle \vec{b}_2, \vec{b}_n\rangle \\ \vdots & \vdots & \ddots & \vdots \\ \langle \vec{b}_n, \vec{b}_1\rangle & \langle \vec{b}_n, \vec{b}_2\rangle & \cdots & \langle \vec{b}_n, \vec{b}_n\rangle \end{bmatrix}.$$

Por las propiedades del producto interno, esta matriz debe satisfacer:

$$(\mathrm{G}^{\mathrm{B}})^{\mathrm{T}} = \mathrm{G}^{\mathrm{B}}, \qquad \vec{x}^{\mathrm{T}}\mathrm{G}^{\mathrm{B}}\vec{x} \geq 0 \quad \forall \vec{x} \in \mathbb{R}^n.$$

Ejemplo. En la base canónica $\mathcal{E}_n = \{\vec{e}_1, \ldots, \vec{e}_n\}$ de $\mathbb{R}^n$, se tiene:

$$[\vec{u}]_{\mathcal{E}_n} = \vec{u}.$$

Entonces:

$$\langle \vec{u}, \vec{v}\rangle = \vec{u}^{\mathrm{T}}\vec{v} = [\vec{u}]_{\mathcal{E}_n}^{\mathrm{T}}\,\mathbb{I}_n[\vec{v}]_{\mathcal{E}_n},$$

por lo que la matriz de Gram respecto de la base canónica de $\mathbb{R}^n$ es la identidad $\mathbb{I}_n$. Esto es lo que ya sabíamos: si no especificamos bases, el producto estándar corresponde a la suma de las multiplicaciones componente a componente de ambos vectores.

Ejercicio. Sea el producto usual en $\mathbb{R}^3$ y la base $\mathrm{B} = \{\vec{b}_1, \vec{b}_2, \vec{b}_3\}$ con:

$$\vec{b}_1 = \begin{bmatrix}1\\0\\0\end{bmatrix}, \quad \vec{b}_2 = \begin{bmatrix}1\\1\\0\end{bmatrix}, \quad \vec{b}_3 = \begin{bmatrix}1\\1\\1\end{bmatrix}.$$

Calcular la matriz de Gram respecto a B.

—

$$G^B = \begin{bmatrix} \langle \vec{b}_1, \vec{b}_1 \rangle & \langle \vec{b}_1, \vec{b}_2 \rangle & \langle \vec{b}_1, \vec{b}_3 \rangle \\ \langle \vec{b}_2, \vec{b}_1 \rangle & \langle \vec{b}_2, \vec{b}_2 \rangle & \langle \vec{b}_2, \vec{b}_3 \rangle \\ \langle \vec{b}_3, \vec{b}_1 \rangle & \langle \vec{b}_3, \vec{b}_2 \rangle & \langle \vec{b}_3, \vec{b}_3 \rangle \end{bmatrix} = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 2 \\ 1 & 2 & 3 \end{bmatrix}.$$

Hasta ahora hemos calculado la matriz de Gram para espacios Euclideos, con vectores al uso. En el siguiente ejemplo se ve cómo esta matriz traduce problemas en contextos más complejos, reduciéndolos a problemas púramente algebraicos.

Ejemplo. Consideremos $\mathbb{P}_2$ equipado con el producto interno

$$\langle f, g \rangle = \int_0^1 f(t)g(t)\,dt.$$

La base estándar es $S = \{1, t, t^2\}$. Calculemos la matriz de Gram respecto a S:

$$\langle 1, 1 \rangle = \int_0^1 1\,dt = 1, \qquad \langle 1, t \rangle = \int_0^1 t\,dt = \frac{1}{2}, \quad \langle 1, t^2 \rangle = \int_0^1 t^2\,dt = \frac{1}{3},$$

$$\langle t, t \rangle = \int_0^1 t^2\,dt = \frac{1}{3}, \qquad \langle t, t^2 \rangle = \int_0^1 t^3\,dt = \frac{1}{4}, \quad \langle t^2, t^2 \rangle = \int_0^1 t^4\,dt = \frac{1}{5}.$$

Así, la matriz de Gram es:

$$G^S = \begin{bmatrix} 1 & 1/2 & 1/3 \\ 1/2 & 1/3 & 1/4 \\ 1/3 & 1/4 & 1/5 \end{bmatrix}.$$

Sea $p(t) = 1 - t$ y $q(t) = 1 - t + t^2$. En la base S, tenemos:

$$[p(t)]_S = \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix}, \quad [q(t)]_S = \begin{bmatrix} 1 \\ -1 \\ 1 \end{bmatrix}.$$

Entonces:

$$\langle p(t), q(t) \rangle = [p(t)]_S\, G^S\, [q(t)]_S = [1, -1, 0] \begin{bmatrix} 1 & 1/2 & 1/3 \\ 1/2 & 1/3 & 1/4 \\ 1/3 & 1/4 & 1/5 \end{bmatrix} \begin{bmatrix} 1 \\ -1 \\ 1 \end{bmatrix} = \frac{5}{12}.$$

Y esto es precisamente el valor de $\int_0^1 (1-t)(1-t+t^2)dt$, pero nos hemos ahorrado el cálculo explícito de esa integral. De hecho, ahora que tenemos G^B construido, cualquier producto interno de polinomios en $\mathbb{P}_2$ lo podemos calcular algebraicamente, sin tener que hacer ni una sola integral.

La ventaja de la matriz de Gram es que, una vez la tenemos calculada, cualquier producto interno

que necesitemos consiste únicamente en una multiplicación de vectores por matrices: no es necesario calcular de nuevo el producto interno. Por ejemplo, en el caso anterior no hizo falta calcular explícitamente la integral

$$\int_0^1 p(t)q(t)\,dt.$$

Esto, como veremos, es muy útil, ya que el producto interno nos permite calcular distancias y ángulos, es decir, nos permite "medir". [5]

Hay ciertas propiedades de los productos internos y las normas que conviene conocer.

21.1 THEOREM. *desigualdad de Cauchy-Schwartz Para todo $\vec{u}, \vec{v} \in \mathrm{V}$ se cumple*

$$\left|\langle \vec{u}, \vec{v}\rangle\right| \leq \|\vec{u}\| \cdot \|\vec{v}\|.$$

La desigualdad se satura si y sólo si $\vec{u} \propto \vec{v}$.

EJEMPLO. Por ejemplo, si $f(t)$ y $g(t)$ son funciones continuas en un intervalo $a \leq t \leq b$, la desigualdad de Cauchy–Schwarz nos dice que

$$\left(\int_a^b f(t)g(t)\,dt\right)^2 \leq \left(\int_a^b f(t)^2\,dt\right)\left(\int_a^b g(t)^2\,dt\right).$$

Existen además propiedades adicionales que toda norma inducida por un producto interno cumple. Para todo $\vec{u}, \vec{v} \in \mathrm{V}$ $k \in \mathbb{K}$,

- $\|\vec{v}\| \geq 0$, y $\|\vec{v}\| = 0$ si y sólo si $\vec{v} = 0$.
- $\|k\vec{v}\| = |k|\|\vec{v}\|$.
- Desigualdad triangular:
$$\|\vec{u} + \vec{v}\| \leq \|\vec{u}\| + \|\vec{v}\|.$$
Esta última es de sobra conocida en $\mathbb{R}^n$ (se tarda menos yendo en diagonal que yendo en horizontal y vertical), pero realmente es válida para cualquier espacio vectorial.

EJEMPLO. Sean

$$\vec{u}_1 = \begin{bmatrix} 2 \\ 1 \end{bmatrix}, \quad \vec{u}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Calculemos ambos lados de la desigualdad triangular:

$$\|\vec{u}_1 + \vec{u}_2\| = \sqrt{13} \approx 3.605, \qquad \|\vec{u}_1\| + \|\vec{u}_2\| = \sqrt{5} + \sqrt{2} \approx 3.65.$$

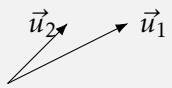

[5] Un ejemplo relevante aparece en relatividad general: la generalización de la matriz de Gram es la llamada *métrica*, y cuando se estudian los agujeros negros como solución de las ecuaciones de Einstein, lo que realmente se está usando es precisamente esto (como en la película *Interstellar* y la dilatación temporal).

Un vector $\vec{u}$ de norma $\|\vec{u}\| = 1$ se denomina *unitario*. A partir de cualquier vector no nulo $\vec{v}$ se puede construir un vector unitario mediante la llamada *normalización*:

$$\vec{u} = \frac{\vec{v}}{\|\vec{v}\|}.$$

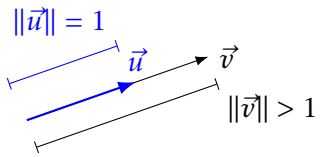

Podemos también definir la **distancia entre vectores** $\vec{u}, \vec{v} \in V$ como

$$\operatorname{dist}(\vec{u}, \vec{v}) = \|\vec{u} - \vec{v}\|.$$

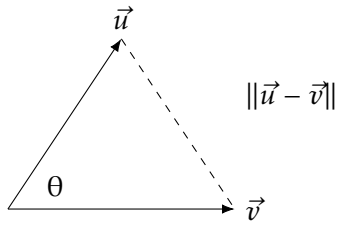

Esta definición coincide con la usual en $\mathbb{R}^n$.
Asimismo, se puede definir un **ángulo entre vectores** $\vec{u}, \vec{v} \in V$ mediante

$$\cos\theta = \frac{\langle \vec{u}, \vec{v} \rangle}{\|\vec{u}\| \cdot \|\vec{v}\|}, \quad \theta \in [0, \pi].$$

Curiosidad: actualmente está muy de moda el tema de los *Large Language Models* (LLMs) como ChatGPT, Gemini, Claude, etc. Gran parte de las matemáticas que lo sustentan son álgebra lineal, y, en concreto, estas IAs han aprendido qué conceptos son "similares" (por ejemplo, que una pera y una manzana son más parecidos que una pera y una montaña) gracias a la introducción de productos internos apropiados, que dan un valor numérico, una "distancia", entre conceptos.

22 ORTOGONALIDAD

Sea V un espacio vectorial. Se dice que dos vectores $\vec{u}, \vec{v} \in V$ son **ortogonales** (entre sí) o perpendiculares si se cumple que

$$\langle \vec{u}, \vec{v} \rangle = 0.$$

Claramente, el vector nulo $\vec{0}$ es ortogonal a todos los vectores, ya que $\langle \vec{0}, \vec{v} \rangle = \langle 0 \cdot \vec{v}, \vec{v} \rangle = 0\langle \vec{v}, \vec{v} \rangle = 0$. Otra conclusión que obtenemos es que, entre vectores ortogonales, el ángulo formado es $\pi/2$.

El **teorema de Pitágoras** aparece en este contexto como el caso de vectores ortogonales en el espacio euclídeo $\mathbb{R}^n$. En efecto, si $\vec{u}, \vec{v}$ son ortogonales, entonces

$$\|\vec{u} + \vec{v}\|^2 = \langle \vec{u} + \vec{v}, \vec{u} + \vec{v} \rangle = \langle \vec{u}, \vec{u} \rangle + \langle \vec{v}, \vec{v} \rangle + 2\langle \vec{u}, \vec{v} \rangle.$$

Pero como $\langle \vec{u}, \vec{v} \rangle = 0$, obtenemos

$$\|\vec{u} + \vec{v}\|^2 = \|\vec{u}\|^2 + \|\vec{v}\|^2.$$

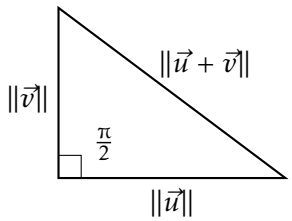

22.1 *Complemento ortogonal*

Sea W un subespacio de un espacio vectorial V equipado con producto interno. El **complemento ortogonal** de W, denotado $W^\perp$, es el conjunto de todos los vectores ortogonales a W:

$$W^\perp = \{\vec{v} \in V \ : \ \langle \vec{v}, \vec{w} \rangle = 0 \quad \forall \vec{w} \in W\}.$$

Claramente esto forma un subespacio porque el vector nulo $\vec{0} \in V$ es perpendicular a todo vector y, por tanto, pertenece a $W^\perp$. Además, se cumple

$$\langle a\vec{u} + b\vec{v}, \vec{w} \rangle = a\langle \vec{u}, \vec{w} \rangle + b\langle \vec{v}, \vec{w} \rangle = 0,$$

para todo $\vec{w} \in W$, $\vec{u}, \vec{v} \in W^{\perp}$, y $a, b \in \mathbb{K}$.

Ejemplo. Hallar el subespacio de $\mathbb{R}^3$ ortogonal a

$$W = \operatorname{Span}\left\{\begin{bmatrix}1\\3\\5\end{bmatrix}, \begin{bmatrix}0\\1\\4\end{bmatrix}\right\}.$$

Si $\vec{u} = \begin{bmatrix}u_1\\u_2\\u_3\end{bmatrix} \in W^{\perp}$, se deben cumplir las condiciones

$$\begin{cases} u_1 + 3u_2 + 5u_3 = 0, \\ u_2 + 4u_3 = 0, \end{cases}$$

de donde se deduce

$$W^{\perp} = \operatorname{Span}\left\{\begin{bmatrix}7\\-4\\1\end{bmatrix}\right\}.$$

El siguiente teorema nos dice que la descomposición de un vector en componentes paralela y perpendicular a un subespacio es única.

22.1 THEOREM. *Sea* $W = Span\{\vec{v}\}$ *con* $\vec{v} \in V$ *y* $\vec{v} \neq 0$. *Entonces, para todo* $\vec{x} \in V$ *existen un único* $\vec{w} \in W$ *y un único* $\vec{u} \in W^{\perp}$ *tales que*

$$\vec{x} = \vec{w} + \vec{u}.$$

Esto será esencial cuando hablemos de proyecciones.

22.2 *Conjuntos ortogonales*

Se dice que un conjunto de vectores $\{\vec{u}_1, \ldots, \vec{u}_n\}$ de un espacio vectorial V es un *conjunto ortogonal* si cada par de vectores distintos del conjunto es ortogonal, es decir:

$$\langle \vec{u}_i, \vec{u}_j \rangle = 0 \quad \text{si } i \neq j.$$

Si además los vectores son unitarios, se dice que el conjunto es *ortonormal*:

$$\langle \vec{u}_i, \vec{u}_j \rangle = \delta_{ij} = \begin{cases} 0 & \text{si } i \neq j, \\ 1 & \text{si } i = j. \end{cases}$$

Ejemplo. La base canónica de $\mathbb{R}^3$, $\mathcal{E} = \{\vec{e}_1, \vec{e}_2, \vec{e}_3\}$, cumple que

$$\langle \vec{e}_i, \vec{e}_j \rangle = \delta_{ij}.$$

El siguiente resultado es evidente.

22.2 THEOREM. *Si* S *es un conjunto ortogonal de vectores no nulos, entonces* S *es linealmente independiente.*

EJEMPLO. Consideremos $\mathbb{P}_2$ con el producto interno definido como

$$\langle f, g\rangle = \int_0^1 f(t)g(t)\,dt.$$

La base estándar de $\mathbb{P}_2$, $\mathrm{B} = \{1, t, t^2\}$, no es un conjunto ortogonal, pues:

$$\langle 1, t\rangle = \int_0^1 t\,dt = \frac{1}{2}, \qquad \langle 1, t^2\rangle = \int_0^1 t^2\,dt = \frac{1}{3}, \qquad \langle t, t^2\rangle = \int_0^1 t^3\,dt = \frac{1}{4}.$$

Por otro lado, el conjunto $\mathrm{S} = \{1, 1-2t\}$ sí es ortogonal:

$$\langle 1, 1-2t\rangle = \int_0^1 (1-2t)\,dt = 0.$$

Por tanto, S es linealmente independiente y base de su subespacio. Si además añadimos $\{2 - 12t + 12t^2\}$, sigue siendo ortogonal y ahora es base de todo $\mathbb{P}_2$. Esto puede comprobarse con la matriz de Gram.

22.3 THEOREM. *Sea* $\{\vec{u}_1, \dots, \vec{u}_n\}$ *una base ortogonal de* V. *Entonces, para todo* $\vec{v} \in \mathrm{V}$ *se tiene*

$$\vec{v} = c_1\vec{u}_1 + \cdots + c_n\vec{u}_n, \qquad c_i = \frac{\langle \vec{v}, \vec{u}_i\rangle}{\langle \vec{u}_i, \vec{u}_i\rangle}.$$

Los coeficientes c_i se denominan *coeficientes de Fourier* de $\vec{v}$ respecto a $\{\vec{u}_1, \dots, \vec{u}_n\}$.

EJERCICIO. Dados

$$\vec{u}_1 = \begin{bmatrix} 3 \\ 1 \\ 1 \end{bmatrix}, \quad \vec{u}_2 = \begin{bmatrix} -1 \\ 2 \\ 1 \end{bmatrix}, \quad \vec{u}_3 = \begin{bmatrix} -\frac{1}{2} \\ -2 \\ \frac{7}{2} \end{bmatrix},$$

mostrar que forman una base ortogonal de $\mathbb{R}^3$ y expresar $\vec{v} = \begin{bmatrix} 6 \\ -1 \\ 8 \end{bmatrix}$ como combinación lineal de ellos.

—

Los coeficientes de Fourier son:

$$c_1 = \frac{\langle \vec{v}, \vec{u}_1\rangle}{\|\vec{u}_1\|^2} = 1, \qquad c_2 = \frac{\langle \vec{v}, \vec{u}_2\rangle}{\|\vec{u}_2\|^2} = -2, \qquad c_3 = \frac{\langle \vec{v}, \vec{u}_3\rangle}{\|\vec{u}_3\|^2} = -2.$$

Por lo tanto,

$$\vec{v} = \vec{u}_1 - 2\vec{u}_2 - 2\vec{u}_3.$$

22.3 *Proyecciones*

La descomposición anterior nos lleva a la noción de *proyección* de $\vec{v}$ sobre $\vec{w}$, definida como

$$\operatorname{proj}_{\vec{w}} \vec{v} = \frac{\langle \vec{v}, \vec{w} \rangle}{\langle \vec{w}, \vec{w} \rangle} \vec{w}.$$

De este modo, la combinación lineal anterior puede entenderse como la suma de las proyecciones de $\vec{v}$ sobre cada vector del conjunto ortogonal.

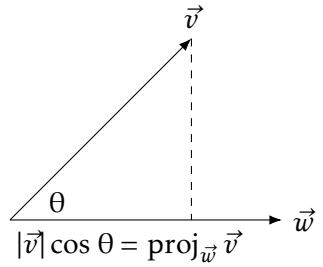

Esto implica también que $\vec{v}' = \vec{v} - \operatorname{proj}_{\vec{w}} \vec{v}$ es necesariamente perpendicular a $\vec{w}$ (le hemos sustraído a $\vec{v}$ la contribución en la dirección $\vec{w}$, y al ser parte de un conjunto ortogonal no la pueden suplir el resto de direcciones).

De forma más general, podemos definir la proyección de $\vec{v}$ sobre un subespacio $W = \operatorname{Span}\{\vec{w}_1, \dots, \vec{w}_p\}$ como

$$\operatorname{proj}_W \vec{v} = \sum_{i=1}^{p} \frac{\langle \vec{v}, \vec{w}_i \rangle}{\langle \vec{w}_i, \vec{w}_i \rangle} \vec{w}_i.$$

22.4 THEOREM. *Sean $\{\vec{u}_1, \dots, \vec{u}_p\}$ un conjunto ortogonal de vectores no nulos de V y sea $\vec{v} \in V$ cualquier vector. Definimos*

$$\vec{v}^{\perp} = \vec{v} - \operatorname{proj}_W \vec{v}, \qquad W = \operatorname{Span}\{\vec{u}_1, \dots, \vec{u}_p\}.$$

Entonces, $\vec{v}^{\perp}$ es ortogonal a $\vec{u}_1, \dots, \vec{u}_p$.

EJERCICIO. Reflejar el vector $\vec{v} = \begin{bmatrix} 0 \\ 1 \\ 2 \end{bmatrix}$ respecto al plano generado por

$$\vec{w}_1 = \begin{bmatrix} 3 \\ 1 \\ 1 \end{bmatrix}, \qquad \vec{w}_2 = \begin{bmatrix} -1 \\ 2 \\ 1 \end{bmatrix}.$$

Tenemos que el subespacio es $W = \operatorname{Span}\{\vec{w}_1, \vec{w}_2\}$. Para reflejarlo, simplemente le restamos la proyección dos veces (la primera lo "baja" al subespacio, la siguiente lo baja aun más a su reflejo)

$$\vec{v}' = \vec{v} - 2 \operatorname{proj}_W \vec{v} = \vec{v} - \frac{6}{11} \vec{w}_1 - \frac{8}{6} \vec{w}_2.$$

El anterior teorema generaliza lo que hemos discutido anteriormente, y prepara el terreno para la ortogonalización conjuntos de vectores.

22.4 *Proceso de Gram–Schmidt*

Sea $B = \{\vec{v}_1, \vec{v}_2, \dots, \vec{v}_n\}$ una base de un espacio vectorial V. Definimos

$$\vec{w}_1 = \vec{v}_1,$$

$$\vec{w}_2 = \vec{v}_2 - \operatorname{proj}_{\vec{w}_1} \vec{v}_2,$$

$$\vec{w}_3 = \vec{v}_3 - \operatorname{proj}_{\vec{w}_1} \vec{v}_3 - \operatorname{proj}_{\vec{w}_2} \vec{v}_3,$$

$$\dots$$

$$\vec{w}_n = \vec{v}_n - \operatorname{proj}_{\vec{w}_1} \vec{v}_n - \operatorname{proj}_{\vec{w}_2} \vec{v}_n - \dots - \operatorname{proj}_{\vec{w}_{k-1}} \vec{v}_n.$$

En otras palabras, para $k = 2, 3, \dots, n$ definimos

$$\vec{w}_k = \vec{v}_k - \operatorname{proj}_{\mathrm{W}} \vec{v}_k, \quad \mathrm{W} = \{\vec{w}_1, \dots, \vec{w}_{k-1}\}.$$

Por el teorema anterior, cada $\vec{w}_k$ es ortogonal a los anteriores, por lo que $\{\vec{w}_1, \dots, \vec{w}_n\}$ forma una base ortogonal de V. Normalizándolos se obtiene una base ortonormal.

Este procedimiento recibe el nombre de *ortogonalización de Gram–Schmidt*.

22.5 THEOREM. *Sea* $\mathrm{S} = \{\vec{w}_1, \dots, \vec{w}_p\}$ *una base ortogonal de* W, *subespacio de* V. *Se puede extender* S *a una base ortogonal de* V, *es decir, encontrar vectores* $\vec{w}_{p+1}, \dots, \vec{w}_n$ *tales que*

$$\{\vec{w}_1, \dots, \vec{w}_p, \vec{w}_{p+1}, \dots, \vec{w}_n\}$$

sea una base ortogonal de V.

Esto tiene sentido: podemos extender S con vectores linealmente independientes que luego ortogonalizamos con Gram–Schmidt.

EJERCICIO. Aplicar Gram–Schmidt para encontrar una base de

$$\mathrm{W} = \operatorname{Span}\left\{\begin{bmatrix}1\\1\\1\\1\end{bmatrix}, \begin{bmatrix}2\\4\\5\\-2\end{bmatrix}, \begin{bmatrix}-3\\-4\\5\\-2\end{bmatrix}\right\} \subset \mathbb{R}^4.$$

—

Seguimos el proceso calculando $\vec{w}_1$, luego $\vec{w}_2$ y finalmente $\vec{w}_3$:

$$\vec{w}_1 = \vec{v}_1,$$

$$\vec{w}_2 = \vec{v}_2 - \frac{\langle \vec{v}_2, \vec{w}_1 \rangle}{\langle \vec{w}_1, \vec{w}_1 \rangle} \vec{w}_1 = \vec{v}_2 - \frac{12}{4} \vec{w}_1 = \begin{bmatrix}-2\\-1\\1\\2\end{bmatrix},$$

$$\vec{w}_3 = \vec{v}_3 - \frac{\langle \vec{v}_3, \vec{w}_1 \rangle}{\langle \vec{w}_1, \vec{w}_1 \rangle} \vec{w}_1 - \frac{\langle \vec{v}_3, \vec{w}_2 \rangle}{\langle \vec{w}_2, \vec{w}_2 \rangle} \vec{w}_2 = \vec{v}_3 - \frac{8}{4} \vec{w}_1 - \frac{7}{10} \vec{w}_2 = \frac{1}{10} \begin{bmatrix}16\\-17\\-13\\14\end{bmatrix},$$

Convendría ahora comprobar la ortogonalidad del conjunto.

Ejercicio. Consideremos $\mathbb{P}_3$ con la base estándar $\{1, t, t^2, t^3\}$ y el producto interno

$$\langle f, g\rangle = \int_{-1}^{1} f(t)g(t)\,dt.$$

Encontrar una base ortogonal.

—

Sabemos que

$$\langle t^r, t^s\rangle = \int_{-1}^{1} t^{r+s}\,dt = \left.\frac{t^{r+s+1}}{r+s+1}\right|_{-1}^{1} = \begin{cases} \frac{2}{r+s+1}, & r+s \text{ par}, \\ 0, & r+s \text{ impar}. \end{cases}$$

Aplicando Gram–Schmidt obtenemos:

$$f_0 = 1, \qquad f_1 = t, \qquad f_2 = t^2 - \frac{1}{3}, \qquad f_3 = t^3 - \frac{3}{5}t.$$

23 OPTIMIZACIÓN

Una de las aplicaciones más importantes de los conceptos de este tema es en problemas de optimización: dado un conjunto de restricciones (que usualmente vienen dadas por las propiedades de los sistemas que estemos intentando modelar, o de necesidades particulares a satisfacer) que usualmente no podemos satisfacer por completo, queremos aun así encontrar la solución que se aproxime más a cada una de las restricciones impuestas. Esa idea nos va a llevar a la conocida "solución por mínimos cuadrados".

Comenzamos con el teorema siguiente, que es bastante intuitivo.

23.1 theorem (de la mejor aproximación). *Sea* W *un subespacio de* V *y* $\vec{v} \in$ V. *Entonces, para todo* $\vec{w} \in$ W *se cumple*

$$\|\vec{v} - \operatorname{proj}_W \vec{v}\| \leq \|\vec{v} - \vec{w}\|.$$

Esto nos indica que $\vec{y} = \operatorname{proj}_W \vec{v}$ es el punto más cercano a $\vec{v}$ dentro del subespacio W.

Visualmente, tenemos que las restricciones impuestas (siempre y cuando sean lineales) conforman un subespacio W, y dentro de ese subespacio queremos el mejor vector (en el sentido de más cercano) a la solución ideal (pero que no es factible) $\vec{v}$.

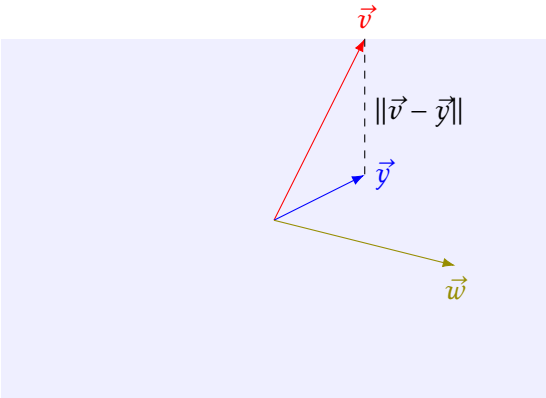

23.1 *Mínimos cuadrados*

Un ejemplo de lo anterior ocurre en los sistemas inconsistentes. Consideremos el sistema $A\vec{x} = \vec{b}$, sin solución $\vec{x}$. Queremos obtener el vector $\vec{x}^{\times}$ que más acerque $A\vec{x}^{\times}$ a $\vec{b}$.

Sea $A \in \mathbb{M}_{m\times n}$ y $\vec{b} \in \mathbb{R}^m$. Una *solución por mínimos cuadrados* de $A\vec{x}\times = \vec{b}$ es un vector $\vec{x}^{\times} \in \mathbb{R}^n$ tal que

$$\|\vec{b} - A\vec{x}^{\times}\| \leq \|\vec{b} - A\vec{x}\| \quad \forall \vec{x} \in \mathbb{R}^n.$$

La clave es que $A\vec{x} \in \mathrm{Col}(A)$ para todo $\vec{x}$, y buscamos la mejor aproximación de $\vec{b}$ en ese subespacio:

$$\vec{b}' = \mathrm{proj}_{\mathrm{Col}(A)}\, \vec{b}.$$

Entonces resolvemos el sistema consistente $A\vec{x}^{\times} = \vec{b}'$.

Sea $\vec{x}^{\times}$ tal que $A\vec{x}^{\times} = \vec{b}'$. Por el teorema de la descomposición ortogonal, $\vec{b} - \vec{b}'$ es ortogonal a $\mathrm{Col}(A)$. Es decir,

$$A^T(\vec{b} - \vec{b}') = A^T(\vec{b} - A\vec{x}^{\times}) = 0.$$

23.2 THEOREM. *El conjunto de soluciones por mínimos cuadrados de $A\vec{x} = \vec{b}$ coincide con el conjunto no vacío de soluciones de*

$$A^T A\vec{x}^{\times} = A^T\vec{b}.$$

Por tanto, usando todas las técnicas vistas en temas anteriores, resolviendo ese sistema encontraríamos la solución buscada. Si además A fuera invertible, la obtención de esta solución tiene una forma cerrada, siendo su obtención por tanto inmediata (y única).

23.3 THEOREM. *Si la matriz $A^T A$ es invertible (lo cual ocurre cuando las columnas de A son linealmente independientes), entonces el sistema $A\vec{x} = \vec{b}$ tiene una solución de mínimos cuadrados única dada por*

$$\vec{x}^{\times} = (A^T A)^{-1} A^T\vec{b}.$$

Un apunte respecto al nombre: aquí no vamos a discutirlo en detalle, pero se denomina "mínimos cuadrados" ya que, en el caso Euclidiano con el producto interno estándar, minimiza la distancia al subespacio de las restricciones (que por el Teorema de Pitágoras, proviene de la suma de los cuadrados de los lados).

EJERCICIO. Encontrar la solución de mínimos cuadrados del sistema inconsistente $A\vec{x} = \vec{b}$ con

$$A = \begin{bmatrix} 4 & 0 \\ 0 & 2 \\ 1 & 1 \end{bmatrix}, \quad \vec{b} = \begin{bmatrix} 2 \\ 0 \\ 11 \end{bmatrix}.$$

—

Calculamos:

$$A^T A = \begin{bmatrix} 17 & 1 \\ 1 & 5 \end{bmatrix}, \qquad A^T\vec{b} = \begin{bmatrix} 19 \\ 11 \end{bmatrix}.$$

Resolvemos

$$A^T A\vec{x}^{\times} = A^T\vec{b},$$

es decir,

$$\begin{bmatrix} 17 & 1 \\ 1 & 5 \end{bmatrix} \vec{x}^{\times} = \begin{bmatrix} 19 \\ 11 \end{bmatrix}.$$

El resultado es

$$\vec{x}^{\times} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

24 EXTRA

24.1 *Descomposición QR*

REFERENCES

[1] David C Lay. *Álgebra lineal y sus aplicaciones*. Pearson educación, 2007.
[2] Peter Woit. URL: https://www.math.columbia.edu/~woit/eulerformula.pdf.

Appendix A

Derivaciones de la fórmula de Euler

En la Sección 3.2 hemos postulado la forma exponencial mediante la Fórmula de Euler. Si bien hemos motivado la razón de ser de esa fórmula, es interesante entender más concretamente de dónde viene, y por qué es efectivamente cierta, aunque eso se va ligeramente del nivel y contenido de este curso.

A continuación, presentamos tres derivaciones distintas de dicha Fórmula, que hacen uso de diferentes ideas y/o técnicas matemáticas (integrales, ecuaciones diferenciales o series de Taylor), que son entendibles para cualquiera que haya cursado asignaturas de cálculo/análisis de primero de cualquier grado de ciencias.

.1 *A partir de la derivada del arcotangente*

La derivación parte de la integral cuya primitiva es la función arcotangente, es decir,

$$\int \frac{1}{1+x^2}\,dx = \arctan(x).$$

Para obtener una expresión compleja equivalente, se factoriza el denominador en $\mathbb{C}$:

$$1 + x^2 = (1 - ix)(1 + ix),$$

y (omitiendo los pasos rutinarios de fracciones parciales) se llega a

$$\arctan(x) = \int \frac{1}{1+x^2}\,dx = \frac{1}{2}\int\left(\frac{1}{1-ix} + \frac{1}{1+ix}\right)dx = \frac{1}{2i}\,\ln\left(\frac{1+ix}{1-ix}\right).$$

Sustituyendo ahora $x = \tan\theta = \sin\theta/\cos\theta$, tenemos

$$\theta = \frac{1}{2i}\ln\left(\frac{1+i\tan\theta}{1-i\tan\theta}\right) = \frac{1}{2i}\ln\left(\frac{\cos\theta + i\sin\theta}{\cos\theta - i\sin\theta}\right).$$

Como el denominador es el conjugado del numerador, multiplicando y dividiendo por el numerador

y aplicando propiedades básicas de los logaritmos obtenemos

$$\theta = \frac{1}{i}\ln(\cos\theta + i\sin\theta).$$

Multiplicando por i y exponenciando obtenemos finalmente la Fórmula de Euler,

$$i\theta = \ln(\cos\theta + i\sin\theta) \quad \Longrightarrow \quad e^{i\theta} = \cos\theta + i\sin\theta.$$

Cabe mencionar que aquí hemos tomado a la ligera el hecho de que los logaritmos presentes en la demostración tienen argumentos complejos. La discusión de las funciones complejas se va del nivel de este curso, por tanto aquí basta decir que los logaritmos se pueden generalizar así, al igual que la exponencial o las funciones trigonométricas.

.2 *A partir de la ecuación diferencial de la exponencial*

Consideremos la función $f(x) = \cos(x) + i\sin(x)$. Queremos mostrar, usando derivadas e integración, que coincide con e^{ix}. Primero derivamos, y factorizamos i para llegar a la siguiente expresión,

$$f'(x) = \frac{d}{dx}(\cos x + i\sin x) = -\sin x + i\cos x = if(x) \qquad \Longrightarrow \qquad \frac{f'(x)}{f(x)} = i.$$

Integramos ambos lados, notando que la izquierda da un logaritmo y la derecha una función lineal,

$$\int \frac{f'(x)}{f(x)}\,dx = \int i\,dx \qquad \Longrightarrow \qquad \ln|f(x)| = ix + \mathrm{C}.$$

Para determinar C, evaluamos en $x = 0$, y comparamos con lo que sabemos que debe dar $f(x)$ según la definición inicial:

$$\ln(f(0)) = \mathrm{C}.$$

Como $f(0) = 1$, se tiene $\ln(1) = 0$, luego $\mathrm{C} = 0$.

Sustituyendo, llegamos a

$$\ln(f(x)) = ix \qquad \Longrightarrow \qquad f(x) = e^{ix}.$$

Con lo que queda claro que $f(x) = \cos(x) + i\sin(x) = e^{ix}$.

.3 *A partir de las correspondientes series de Taylor*

La demostración vía series de Taylor es quizá la más directa y elegante. Recordemos las series de Maclaurin (series de Taylor centradas en $x = 0$) de e^x, $\cos x$ y $\sin x$,

$$e^x = \sum_{n=0}^{\infty}\frac{x^n}{n!}, \qquad \cos x = \sum_{n=0}^{\infty}\frac{(-1)^n x^{2n}}{(2n)!}, \qquad \sin x = \sum_{n=0}^{\infty}\frac{(-1)^n x^{2n+1}}{(2n+1)!}.$$

Sustituimos x por ix en la serie de e^x, y usamos las propiedades cíclicas de las potencias de i $(i, -1, -i, 1)$. La expansión queda

$$e^{ix} = 1 + ix - \frac{x^2}{2!} - i\frac{x^3}{3!} + \frac{x^4}{4!} + i\frac{x^5}{5!} - \frac{x^6}{6!} - i\frac{x^7}{7!} + \cdots.$$

Separamos parte real y parte imaginaria:

$$e^{ix} = \left(1 - \frac{x^2}{2!} + \frac{x^4}{4!} - \frac{x^6}{6!} + \cdots\right) + i\left(x - \frac{x^3}{3!} + \frac{x^5}{5!} - \frac{x^7}{7!} + \cdots\right).$$

Reconocemos inmediatamente que ambas partes se corresponden con la serie del seno y la del coseno, y por tanto:

$$e^{ix} = \cos(x) + i\sin(x)$$

Appendix B

Matrices simétricas y matrices no negativas